



第 7 章

位置、速度和时间解算

本章要点

- 最小二乘法解算
 - 卡尔曼滤波解算
 - 最小二乘法和卡尔曼滤波总结
- 

在本章中,将针对第5章提出的伪距、载波相位和多普勒观测量详细讲解如何利用这些观测量来计算接收机的位置、速度和时间偏差。本章主要分为两大部分:第一部分是如何利用最小二乘法来计算用户的位置、速度和钟差,由于这三项的英文单词分别为 Position、Velocity 和 Time,所以一般把这个计算过程简称为 PVT 解算;第二部分讲解如何利用卡尔曼滤波的方法来进行 PVT 解算。最小二乘法作为常规的解算方法,在现实和理论上都有着重要意义,也是理解后面卡尔曼滤波的基础。在用最小二乘法完成了 PVT 解算以后,就可以计算几何精度因子和卫星的仰角辐角等一些接收机内很重要的信息,将这部分内容和最小二乘法放在一起讲解,会使读者对接收机内部的导航算法有一个整体的概念,也比较容易理解和接受。卡尔曼滤波的方法虽理解起来难度相对比较大,对读者在信号估值理论和自适应滤波理论等方面的背景知识要求较高,但它是现代接收机设计必不可少的一部分,所以第二部分用了较大的篇幅来讲解,尽量使读者在理解了最小二乘法原理的基础上能接受并真正理解卡尔曼滤波方法。但由于本书毕竟不是专门讲解信号估值理论和自适应滤波理论的著作,对相关理论无法面面俱到,所以有兴趣进一步深刻理解的读者可以阅读这方面的其他专业书籍和文献。

本章将结合北斗和 GPS 双模观测量的数学模型,分析双模联合定位的算法原理,并和单模定位算法进行对比,分析双模联合定位的性能优势和由此带来的问题。针对双模观测量的特点,最小二乘法和卡尔曼滤波方法均需要进行相应的调整。由于单模和双模观测量同时共存,所以在实际的北斗 / GPS 双模接收机实现中需要考虑兼容单模和双模观测量的定位算法。

本章的内容涵盖了一部分随机过程和状态参数估计的知识,考虑到读者的背景不同,所以本着由浅入深、循序渐进的原则,在深入讲述定位算法之前先讲述一些有关参数估计和随机过程的基本知识,使没有这方面背景知识的读者也可以大致理解本章的内容。感兴趣并想进一步深入理解的读者,可以参阅有关状态参数估计和信号估值理论的书籍。



7.1 最小二乘法解算

7.1.1 基本原理

考虑包含噪声的状态观测方程如下:

$$\mathbf{Y} = \mathbf{A}\mathbf{x} + \mathbf{n} \quad (7.1)$$

式中, $\mathbf{x}$ 是我们需要估计的系统状态量。 $\mathbf{x} \in \mathbb{R}^k$, 这里 $\mathbb{R}^k$ 表示 k 维向量空间, k 是系统状态变量的数目。我们没有办法直接观测到 $\mathbf{x}$, 但可以观测到 $\mathbf{Y}$, 用 $\tilde{\mathbf{Y}}$ 来表示实际观测量。 $\mathbf{A}$ 是系统观测矩阵, 它反映了从状态量到观测量的转换关系。具体来

说, $\mathbf{A}$ 的每一个行向量将状态变量转换到一个观测量。观测量中不可避免地会包含有噪声, 式(7.1)中用 $\mathbf{n}$ 表示观测量中的噪声向量。假设我们能得到 m 个观测量, 则 $\mathbf{Y}$ 和 $\mathbf{n}$ 是一个 $m \times 1$ 的矩阵 (向量), $\mathbf{A}$ 是一个 $m \times k$ 的矩阵。

现在的问题是如何由观测量 $\tilde{\mathbf{Y}}$ 以一种最优化的方法估计出 $\mathbf{x}$? 这个问题本身其实也提出了另一个问题, 即如何定义“最优化”?

假设对状态 $\mathbf{x}$ 的估计值为 $\hat{\mathbf{x}}$, 则可以定义代价函数 $J(\hat{\mathbf{x}})$ 如下:

$$J(\hat{\mathbf{x}}) = (\tilde{\mathbf{Y}} - \mathbf{A}\hat{\mathbf{x}})^T (\tilde{\mathbf{Y}} - \mathbf{A}\hat{\mathbf{x}}) \quad (7.2)$$

式(7.2)中代价函数 $J(\hat{\mathbf{x}})$ 的含义可以进行如下的理解: 前面说过, $\mathbf{A}$ 的每一行将状态变量转换到一个观测量, 因为 $\hat{\mathbf{x}}$ 是对系统状态量的一个估计, 所以 $\mathbf{A}$ 的每一行将 $\hat{\mathbf{x}}$ 转换到一个观测量的估计值。如果实际观测量 $\tilde{\mathbf{Y}} = [\tilde{y}_1, \tilde{y}_2, \dots, \tilde{y}_m]^T$, 那么, $\mathbf{A}\hat{\mathbf{x}} = [\hat{y}_1, \hat{y}_2, \dots, \hat{y}_m]^T$ 。显然, $\mathbf{A}\hat{\mathbf{x}}$ 就是对式(7.1)中 $\mathbf{Y}$ 的估计值, $(\tilde{\mathbf{Y}} - \mathbf{A}\hat{\mathbf{x}})$ 是实际观测量和估计观测量之间的差, 于是 $J(\hat{\mathbf{x}})$ 是 $(\tilde{\mathbf{Y}} - \mathbf{A}\hat{\mathbf{x}})$ 的 2-范数的平方。显然 $J(\hat{\mathbf{x}})$ 是 $\hat{\mathbf{x}}$ 的一个二次型, 衡量了实测观测量和估计观测量之间的差别, 当 $(\tilde{\mathbf{Y}} - \mathbf{A}\hat{\mathbf{x}})$ 为 $\mathbf{0}$ 向量时 $J(\hat{\mathbf{x}}) = 0$, 表示此时实现了对 $\mathbf{x}$ 的完美估计。有了代价函数的定义, 我们将能够使代价函数最小化的 $\hat{\mathbf{x}}$ 叫作“最优的”。从这个意义来说, 这也是最小二乘法 (Least Square) 的名字由来。

将式(7.2)展开得到:

$$\begin{aligned} J(\hat{\mathbf{x}}) &= \tilde{\mathbf{Y}}^T \tilde{\mathbf{Y}} - \hat{\mathbf{x}}^T \mathbf{A}^T \tilde{\mathbf{Y}} - \tilde{\mathbf{Y}}^T \mathbf{A} \hat{\mathbf{x}} + \hat{\mathbf{x}}^T \mathbf{A}^T \mathbf{A} \hat{\mathbf{x}} \\ &= \tilde{\mathbf{Y}}^T \tilde{\mathbf{Y}} - 2\tilde{\mathbf{Y}}^T \mathbf{A} \hat{\mathbf{x}} + \hat{\mathbf{x}}^T \mathbf{A}^T \mathbf{A} \hat{\mathbf{x}} \end{aligned} \quad (7.3)$$

式(7.3)中第二步是因为 $\hat{\mathbf{x}}^T \mathbf{A}^T \tilde{\mathbf{Y}}$ 和 $\tilde{\mathbf{Y}}^T \mathbf{A} \hat{\mathbf{x}}$ 同为标量, 而且二者相等。

将式(7.3)对 $\hat{\mathbf{x}}$ 求导。根据附录 A 中对向量求导的定义, 可以得到

$$\frac{\partial J(\hat{\mathbf{x}})}{\partial \hat{\mathbf{x}}} = -2\mathbf{A}^T \tilde{\mathbf{Y}} + 2\mathbf{A}^T \mathbf{A} \hat{\mathbf{x}} \quad (7.4)$$

读者可以参看附录 A 第 A.5 节中标量函数对向量求导的定义自行推导出上式。

$J(\hat{\mathbf{x}})$ 极值点在 $\frac{\partial J(\hat{\mathbf{x}})}{\partial \hat{\mathbf{x}}} = 0$ 时得到, 即

$$-\mathbf{A}^T \tilde{\mathbf{Y}} + \mathbf{A}^T \mathbf{A} \hat{\mathbf{x}} = 0 \quad (7.5)$$

解方程(7.5)可以得到

$$\hat{\mathbf{x}} = (\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \tilde{\mathbf{Y}} \quad (7.6)$$

由于 $\frac{\partial^2 J(\hat{\mathbf{x}})}{\partial \hat{\mathbf{x}}^2} = 2\mathbf{A}^T \mathbf{A}$ 是正定矩阵, 所以此时 $J(\hat{\mathbf{x}})$ 必定取到最小值。式(7.6)就是对状态参量 $\mathbf{x}$ 的最小二乘估计, 简称 LS 估计或 LS 解。

需要注意的是, 式(7.6)给出的最小二乘解只有在矩阵 $(\mathbf{A}^T \mathbf{A})$ 可逆的情况下才可行。这就意味着, $\mathbf{A}$ 的 m 个行向量中至少有 k 个是线性无关的, 即 $\text{rank}(\mathbf{A}) = k$, 这里 $\text{rank}(\mathbf{A})$ 意为 $\mathbf{A}$ 矩阵的秩, 也就是 $\mathbf{A}$ 矩阵中的行向量或列向量的极大线性无关组的向量个数。一般应用中, 往往有 $m > k$, 所以这个条件可以满足; 如果 $m < k$, 则

式(7.1)中的观测量数目小于系统状态变量的数目, 此时式(7.1)是不定方程 (或欠定方程), 无法使用最小二乘解。

在对 $\mathbf{x}$ 的估计为 $\hat{\mathbf{x}}$ 的条件下, 可以定义状态量的估计误差 $\delta\mathbf{x}$ 为

$$\delta\mathbf{x} = \mathbf{x} - \hat{\mathbf{x}} \quad (7.7)$$

将式(7.6)带入式(7.7)就得到

$$\begin{aligned} \delta\mathbf{x} &= \mathbf{x} - (\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \tilde{\mathbf{Y}} \\ &= \mathbf{x} - (\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T (\mathbf{A}\mathbf{x} + \mathbf{n}) \\ &= \mathbf{x} - \mathbf{x} - (\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \mathbf{n} \\ &= -(\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \mathbf{n} \end{aligned} \quad (7.8)$$

从式(7.8)可以看出, 此时系统状态矢量的估计误差 $\delta\mathbf{x}$ 和系统状态量无关, 而只受观测噪声矢量 $\mathbf{n}$ 的影响。

如果噪声向量 $\mathbf{n}$ 的均值为 $\mathbf{0}$, 即 $E\{\mathbf{n}\} = \mathbf{0}$, 则

$$E\{\delta\mathbf{x}\} = -(\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T E\{\mathbf{n}\} = \mathbf{0} \quad (7.9)$$

式(7.9)说明 LS 估计值为无偏估计。

根据式(7.8)可以计算 $\delta\mathbf{x}$ 的协方差矩阵:

$$\begin{aligned} \text{var}(\delta\mathbf{x}) &= E\{(\delta\mathbf{x})(\delta\mathbf{x})^T\} \\ &= (\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T E\{\mathbf{n}\mathbf{n}^T\} \mathbf{A} (\mathbf{A}^T \mathbf{A})^{-1} \\ &= (\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \mathbf{R} \mathbf{A} (\mathbf{A}^T \mathbf{A})^{-1} \end{aligned} \quad (7.10)$$

其中, $\mathbf{R} = E\{\mathbf{n}\mathbf{n}^T\}$ 是 $\mathbf{n}$ 的协方差矩阵。很显然, $\mathbf{R}$ 是正定的。更进一步, 在 $\mathbf{n}$ 各个噪声量互不相关的情况下, $\mathbf{R}$ 是对角矩阵, 即 $\mathbf{R} = \text{diag}\{\sigma_1, \sigma_2, \dots, \sigma_m\}$ 。

以上分析是从代价函数的定义出发, 从代价函数的极值点得到最小二乘解的推导。下面将从线性空间的角度出发来讨论最小二乘解的意义。

将系统观测矩阵 $\mathbf{A}$ 写成列向量的形式, 即

$$\mathbf{A} = [\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_k]$$

将 $\mathbf{A}$ 的列向量所组成的线性空间记作 $S(\mathbf{A})$ 。

对任一状态量的估计 $\hat{\mathbf{x}}$ 来说, $\mathbf{A}\hat{\mathbf{x}}$ 可以看作 $S(\mathbf{A})$ 中的一个矢量, 因为

$$\mathbf{A}\hat{\mathbf{x}} = \sum_{i=1}^k \mathbf{a}_i x_i \quad (7.11)$$

即 $\mathbf{A}\hat{\mathbf{x}}$ 可以用 $\mathbf{A}$ 的列向量的线性组合来表示。

于是观测量 $\tilde{\mathbf{Y}}$ 和 $\mathbf{A}\hat{\mathbf{x}}$ 的线性空间距离是

$$D(\tilde{\mathbf{Y}}, \mathbf{A}\hat{\mathbf{x}}) = \|\tilde{\mathbf{Y}} - \mathbf{A}\hat{\mathbf{x}}\| \quad (7.12)$$

如果对任意两个矢量 $\mathbf{s}_1$ 和 $\mathbf{s}_2$, 定义其空间距离 $\|\mathbf{s}_1 - \mathbf{s}_2\| = (\mathbf{s}_1 - \mathbf{s}_2)^T (\mathbf{s}_1 - \mathbf{s}_2)$, 则从式(7.12)可以看出, $D(\tilde{\mathbf{Y}}, \mathbf{A}\hat{\mathbf{x}})$ 其实就是前面定义的代价函数 $J(\hat{\mathbf{x}})$ 。

从直观的角度考虑, 当 $\mathbf{A}\hat{\mathbf{x}}$ 是 $\tilde{\mathbf{Y}}$ 在 $S(\mathbf{A})$ 上的投影时, $D(\tilde{\mathbf{Y}}, \mathbf{A}\hat{\mathbf{x}})$ 取到最小值, 因为此时 $(\tilde{\mathbf{Y}} - \mathbf{A}\hat{\mathbf{x}})$ 和 $S(\mathbf{A})$ 垂直, 而 $\hat{\mathbf{x}}$ 就是对 $\mathbf{x}$ 的最小二乘估计。

用一个简单的例子来说明。考虑 $\mathbf{x}=[x_1, x_2]^T \in \mathbb{R}^2$ ， $\tilde{\mathbf{Y}}=[\tilde{y}_1, \tilde{y}_2, \tilde{y}_3]^T \in \mathbb{R}^3$ ， $\mathbf{A}=[\mathbf{a}_1 \ \mathbf{a}_2]$ ，其中 $\mathbf{a}_1, \mathbf{a}_2 \in \mathbb{R}^3$ ，则可以将状态观测量方程写成

$$\begin{bmatrix} \tilde{y}_1 \\ \tilde{y}_2 \\ \tilde{y}_3 \end{bmatrix} = \mathbf{A}\mathbf{x} = \begin{bmatrix} \mathbf{a}_1 & \mathbf{a}_2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \quad (7.13)$$

此时假设 $(\mathbf{a}_1, \mathbf{a}_2)$ 组成一个二维平面，则当 $\mathbf{A}\hat{\mathbf{x}}$ 正好是 $\tilde{\mathbf{Y}}$ 在这个二维平面上的投影时， $\hat{\mathbf{x}}$ 就是对 $\mathbf{x}$ 的最小二乘估计。对于其他任意的 $\mathbf{x}^*$ 所得到的 $\mathbf{A}\mathbf{x}^*$ 都会有

$$\|\tilde{\mathbf{Y}} - \mathbf{A}\mathbf{x}^*\| > \|\tilde{\mathbf{Y}} - \mathbf{A}\hat{\mathbf{x}}\| \quad (7.14)$$

式(7.14)所示的性质可以用图 7.1 直观地表示。




图 7.1 从线性空间的角度理解最小二乘法

7.1.2 加权的最小二乘法

在提取观测量 $\tilde{\mathbf{Y}}$ 时，不可避免地包含有噪声，于是有的观测量的可信度就要高一些，而有的观测量的可信度就要低一些。在利用最小二乘法对状态参量进行估值时，就理所当然地要尽量多地采用可信度高的观测量，而尽量少地采用可信度低的观测量。于是就对观测量引入了权重的概念。此时所得到的改进的最小二乘法被称作加权的最小二乘法（Weighted Least Square），简称 WLS 方法。

加权最小二乘法和常规最小二乘法相比，不同之处首先体现在对代价函数的改变，即

$$J(\hat{\mathbf{x}}) = (\tilde{\mathbf{Y}} - \mathbf{A}\hat{\mathbf{x}})^T \mathbf{W} (\tilde{\mathbf{Y}} - \mathbf{A}\hat{\mathbf{x}}) \quad (7.15)$$

其中，

$$\mathbf{W} = \begin{bmatrix} w_1 & 0 & \cdots & 0 \\ 0 & w_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & w_m \end{bmatrix}$$

被称作加权矩阵,它是一个 $m \times m$ 的对角矩阵,其中每一条对角线上的元素都对应于每一个观测量的权重。当 $w_i = w_j, \forall i, j \in [1, m]$ 时, WLS 方法就退化成常规 LS 方法。

依然遵循 7.1.1 节中推导 $J(\hat{\mathbf{x}})$ 极值点的方法,首先对式(7.15)展开,得到

$$J(\hat{\mathbf{x}}) = \tilde{\mathbf{Y}}^T \mathbf{W} \tilde{\mathbf{Y}} - 2\tilde{\mathbf{Y}}^T \mathbf{W} \mathbf{A} \hat{\mathbf{x}} + \hat{\mathbf{x}}^T \mathbf{A}^T \mathbf{W} \mathbf{A} \hat{\mathbf{x}} \quad (7.16)$$

将式(7.16)对 $\hat{\mathbf{x}}$ 求导,则根据附录 A 中对向量求导的定义,可以得到

$$\frac{\partial J(\hat{\mathbf{x}})}{\partial \hat{\mathbf{x}}} = -2\mathbf{A}^T \mathbf{W} \tilde{\mathbf{Y}} + 2\mathbf{A}^T \mathbf{W} \mathbf{A} \hat{\mathbf{x}} \quad (7.17)$$

$J(\hat{\mathbf{x}})$ 极值点在 $\frac{\partial J(\hat{\mathbf{x}})}{\partial \hat{\mathbf{x}}} = 0$ 时得到,所以令式(7.17)等于 0,可以得到对 $\mathbf{x}$ 的 WLS 估计为

$$\hat{\mathbf{x}}_{\text{WLS}} = (\mathbf{A}^T \mathbf{W} \mathbf{A})^{-1} \mathbf{A}^T \mathbf{W} \tilde{\mathbf{Y}} \quad (7.18)$$

由式(7.18)可以看出,只有在矩阵 $(\mathbf{A}^T \mathbf{W} \mathbf{A})$ 可逆的情况下,才能运用式(7.18)对系统状态参量进行 WLS 估计。

继续沿用式(7.7)中对系统状态估计误差的定义,可以得到

$$\begin{aligned} \delta \mathbf{x}_{\text{WLS}} &= \mathbf{x} - (\mathbf{A}^T \mathbf{W} \mathbf{A})^{-1} \mathbf{A}^T \mathbf{W} \tilde{\mathbf{Y}} \\ &= \mathbf{x} - (\mathbf{A}^T \mathbf{W} \mathbf{A})^{-1} \mathbf{A}^T \mathbf{W} (\mathbf{A} \mathbf{x} + \mathbf{n}) \\ &= (\mathbf{x} - \mathbf{x} - (\mathbf{A}^T \mathbf{W} \mathbf{A})^{-1} \mathbf{A}^T \mathbf{W} \mathbf{n}) \\ &= -(\mathbf{A}^T \mathbf{W} \mathbf{A})^{-1} \mathbf{A}^T \mathbf{W} \mathbf{n} \end{aligned} \quad (7.19)$$

由式(7.19)可以看出, WLS 的估计误差 $\delta \mathbf{x}_{\text{WLS}}$ 依然和 $\mathbf{x}$ 无关,而只与 $\mathbf{A}$ 、 $\mathbf{W}$ 和观测噪声向量 $\mathbf{n}$ 有关,并且在观测噪声均值为零的情况下, WLS 估计也是无偏估计。

WLS 估计的 $\delta \mathbf{x}_{\text{WLS}}$ 的协方差矩阵变成

$$\text{var}\{\delta \mathbf{x}_{\text{WLS}}\} = (\mathbf{A}^T \mathbf{W} \mathbf{A})^{-1} \mathbf{A}^T \mathbf{W} \mathbf{R} \mathbf{W} \mathbf{A} (\mathbf{A}^T \mathbf{W} \mathbf{A})^{-1} \quad (7.20)$$

其中, $\mathbf{R}$ 依然是噪声矢量 $\mathbf{n}$ 的协方差矩阵,在 $\mathbf{n}$ 各个噪声量互不相关的情况下,可以把 $\mathbf{R}$ 记作 $\text{diag}\{\sigma_1, \sigma_2, \dots, \sigma_m\}$ 。

因为观测噪声衡量了观测量的可信程度,所以很自然地就会想到将加权矩阵和噪声协方差矩阵联系起来。一般可以取

$$\mathbf{W} = \mathbf{R}^{-1} = \begin{bmatrix} \frac{1}{\sigma_1} & 0 & \dots & 0 \\ 0 & \frac{1}{\sigma_2} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \frac{1}{\sigma_m} \end{bmatrix} \quad (7.21)$$

对式(7.21)的直观理解就是:越大的 σ 说明该观测量越不可靠,所以应该给以较小的权重;反之, σ 越小则说明该观测量越可靠,所以应该给以较大的权重。

如果将式(7.21)分别代入式(7.18)、式(7.19)和式(7.20)，则可以得到

$$\hat{\mathbf{x}}_{\text{WLS}} = (\mathbf{A}^T \mathbf{R}^{-1} \mathbf{A})^{-1} \mathbf{A}^T \mathbf{R}^{-1} \tilde{\mathbf{Y}} \quad (7.22)$$

$$\delta \mathbf{x}_{\text{WLS}} = -(\mathbf{A}^T \mathbf{R}^{-1} \mathbf{A})^{-1} \mathbf{A}^T \mathbf{R}^{-1} \mathbf{n} \quad (7.23)$$

$$\begin{aligned} \text{var}\{\delta \mathbf{x}_{\text{WLS}}\} &= (\mathbf{A}^T \mathbf{R}^{-1} \mathbf{A})^{-1} \mathbf{A}^T \mathbf{R}^{-1} \mathbf{R} \mathbf{R}^{-1} \mathbf{A} (\mathbf{A}^T \mathbf{R}^{-1} \mathbf{A})^{-1} \\ &= (\mathbf{A} \mathbf{R}^{-1} \mathbf{A}^T)^{-1} \end{aligned} \quad (7.24)$$

此时，如果记 $\mathbf{P} = \text{var}\{\delta \mathbf{x}_{\text{WLS}}\}$ ，则式(7.22)变为

$$\hat{\mathbf{x}}_{\text{WLS}} = \mathbf{P} \mathbf{A}^T \mathbf{R}^{-1} \tilde{\mathbf{Y}} \quad (7.25)$$

由于 $\mathbf{P}^{-1} = \mathbf{A} \mathbf{R}^{-1} \mathbf{A}^T$ ，所以 $\mathbf{P}$ 和 $\mathbf{R}$ 正相关；观测量越准确，即 $\mathbf{R}$ 越小， $\mathbf{P}$ 就越小，意味着估计的准确性越高。从这个意义上来说，可以把 $\mathbf{P}^{-1}$ 叫作“信息矩阵”。

由式(7.24)可以看出，选取 $\mathbf{R}^{-1}$ 作为加权矩阵，大大简化了估计误差的协方差矩阵的计算。同时可以看出， $\delta \mathbf{x}_{\text{WLS}}$ 的协方差矩阵和状态参量 $\mathbf{x}$ 无关，而仅仅和观测噪声的协方差矩阵以及系统观测矩阵有关。

在本节的最后，以一个简单的例子对 LS 和 WLS 方法做一个小结。考虑一个单状态参量系统，用 $[x]^T$ 表示系统状态向量。假设每一次对状态参量做观测，都会得到一个观测结果 $\tilde{y}$ 。总共做了 N 次观测，得到的 N 个观测值用下列方程表示：

$$\begin{aligned} \tilde{y}_1 &= x + v_1 \\ \tilde{y}_2 &= x + v_2 \\ &\vdots \\ \tilde{y}_N &= x + v_N \end{aligned}$$

将该单状态参量系统和式(7.1)给出的状态观测方程对比，可知

$$\mathbf{Y} = \begin{bmatrix} \tilde{y}_1 \\ \tilde{y}_2 \\ \vdots \\ \tilde{y}_N \end{bmatrix}, \quad \mathbf{A} = \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix}, \quad \mathbf{n} = \begin{bmatrix} \tilde{v}_1 \\ \tilde{v}_2 \\ \vdots \\ \tilde{v}_N \end{bmatrix} \quad (7.26)$$

首先假设所有观测量所包含的噪声功率都相等，并且为白噪声，则 $\mathbf{n}$ 的协方差矩阵为

$$\mathbf{R} = \begin{bmatrix} \sigma^2 & 0 & \cdots & 0 \\ 0 & \sigma^2 & \cdots & 0 \\ \vdots & \vdots & & \vdots \\ 0 & 0 & \cdots & \sigma^2 \end{bmatrix}$$

于是根据式(7.6)，对 x 的最小二乘估计是

$$\hat{x}_{\text{LS}} = (\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \mathbf{Y} = \frac{1}{N} \sum_{i=1}^N \tilde{y}_i \quad (7.27)$$

可以看出，此时最小二乘法的结果其实就是人们在实际中经常使用的算术平均法。如果观测噪声均值为 0， $\hat{x}_{\text{LS}}$ 的均值趋近于 $[x]^T$ ，即 $\hat{x}_{\text{LS}}$ 是无偏的。

同时根据式(7.10)可知, 此时估计结果的方差为

$$\begin{aligned}\text{var}\{\delta x_{\text{LS}}\} &= (\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \mathbf{R} \mathbf{A} (\mathbf{A}^T \mathbf{A})^{-1} \\ &= \frac{1}{N} \left(\sum_{i=1}^N \sigma_i^2 \right) \frac{1}{N} \\ &= \frac{\sigma^2}{N}\end{aligned}\quad (7.28)$$

从式(7.28)可以知道: N 越大, $\text{var}\{\delta x_{\text{LS}}\}$ 越小, 意味着 $\hat{x}_{\text{LS}}$ 的准确度越高, 这也和实际情况相符。

下面考虑每次观测值包含的噪声功率不相等, 此时令 $\mathbf{n}$ 的协方差矩阵为

$$\mathbf{R} = \begin{bmatrix} \sigma_1^2 & 0 & \cdots & 0 \\ 0 & \sigma_2^2 & \cdots & 0 \\ \vdots & \vdots & & \vdots \\ 0 & 0 & \cdots & \sigma_N^2 \end{bmatrix}\quad (7.29)$$

如果选取加权矩阵 $\mathbf{W} = \mathbf{R}^{-1}$, 则根据式(7.22)得到对 x 的 WLS 估计是

$$\hat{x}_{\text{WLS}} = (\mathbf{A}^T \mathbf{R}^{-1} \mathbf{A})^{-1} \mathbf{A}^T \mathbf{R}^{-1} \mathbf{Y}$$

将 $\mathbf{A}$ 和 $\mathbf{R}$ 代入上式可得

$$\hat{x}_{\text{WLS}} = \frac{1}{\sum_{i=1}^N (1/\sigma_i^2)} \sum_{i=1}^N (1/\sigma_i^2) \tilde{y}_i\quad (7.30)$$

式(7.30)的结果实际上正是我们熟知的加权平均, 同时根据式(7.24)可知, WLS 状态估计误差的方差为

$$\begin{aligned}\text{var}\{\delta x_{\text{WLS}}\} &= (\mathbf{A}^T \mathbf{R}^{-1} \mathbf{A})^{-1} \\ &= \frac{1}{\sum_{i=1}^N (1/\sigma_i^2)}\end{aligned}\quad (7.31)$$

由式(7.31)可知: 如果增大测试次数, 也就是式中的 N 值变大, 则 $\text{var}\{\delta x_{\text{WLS}}\}$ 的值是随着 N 值单调递减的, 说明可以通过增大测量次数来提高估值的准确度。当 σ_i^2 值彼此相同时, WLS 估计就变成 LS 估计。

7.1.3 利用伪距观测量计算位置和钟偏

北斗和 GPS 双模接收机的伪距观测量在第 5.1 节详细介绍过, 式(5.9)和式(5.10)分别是 GPS 和北斗伪距观测量的数学模型, 接收机跟踪通道的每一个 GPS 或北斗卫星信号能够提供一个如式(5.9)或式(5.10)所示的伪距观测量。本节将详细讲解如何根据伪距观测量计算接收机位置和本地时钟偏差。

双模接收机具备同时接收和处理两种伪距观测量的能力, 但有些时候只有单模

观测量可以使用, 比如在某些应用环境下只有 GPS 或只有北斗卫星可用。典型的例子是, 在北斗信号区域覆盖范围之外的地理位置, 或者在基于特殊考虑 (如战略安全或政治因素) 的情况下, 只需要使能单北斗模式或单 GPS 模式, 此时将只有单模伪距观测量参与定位解算。所以, 本节将分单模模式和双模模式两种情况讲解如何完成位置和钟偏量的计算。

1. 单模观测量模式

在这种情况下参与计算的伪距观测量来自同一个 GNSS 系统, 此时可以把式(5.9)中的下标去掉, 表示单模伪距观测量的数学模型, 即

$$\tilde{\rho}_1(\mathbf{x}_u) = \sqrt{(x_u - x_{s_1})^2 + (y_u - y_{s_1})^2 + (z_u - z_{s_1})^2} + cb + n_{\rho_1} \quad (7.32)$$

$$\tilde{\rho}_2(\mathbf{x}_u) = \sqrt{(x_u - x_{s_2})^2 + (y_u - y_{s_2})^2 + (z_u - z_{s_2})^2} + cb + n_{\rho_2} \quad (7.33)$$

⋮

$$\tilde{\rho}_m(\mathbf{x}_u) = \sqrt{(x_u - x_{s_m})^2 + (y_u - y_{s_m})^2 + (z_u - z_{s_m})^2} + cb + n_{\rho_m} \quad (7.34)$$

式(7.32)~(7.34)表示 m 个伪距观测量, $[x_u, y_u, z_u]$ 为用户的位置; b 是用户本地时钟和 GPST/BDT 之间的偏差, 具体情况依据式中的伪距观测量所属的 GNSS 系统而定; $n_\rho = c\tau_s + E_{\text{eph}} + T_{\text{iono}} + T_{\text{trop}} + \text{MP} + n_r$ 表示伪距观测量中总的误差项。已知量为伪距观测量 $\tilde{\rho}_i$ 和卫星坐标 $[x_{s_i}, y_{s_i}, z_{s_i}]$, 观测量上面的波浪号 “ $\sim$ ” 表示实际观测量, 是为了和后面的预测量区分开。这里卫星和用户的坐标都在 ECEF 坐标系中表示, 其中伪距观测量的获取在 5.1 节有详细说明。卫星的坐标根据信号的发射时刻用星历数据算出, 具体步骤在第 6 章的内容里已经详细介绍。

将上述伪距观测量方程和最小二乘法中的状态观测方程相比, 可见伪距方程是非线性方程, 不能直接利用 7.1.1 节所讲述的 LS 方法解算。所以, 首先要先将伪距方程线性化才能利用 LS 方法。在实际中, 最常用的线性化方法就是利用一阶泰勒级数展开。

假设用户的坐标和本地钟差有一个起始值 $\mathbf{x}_0 = [x_0, y_0, z_0, b_0]$, 那么基于这个起始值将伪距方程进行一阶泰勒级数展开, 就会得到

$$\begin{aligned} \tilde{\rho}_i(\mathbf{x}_u) = & \rho_i(\mathbf{x}_0) + \frac{\partial \rho_i}{\partial x_u} \Big|_{x_0} (x_u - x_0) + \frac{\partial \rho_i}{\partial y_u} \Big|_{y_0} (y_u - y_0) + \\ & \frac{\partial \rho_i}{\partial z_u} \Big|_{z_0} (z_u - z_0) + \frac{\partial \rho_i}{\partial b} \Big|_{b_0} (b - b_0) + \text{h.o.t.} + n_{\rho_i} \end{aligned} \quad (7.35)$$

式中, $i=1, 2, \dots, m$; h.o.t. 是高阶泰勒级数项。

$$\begin{aligned} \rho_i(\mathbf{x}_0) = & \sqrt{(x_0 - x_{s_i})^2 + (y_0 - y_{s_i})^2 + (z_0 - z_{s_i})^2} + cb_0 \\ \frac{\partial \rho_i}{\partial x_u} \Big|_{x_0} = & - \frac{x_0 - x_{s_i}}{\sqrt{(x_0 - x_{s_i})^2 + (y_0 - y_{s_i})^2 + (z_0 - z_{s_i})^2}} \end{aligned}$$

$$\begin{aligned}\frac{\partial \rho_i}{\partial y_u} \Big|_{y_0} &= -\frac{y_0 - y_{s_i}}{\sqrt{(x_0 - x_{s_i})^2 + (y_0 - y_{s_i})^2 + (z_0 - z_{s_i})^2}} \\ \frac{\partial \rho_i}{\partial z_u} \Big|_{z_0} &= -\frac{z_0 - z_{s_i}}{\sqrt{(x_0 - x_{s_i})^2 + (y_0 - y_{s_i})^2 + (z_0 - z_{s_i})^2}} \\ \frac{\partial \rho_i}{\partial b} \Big|_{b_0} &= 1\end{aligned}$$

$\rho_i(\mathbf{x}_0)$ 用当前的位置、钟差和卫星位置算出, 往往被称作预测伪距量, 注意与真实的伪距观测量区分开。此处下标 “ i ” 表示不同的卫星。

定义如下矢量:

$$\mathbf{u}_i \triangleq \left[\frac{\partial \rho_i}{\partial x_u} \Big|_{x_0}, \frac{\partial \rho_i}{\partial y_u} \Big|_{y_0}, \frac{\partial \rho_i}{\partial z_u} \Big|_{z_0}, 1 \right], \quad \mathbf{dx}_0 \triangleq [(x_u - x_0), (y_u - y_0), (z_u - z_0), (b - b_0)]^T$$

其中 $\mathbf{u}_i$ 的前三个元素构成的矢量一般称作方向余弦矢量 (Direction Cosine Vector), 这里记作 $\mathbf{DC}_i = \left[\frac{\partial \rho_i}{\partial x_u} \Big|_{x_0}, \frac{\partial \rho_i}{\partial y_u} \Big|_{y_0}, \frac{\partial \rho_i}{\partial z_u} \Big|_{z_0} \right]$, 该矢量是从用户位置到卫星的单位方向矢量在 ECEF 坐标系中的表示。每一个卫星都有自己的方向余弦矢量, 后面会看到该矢量还可以在其他坐标系中表示, 但其物理意义是一样的。

将式(7.35)稍做整理并略去高阶项, 得到

$$\rho_i(\mathbf{x}_u) - \rho_i(\mathbf{x}_0) = \mathbf{u}_i \cdot \mathbf{dx}_0 + n_{\rho_i} \quad (7.36)$$

式(7.36)中等号左边就是用观测到的伪距量减去利用初始点预测的伪距量, 一般把这个差叫作伪距残差, 用 $\delta \rho_i$ 来表示。伪距残差的数学表达式如等号右边所示, 可以看出伪距残差已经可以表示为线性方程的形式了。但需要注意的是, 这里的线性化只是在一阶泰勒级数意义上的近似。严格来说, 式(7.36)中不能用等号, 而只能用近似号。后面会看到, 随着迭代次数增加, 线性化的结果会越来越精确。

式(7.36)是对一个卫星的伪距观测量所做的线性化, 对于 m 个观测量同时进行线性化, 就得到如下的线性方程组:

$$\begin{aligned}\delta \rho_1 &= \mathbf{u}_1 \cdot \mathbf{dx}_0 + n_{\rho_1} \\ \delta \rho_2 &= \mathbf{u}_2 \cdot \mathbf{dx}_0 + n_{\rho_2} \\ &\vdots \\ \delta \rho_m &= \mathbf{u}_m \cdot \mathbf{dx}_0 + n_{\rho_m}\end{aligned}$$

将上述方程组写成矩阵的形式, 得到

$$\delta \boldsymbol{\rho} = \mathbf{H} \mathbf{dx}_0 + \mathbf{n}_\rho \quad (7.37)$$

其中, $\delta \boldsymbol{\rho} = [\delta \rho_1, \delta \rho_2, \dots, \delta \rho_m]^T$, $\mathbf{H} = [\mathbf{u}_1^T, \mathbf{u}_2^T, \dots, \mathbf{u}_m^T]^T$, $\mathbf{n}_\rho = [n_{\rho_1}, n_{\rho_2}, \dots, n_{\rho_m}]^T$, 其各自的维数分别为 $m \times 1$ 、 $m \times 4$ 和 $m \times 1$ 。

根据 7.1.1 节的分析结果可知, 式(7.37)的最小二乘估计为

$$\mathrm{d}\mathbf{x}_0 = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \delta \boldsymbol{\rho} \quad (7.38)$$

如果将矩阵 $(\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T$ 写成如下形式:

$$(\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T = \begin{bmatrix} h_{11} & h_{12} & \cdots & h_{1m} \\ h_{21} & h_{22} & \cdots & h_{2m} \\ h_{31} & h_{32} & \cdots & h_{3m} \\ h_{41} & h_{42} & \cdots & h_{4m} \end{bmatrix}$$

则可以证明

$$\sum_{i=1}^m h_{1i} = 0, \quad \sum_{i=1}^m h_{2i} = 0, \quad \sum_{i=1}^m h_{3i} = 0, \quad \sum_{i=1}^m h_{4i} = 1 \quad (7.39)$$

即矩阵 $(\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T$ 的前 3 个行向量的元素之和为 0, 第 4 个行向量的元素之和为 1。因为 $(\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T$ 的前 3 个行向量是计算用户位置的 x, y, z , 所以由式(7.39)可以知道伪距观测量中的公共误差项不会对位置解算产生影响。而 $(\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T$ 的第 4 个行向量是计算用户钟差, 所以伪距观测量中的公共误差项会影响钟差的解算。这个结论是从理论推导得出来的, 而且和我们的直观观察相吻合。比如, 将所有伪距观测量都加上一个同样的数值 Δt , 得到的位置解算不会改变, 而得到的钟差 b 会偏离 Δt 。

式(7.38)得到的是通过一次线性化后初始点和真实点之间的修正量, 将这个修正量用来更新初始点, 得到修正后的解, 即

$$\mathbf{x}_1 = \mathbf{x}_0 + \mathrm{d}\mathbf{x}_0 \quad (7.40)$$

然后再用 $\mathbf{x}_1$ 作为起始点来重复从式(7.36)到式(7.40)的过程, 得到新的修正量 $\mathrm{d}\mathbf{x}_1$ 来更新上一次的解。

上述过程用通用的方式来描述, 对第 k 次更新来说, 其过程为

$$\mathrm{d}\mathbf{x}_{k-1} = (\mathbf{H}_{k-1}^T \mathbf{H}_{k-1})^{-1} \mathbf{H}_{k-1}^T \delta \boldsymbol{\rho}_{k-1} \quad (7.41)$$

$$\mathbf{x}_k = \mathbf{x}_{k-1} + \mathrm{d}\mathbf{x}_{k-1} \quad (7.42)$$

式(7.41)和式(7.42)中 $\mathbf{H}$ 和 $\delta \boldsymbol{\rho}$ 都被加上了下标, 是因为每一次更新 $\mathbf{x}_k$ 以后都要重新计算每颗卫星的方向余弦矢量及其对应的伪距残差。

更新终结的条件是通过判断 $\|\mathrm{d}\mathbf{x}_k\|$, 即

$$\|\mathrm{d}\mathbf{x}_k\| < \text{预定门限} \quad (7.43)$$

其中预定门限是预先设定的一个阈值。当 $\|\mathrm{d}\mathbf{x}_k\|$ 小于该阈值时, 就认为可以停止更新了。一般来说, 如果设置起始点为地心, 那么只需要约 5 次迭代就能收敛到满意的精度。随着迭代次数的增多, $\|\mathrm{d}\mathbf{x}_k\|$ 的值越来越小, 式(7.36)的线性化的精度就越来越高。

在迭代终结的时刻, $\|\mathrm{d}\mathbf{x}_k\|$ 的值可以非常小, 比如小于 1 cm。这里需要注意的是, 这并不意味着得到的用户的位置和钟差的误差已经小于 1 cm 了。 $\|\mathrm{d}\mathbf{x}_k\|$ 的收敛只是意味着我们已经找到了使最小二乘法的代价函数最小的解, 并不是说代价函数已经趋近于 0, 所以用户的位置和钟差的误差还可能比较大。因此, 试图通过增

大迭代次数的方法来提高解的精度是行不通的。关于位置和钟差的误差在后续有关几何精度因子的内容介绍中还要进一步说明。

在进行迭代运算时,还必须考虑地球自转的影响。我们知道, GPS 卫星和北斗 MEO 卫星信号从太空传播到地球表面需要 60~80 ms, 北斗 IGSO 和 GEO 卫星信号从太空传播到地球表面需要 110~130 ms, 在这段时间内地球转过了一定的角度。这个角度很小, 但考虑到地球的半径非常大, 所以带来的定位误差不容忽视。

地球自转的角速度为 ω_{ie} , 每一次迭代时得到的预测伪距量除以光速就得到信号传输的时间 Δt_{tr} , 于是在信号传输过程中地球转过的角度为

$$\alpha_k = \omega_{\text{ie}} \Delta t_{\text{tr}} \quad (7.44)$$

这里 α_k 的下标表示第 k 次迭代, 也就是说, 每一次迭代都需要重新计算 α_k 。

由于地球绕着 ECEF 坐标系的 z 轴旋转, 所以由 α_k 可以计算旋转矩阵如下:

$$R_{\alpha_k} = \begin{bmatrix} \cos(\alpha_k) & -\sin(\alpha_k) & 0 \\ \sin(\alpha_k) & \cos(\alpha_k) & 0 \\ 0 & 0 & 1 \end{bmatrix} \quad (7.45)$$

将该旋转矩阵和通过星历数据计算得到的卫星坐标相乘, 就得到了考虑了自转效应以后的卫星坐标, 即

$$\begin{bmatrix} x'_{\text{sv}} \\ y'_{\text{sv}} \\ z'_{\text{sv}} \end{bmatrix} = \begin{bmatrix} \cos(\alpha_k) & -\sin(\alpha_k) & 0 \\ \sin(\alpha_k) & \cos(\alpha_k) & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x_{\text{sv}} \\ y_{\text{sv}} \\ z_{\text{sv}} \end{bmatrix} \quad (7.46)$$

然后利用 $[x'_{\text{sv}}, y'_{\text{sv}}, z'_{\text{sv}}]^T$ 来计算卫星的方向余弦向量和预测的伪距量。

2. 双模观测量模式

在双模观测量参与计算时, GPS 和北斗伪距观测量混在一起。根据 5.1 节的分析, 如果把 GPS 时 (GPST) 选择作为接收机的时间基准, 则北斗卫星的伪距观测量与式(7.32)~式(7.34)相比, 会多出一项北斗时 (BDT) 和 GPST 之间的系统时间偏差 T_{GB} 。双模模式的分析主要围绕着如何处理 T_{GB} 展开。

一种方法是通过系统设置来读取 T_{GB} , 从而解决北斗伪距观测量相对于 GPST 的系统偏差。具体来说, 北斗导航电文中给出了 BDT 和 GPST 之间的时间同步参数, 分别在 D1 码电文中第 5 子帧第 9 页面和 D2 码电文中第 5 子帧第 101 页面。BDT 和 GPST 之间时间同步参数有两个:

- $A_{0\text{GPS}}$: BDT 相对于 GPST 的钟差;
- $A_{1\text{GPS}}$: BDT 相对于 GPST 的钟差速度。

BDT 和 GPST 之间的系统偏差计算公式如下:

$$T_{\text{GB}} = A_{0\text{GPS}} + A_{1\text{GPS}} \times t_{\text{E}} \quad (7.47)$$

式(7.47)中 t_{E} 为接收机提取伪距观测量时刻的 BDT。

在计算出 T_{GB} 之后, 可以将 T_{GB} 对应的项 cT_{GB} 从北斗伪距观测量表达式(5.10)

中扣除, 此时待解系统状态量为 $\mathbf{x}=[x,y,z,b]$, 则北斗和 GPS 伪距观测量转换为单模观测量的情况, 按照上述单模观测量模式中的求解步骤计算。

这种方法的优点在于与单模模式相比没有增加状态变量数目, 所以只需要至少 4 颗北斗或 GPS 卫星的数据即可完成接收机位置和本地钟差的计算, 在观测量数目较少的情况下比较适用。但这种方法主要的不足之处在于需要获取时间同步参数, 这就意味着必须完成北斗导航电文的数据解调。从接收机开机、完成北斗卫星信号捕获和跟踪、开始解调电文到读取时间同步参数, 一般需要一定的时间开销, 具体时间开销大小需要根据信号捕获速度、信号强度、开机时刻相对时间参数的距离等因素决定, 时间开销会增大 TTFF 时间。同时, 在信号质量较差的情况下甚至无法顺利完成数据解调任务, 此时这种方法就不能使用了。

另一种方法是在用户设备端解决问题, 其主要思想是将 T_{GB} 看作待估的系统状态量, 此时待解系统状态量为 $\mathbf{x}=[x,y,z,b,T_{GB}]$, 由单模模式的 4 个未知量变为 5 个未知量。由此双模伪距观测量可以写为

$$\tilde{\rho}_{G1}(\mathbf{x}_u) = \sqrt{(x_u - x_{Gs_1})^2 + (y_u - y_{Gs_1})^2 + (z_u - z_{Gs_1})^2} + cb + n_{\rho_{G1}} \quad (7.48)$$

$$\tilde{\rho}_{G2}(\mathbf{x}_u) = \sqrt{(x_u - x_{Gs_2})^2 + (y_u - y_{Gs_2})^2 + (z_u - z_{Gs_2})^2} + cb + n_{\rho_{G2}} \quad (7.49)$$

$$\vdots$$

$$\tilde{\rho}_{Gm}(\mathbf{x}_u) = \sqrt{(x_u - x_{Gs_m})^2 + (y_u - y_{Gs_m})^2 + (z_u - z_{Gs_m})^2} + cb + n_{\rho_{Gm}} \quad (7.50)$$

$$\tilde{\rho}_{B1}(\mathbf{x}_u) = \sqrt{(x_u - x_{Bs_1})^2 + (y_u - y_{Bs_1})^2 + (z_u - z_{Bs_1})^2} + cb + cT_{GB} + n_{\rho_{B1}} \quad (7.51)$$

$$\tilde{\rho}_{B2}(\mathbf{x}_u) = \sqrt{(x_u - x_{Bs_2})^2 + (y_u - y_{Bs_2})^2 + (z_u - z_{Bs_2})^2} + cb + cT_{GB} + n_{\rho_{B2}} \quad (7.52)$$

$$\vdots$$

$$\tilde{\rho}_{Bn}(\mathbf{x}_u) = \sqrt{(x_u - x_{Bs_n})^2 + (y_u - y_{Bs_n})^2 + (z_u - z_{Bs_n})^2} + cb + cT_{GB} + n_{\rho_{Bn}} \quad (7.53)$$

式(7.48)~式(7.53)表示了 m 个 GPS 伪距观测量和 n 个北斗伪距观测量的情况, 其中式(7.48)~式(7.50)是 GPS 伪距观测量, 式(7.51)~式(7.53)是北斗伪距观测量, $\tilde{\rho}_{Gi}$ 和 $\tilde{\rho}_{Bi}$ 中的下标 G 和 B 分别表示 GPS 和北斗。

对双模伪距观测量进行线性化的原理与单模模式情况下相似, 不同之处在于针对 GPS 和北斗卫星信号进行区别:

$$\mathbf{u}_{Gi} \triangleq \left[\frac{\partial \rho_i}{\partial x_u} \Big|_{x_0}, \frac{\partial \rho_i}{\partial y_u} \Big|_{y_0}, \frac{\partial \rho_i}{\partial z_u} \Big|_{z_0}, 1, 0 \right]$$

$$\mathbf{u}_{Bi} \triangleq \left[\frac{\partial \rho_i}{\partial x_u} \Big|_{x_0}, \frac{\partial \rho_i}{\partial y_u} \Big|_{y_0}, \frac{\partial \rho_i}{\partial z_u} \Big|_{z_0}, 1, 1 \right]$$

$$\mathbf{dx}_0 \triangleq [(x_u - x_0), (y_u - y_0), (z_u - z_0), (b - b_0), (T_{GB} - T_{GB0})]^T$$

式中, 下标“B”、“G”用以区分北斗和 GPS 伪距观测量。线性化后的伪距残差可以表示为

$$\delta\rho_{G1} = \boldsymbol{u}_{G1} \bullet \boldsymbol{dx}_0 + n_{\rho_{G1}} \tag{7.54}$$

$$\delta\rho_{G2} = \boldsymbol{u}_{G2} \bullet \boldsymbol{dx}_0 + n_{\rho_{G2}} \tag{7.55}$$

⋮

$$\delta\rho_{Gm} = \boldsymbol{u}_{Gm} \bullet \boldsymbol{dx}_0 + n_{\rho_{Gm}} \tag{7.56}$$

$$\delta\rho_{B1} = \boldsymbol{u}_{B1} \bullet \boldsymbol{dx}_0 + n_{\rho_{B1}} \tag{7.57}$$

$$\delta\rho_{B2} = \boldsymbol{u}_{B2} \bullet \boldsymbol{dx}_0 + n_{\rho_{B2}} \tag{7.58}$$

⋮

$$\delta\rho_{Bn} = \boldsymbol{u}_{Bn} \bullet \boldsymbol{dx}_0 + n_{\rho_{Bn}} \tag{7.59}$$

式(7.54)~(7.59)对应于式(7.48)~式(7.53)，可见 $\boldsymbol{u}_i$ 向量元素个数变为 5，同时需要根据北斗和 GPS 卫星的不同而调整，相应的系统状态修正量 $\boldsymbol{dx}_i$ 的维度也是 5。

通过最小二乘法计算状态修正量 $\boldsymbol{dx}_i$ 与多次迭代的方法和单模模式一样，用通用的方式来描述，对第 k 次更新来说，其过程为

$$\begin{aligned} \boldsymbol{dx}_{k-1} &= (\boldsymbol{H}_{k-1}^T \boldsymbol{H}_{k-1})^{-1} \boldsymbol{H}_{k-1}^T \delta \boldsymbol{\rho}_{k-1} \\ \boldsymbol{x}_k &= \boldsymbol{x}_{k-1} + \boldsymbol{dx}_{k-1} \end{aligned}$$

可以看出上面步骤的表达式和单模模式下完全一样，需要注意的是其中的 $\boldsymbol{H}_{k-1}$ 由 $\boldsymbol{u}_{Gi}$ 和 $\boldsymbol{u}_{Bi}$ 组合而成，即 $\boldsymbol{H} = [\boldsymbol{u}_{G1}^T, \boldsymbol{u}_{G2}^T, \cdots, \boldsymbol{u}_{Gm}^T, \boldsymbol{u}_{B1}^T, \boldsymbol{u}_{B2}^T, \cdots, \boldsymbol{u}_{Bn}^T]^T$ 。

双模模式下的迭代过程收敛的判断和单模模式一样，在计算卫星位置时也需要考虑地球自转的影响，具体过程可以参考式(7.44)~式(7.46)。

在用户设备端通过增加系统状态量的方法解决系统时间偏差问题，其优点在于不依赖系统设置中是否提供时间同步参数，只要有足够多的双模伪距观测量就能计算位置和时间偏差。所以，在卫星信号接收良好的情况下，TTFF 会比采用系统设置的方法要短，但不足之处在于所需的最少卫星数目比单模模式下多 1 个，在信号被遮挡的情况下该方法的使用会受限。

在实际的 GPS / 北斗双模接收机中可以同时实现两种方法：当北斗卫星信号质量较好时可以解调其中的时间同步信息，此时可以采用系统设置方法；否则，可以等到有超过 5 颗卫星的双模观测量时再采用增加系统状态量的方法。具体的处理策略如表 7.1 所示。

表 7.1 由卫星种类和卫星数目决定定位解算方法

卫 星 种 类	卫 星 数 目	解 算 方 法
GPS	≥4	单模模式方法
北斗	≥4	单模模式方法
GPS+北斗	≥5	双模模式的设备端方法 或系统级方法
GPS+北斗	=4	双模模式的系统级方法

表 7.1 中只给出了伪距观测量数目足够多的情况, 当伪距观测量少于 4 颗卫星时无法使用本节介绍的方法, 此时可以采用高程辅助或其他冗余信息辅助的方法实现定位。

上述过程中计算的接收机位置坐标 $P_u = [x, y, z]$ 是在 ECEF 坐标系中, 实际输出的结果一般需要转换为经纬度坐标 (ϕ, λ, h) , 其中 ϕ 为纬度, λ 为经度, h 为高度, 具体转换方法可以参考第 1 章的 1.2.3 节。

7.1.4 利用多普勒观测量计算速度和钟漂

5.3 节讲述了多普勒观测量的获取和其数学模型表达式, 本节要利用最小二乘法来求解接收机的速度和钟漂量。

多普勒频率和积分多普勒观测量的差别在 5.3 节中已经详细讲解。多普勒频率体现的是某时刻卫星和接收机瞬时相对速度矢量在方向余弦上的投影, 积分多普勒体现了一段时间内卫星和接收机之间的距离的变化值。由于在低成本导航接收机内往往不输出积分多普勒观测量, 所以本节将利用多普勒频率计算接收机速度和钟漂, 后面如果不加说明, 则表示将多普勒频率当作多普勒观测量。对于具有积分多普勒观测量输出的接收机而言, 可以把相邻时元的积分多普勒观测量进行差分, 差分结果可以用于本节所述的计算过程。

由于 GPST 和 BDT 由各自系统中的原子钟维持, 原子钟的频率稳定性可以达到 $10^{-12} \sim 10^{-13}$, 转换为速度为 $3 \times 10^{-4} \sim 3 \times 10^{-5} \text{ m/s}$, GPST 和 BDT 之间的时间差与载波跟踪环路的频率误差方差相比可以认为保持恒定, 即 $\dot{T}_{\text{GB}} = 0$; 因此, 虽然双模接收机中同时存在 GPS 和北斗卫星的多普勒观测量, 但两者可以用相同的数学表达式表示, 即 5.3 节中的式(5.20)。当接收机能获取 m 颗 GPS 卫星和北斗卫星的多普勒观测量时, 可列出如下的方程组:

$$f_{d_1} = (\mathbf{v}_{s_1} - \mathbf{v}_u) \cdot \mathbf{DC}_1 + c\dot{b} + n_{d_1} \quad (7.60)$$

$$f_{d_2} = (\mathbf{v}_{s_2} - \mathbf{v}_u) \cdot \mathbf{DC}_2 + c\dot{b} + n_{d_2} \quad (7.61)$$

$$\vdots$$

$$f_{d_m} = (\mathbf{v}_{s_m} - \mathbf{v}_u) \cdot \mathbf{DC}_m + c\dot{b} + n_{d_m} \quad (7.62)$$

其中, f_{d_i} 是第 i 颗卫星的多普勒观测量, 单位是 m/s ; $\mathbf{DC}_i$ 是第 i 颗卫星的方向余弦矢量, 该矢量由上一节中的位置求解的过程提供, 一般是当位置求解的迭代过程收敛时得到; $\mathbf{v}_{s_i}$ 是第 i 颗卫星的速度, 根据 6.2 节和 6.3 节中的相关内容计算。

式(7.60)~(7.62)中已不再区分 GPS 和北斗卫星, 原因前面已经阐明。需要注意的是: f_{d_i} 的单位是 m/s , 但基带跟踪环输出的多普勒频率值是以赫兹或弧度为单位。如果以赫兹为单位, 则需要乘以载波波长; 如果以弧度为单位, 则还需要再乘以 2π ,

载波波长数值用 $\lambda = c / f_{\text{carrier}}$ 计算, 根据卫星信号类型分别代入 GPS 载波频率或北斗载波频率。

式(7.60)~(7.62)中共有四个待解的未知量, 分别为用户的钟漂量 $c\dot{b}$ 和速度矢量 $\mathbf{v}_u = [v_x, v_y, v_z]^T$ 。以下为描述方便, 统一用一个矢量 $\mathbf{x}_v = [v_x, v_y, v_z, c\dot{b}]^T$ 表示。将式(7.60)~式(7.62)中的卫星速度项稍做整理, 移到等号左边得到:

$$f_{d_1} - \mathbf{DC}_1 \cdot \mathbf{v}_{s_1} = -\mathbf{DC}_1 \cdot \mathbf{v}_u + c\dot{b} + n_{d_1} \quad (7.63)$$

$$f_{d_2} - \mathbf{DC}_2 \cdot \mathbf{v}_{s_2} = -\mathbf{DC}_2 \cdot \mathbf{v}_u + c\dot{b} + n_{d_2} \quad (7.64)$$

$$\vdots$$

$$f_{d_m} - \mathbf{DC}_m \cdot \mathbf{v}_{s_m} = -\mathbf{DC}_m \cdot \mathbf{v}_u + c\dot{b} + n_{d_m} \quad (7.65)$$

式(7.63)~(7.65)很容易理解: GPS 和北斗卫星作为高速运动的飞行器, 其高速的运动贡献了多普勒频移中的大部分, 所以必须将这部分去掉, 剩下的部分就完全由用户的运动和本地钟漂决定, 当然噪声项依然保留其中。一般把 $(f_{d_i} - \mathbf{DC}_i \cdot \mathbf{v}_{s_i})$ 称作线性化的多普勒观测量。

当用户静止不动时, 因为 $\mathbf{v}_u = [0, 0, 0]^T$, 则

$$(-\mathbf{DC}_i \cdot \mathbf{v}_u) = 0, \quad i = 1, \dots, m \quad (7.66)$$

此时, 式(7.63)~(7.65)右边完全由本地钟漂和噪声项决定。本地钟漂对所有卫星的观测量来说是一个公共项, 而噪声项相对来说比较小。此时如果在同一时刻对多颗卫星的线性化的多普勒观测量进行观察, 会发现它们的值会非常接近。这一特性在实际系统调试时非常有用。

如果定义

$$\mathbf{f}'_d \triangleq \begin{bmatrix} f_{d_1} - \mathbf{DC}_1 \cdot \mathbf{v}_{s_1} \\ f_{d_2} - \mathbf{DC}_2 \cdot \mathbf{v}_{s_2} \\ \vdots \\ f_{d_m} - \mathbf{DC}_m \cdot \mathbf{v}_{s_m} \end{bmatrix}, \mathbf{H} \triangleq \begin{bmatrix} -\mathbf{DC}_1^T & 1 \\ -\mathbf{DC}_2^T & 1 \\ \vdots & \vdots \\ -\mathbf{DC}_m^T & 1 \end{bmatrix}, \mathbf{n}_d \triangleq \begin{bmatrix} n_{d_1} \\ n_{d_2} \\ \vdots \\ n_{d_m} \end{bmatrix} \quad (7.67)$$

则式(7.63)~(7.65)可以写成矩阵的形式, 即

$$\mathbf{f}'_d = \mathbf{H}\mathbf{x}_v + \mathbf{n}_d \quad (7.68)$$

将式(7.68)和式(7.1)相比, 会发现式(7.68)已经是标准的线性状态观测方程了, 所以对其求解和对位置的解算不同, 速度解算无须迭代, 可以直接用最小二乘法求解:

$$\mathbf{x}_v = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{f}'_d \quad (7.69)$$

式(7.39)中体现的 $(\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T$ 的性质在此处依然成立, 所以所有多普勒观测量中的公共误差项都不会影响用户速度的解算, 而只会影响钟漂的解算。

由此可以看出,在接收机内部利用最小二乘法进行 PVT 求解时,一般的顺序是先运用牛顿迭代法求得用户的位置和钟差,然后再利用在该过程中得到的卫星方向余弦矢量形成 H 矩阵,同时从多普勒观测量扣除卫星运动速度得到线性化的多普勒观测量,最后利用式(7.69)求得用户的速度和钟漂。

至此,通过本节和上一节的讲解,已经用最小二乘法完成了用户的 PVT 解算。最小二乘法作为最常规的解算方法在现实接收机中有着广泛的应用,在理论上也是理解其他解算方法的基础。每一次最小二乘法的解算都基于某一个时元的观测量,和以前时元的观测量没有关系。如果将不同时元的观测量的噪声看作白噪声,则最小二乘解算得到 PVT 结果中包含的误差也可以认为是没有关联的。这一点在实际工程上的体现,就是最小二乘解算得到的位置误差和速度误差会有类似白噪声一样的跳跃现象。当然,伪距观测量和多普勒频率观测量中包含的噪声并不都是白噪声,如电离层延迟和对流层延迟在时间上呈现低频缓变信号的特性,此时计算的位置误差也呈现一定的时间相关性。人们发展出多种对最小二乘法结果进行滤波或使定位结果更平滑的方法,后面要讲述的卡尔曼滤波就是其中的一种。

7.1.5 卫星的仰角和方位角

实现了用户的位置解算以后,一个重要的任务就是计算卫星的仰角和方位角(又称辐角)。卫星的仰角和方位角与用户当前的位置和卫星位置有关,理解这一点必须先明白仰角和方位角的定义。

如图 7.2 所示,其中用户位置为 P_u , 卫星位置为 P_{sv} 。从用户所在位置到卫星位置所形成的矢量 P_{u-sv} , 在用户站心坐标系中 N 坐标轴和 E 坐标轴形成的平面上有一个投影点 $P_\perp$ 。这里 N 坐标轴和 E 坐标轴所形成的平面其实就是从用户所在位置沿地球椭圆面所做的切平面, N 坐标轴指向正北方向, E 坐标轴指向正东方向。矢量 $P_\perp P_u$ 和 N 坐标轴的夹角即为方位角,一般取逆时针为正方向;而矢量 P_{u-sv} 和切平面之间的夹角即为仰角。在图 7.2 中仰角用 α 表示,方位角用 β 表示。

卫星的仰角信息是接收机内部逻辑预测可见星集合的基础,接收机在运行时需要预测目前天顶上方的可见卫星,并计算每一个可见卫星的仰角,这样才能及时地替换已经处于地平线方向的下行卫星,同时对位于地平线方向的上行卫星做好信号捕获跟踪的准备。由此可见,卫星的仰角信息是接收机内部换星控制逻辑的重要依据。预测的可见星集合的一个重要用途是在接收机启动时,当接收机通过 EEPROM 或 Flash 等非易失性存储器保存有效的星历或历书数据时,就能计算卫星大致的方位,根据本地大致方位得到卫星的仰角和俯角。因为只有当卫星的仰角大于 0 时,这颗卫星的信号才可能被接收到,所以就能预先估计当前天空中可能被跟踪的卫星集合,从而减小搜索空间,加快卫星的开机定位时间。




图 7.2 卫星的仰角和方位角示意图

卫星的仰角越低，相应地接收到的信号质量就越差，因为卫星信号需要经过更长的传输距离才能到达地面，而这增加的距离大部分在大气层，从 5.4.3 节和 5.4.4 节可知低仰角的卫星信号受到电离层和对流层的影响更强烈，电离层和对流层延迟也会更大。同时仰角较低的卫星信号比高仰角的卫星信号也更容易地产生多径效应，为了保证定位解算结果的正确性，现代的 GPS 接收机中一般都会对参与定位的卫星有最小的仰角要求（Elevation Mask）。当卫星的仰角低于预先设定的仰角门限时，就要将这颗卫星的观测量从定位解算的计算中剔除。实际中一般将仰角门限定为 $5 \sim 10$ 度，该指标可以根据实际要求调整。

卫星仰角值在 PVT 解算中也被用来对伪距和载波相位观测量的质量进行量化，仰角越高的卫星提供的观测量越好，反之则越差，这种观测量质量好坏的信息在加权最小二乘法中往往用来设置观测量的权重矩阵，或在卡尔曼滤波算法中设置观测量的 R 矩阵，合适的 R 矩阵将会提高定位结果的准确性和平滑性。

从图 7.2 可以看出， P_{u-sv} 的单位矢量就是从用户到卫星的方向余弦矢量，即 7.1.3 节和 7.1.4 节中定义的 DC_i ， i 表示不同的卫星，那里 DC_i 被表示在 ECEF 坐标系中。由上述仰角和方位角的物理意义来看，在讨论仰角和方位角的时候，就必须将 DC_i 转换到 ENU 坐标系中。

根据仰角和方位角的定义可知，方向余弦在 ENU 坐标系中的表示为

$$DC_{ENU} = [-\sin \beta \cos \alpha, \cos \beta \cos \alpha, \sin \alpha] \quad (7.70)$$

同时，如果算出了 DC 在 ECEF 坐标系中的表示以后，将其转换到 ENU 坐标系中，即

$$DC_{\text{ENU}} = R_{e2t} DC \quad (7.71)$$

这里 R_{e2t} 是从 ECEF 到 ENU 的旋转矩阵, 由第 1.2.4 节可知

$$R_{e2t} = \begin{bmatrix} -\sin(\lambda) & \cos(\lambda) & 0 \\ -\cos(\lambda)\sin(\phi) & -\sin(\lambda)\sin(\phi) & \cos(\phi) \\ \cos(\lambda)\cos(\phi) & \sin(\lambda)\cos(\phi) & \sin(\phi) \end{bmatrix}$$

其中, ϕ 为接收机所在位置的纬度, λ 为接收机所在位置的经度。

假设式(7.71)得到的结果可以表示为 $[\kappa_e, \kappa_n, \kappa_u]$, 对比式(7.70)可知:

$$\alpha = \tan^{-1}\left(\frac{\kappa_u}{\sqrt{\kappa_e^2 + \kappa_n^2}}\right) \quad (7.72)$$

$$\beta = \tan^{-1}\left(-\frac{\kappa_e}{\kappa_n}\right) \quad (7.73)$$

式(7.72)和(7.73)分别为仰角和方位角的计算公式, 它们对于 GPS 卫星和北斗卫星均适用。仰角的值域范围为 $[-90^\circ, +90^\circ]$, 方位角的值域范围为 $[-180^\circ, +180^\circ]$ 或 $[0^\circ, +360^\circ]$ 。实际中由于接收机只能接收到位于天顶上方的卫星, 所以根据实际接收到的卫星信号所得到的卫星仰角只能是 $0^\circ \sim 90^\circ$ 之间。图 7.3 所示是 24 小时的 GPS 和北斗卫星仰角和方位角轨迹, 接收机位置为 $(39.9005^\circ\text{N}, 116.4135^\circ\text{E})$ 。为了便于识别, 将 GPS 卫星和北斗卫星的轨迹分为两张图, 左图为 GPS 卫星, 右图为北斗卫星, 图中中心点为接收机自身位置, 不同卫星的仰角和方位角通过距离中心点的距离和角度表示。从图 7.3 中可以看出, 不同 GPS 卫星的轨迹形状比较类似, 而北斗卫星的轨迹形状则明显分为三类: B1 到 B5 为 GEO 卫星, 所以仰角和方位角变化不大; B6 到 B10 为 IGSO 卫星, 其轨迹为大半个“8”字形, 因为当 IGSO 卫星飞行到南半球时不可见; B11 到 B14 为 MEO 卫星, 故在观测地点只能接收到其整个运行周期的一部分时间内的信号。




图 7.3 GPS 和北斗卫星的仰角和方位角分布图 (接收机位置: $39.9005^\circ\text{N}, 116.4135^\circ\text{E}$)

7.1.6 几何精度因子

通过 7.1.3 节中对于伪距观测量定位的算法分析,同时根据最小二乘法中状态误差的协方差矩阵的表达式(7.10),可以得到此时的位置误差的协方差矩阵:

$$\text{var}\{\delta \mathbf{x}_u\} = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{R} \mathbf{H} (\mathbf{H} \mathbf{H}^T)^{-1} \quad (7.74)$$

这里用 $\delta \mathbf{x}_u$ 是为了和 7.1.3 节中的每次迭代的更新量 $d\mathbf{x}_i$ 区分开来; $\mathbf{R}$ 是伪距观测量中的噪声向量的协方差矩阵。如果希望通过式(7.74)计算 $\delta \mathbf{x}_u$, 则必须知道 $\mathbf{R}$ 的值。下面考虑 $\mathbf{R}$ 的具体形式。

一个合理的假设是不同卫星的观测噪声是相互独立的, 所以 $\mathbf{R}$ 是对角矩阵, 用 $\text{diag}\{\sigma_1^2, \sigma_2^2, \dots, \sigma_m^2\}$ 来表示。很显然, σ_i^2 是噪声功率, 衡量了第 i 颗卫星伪距观测量的好坏。一般来说, $\sigma_i^2 \neq \sigma_j^2, \forall i, j \in [1, m]$ 。决定 σ_i^2 的因素有很多, 根据第 5.4 节的分析, 伪距观测量中的噪声项受多个因素的影响。比如, 不同卫星的仰角不同: 较高的仰角会使信号的载噪比比较高, 信号传播过程中的电离层延迟和对流层延迟较小, 因此从其提取到的观测量就会比较干净一些, 从而包含了较小的噪声分量; 与此相对应, 较低仰角的卫星提供的观测量就会有比较大的噪声分量, 导致对应的 σ_i^2 比较大。另外, 影响伪距观测量噪声的因素还有星历误差、卫星钟差、多径延迟和接收机误差等; 但在 GPS 的 SA 政策废止之前, 由于 SA 政策人为加入的卫星时钟随机抖动引起的误差是最为显著的误差源, 并且所有 GPS 卫星均受相同幅度的时钟误差影响, 所以在早期 GPS 接收机的伪距观测量误差分析过程中可以假设所有卫星提供的伪距观测量噪声都有相同(或相近)的功率, 于是 $\mathbf{R} = \sigma^2 \mathbf{I}$, 这里 $\mathbf{I}$ 是个 $m \times m$ 的单位矩阵。下面的公式推导可以证实这个结论, 首先假设伪距观测量误差用 ρ_{URE} 表示, 下标 URE 表示用户测距误差 (User Ranging Error), 在各误差项相互独立的情况下 ρ_{URE} 可以写为:

$$\rho_{\text{URE}} = \sqrt{\sigma_{\text{Eph}}^2 + \sigma_{\text{SA}}^2 + \sigma_{\text{iono}}^2 + \sigma_{\text{trion}}^2 + \sigma_{\text{MP}}^2 + \sigma_{\text{r}}^2} \quad (7.75)$$

在 GPS 的 SA 政策废止之前, $\sigma_{\text{SA}} \approx 33 \text{ m}$ 。当 σ_{SA} 远大于其他各项时, 可以得到 $\rho_{\text{URE}} \approx \sigma_{\text{SA}}$ 。可见, 假设所有卫星提供的伪距观测量噪声都有相同(或相近)的功率是合理的。如果将 $\mathbf{R} = \sigma^2 \mathbf{I}$ 代入式(7.74), 可得到

$$\begin{aligned} \text{var}\{\delta \mathbf{x}_u\} &= (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \sigma^2 \mathbf{I} \mathbf{H} (\mathbf{H}^T \mathbf{H})^{-1} \\ &= \sigma^2 (\mathbf{H}^T \mathbf{H})^{-1} \end{aligned} \quad (7.76)$$

为了后面理论分析方便, 将 $(\mathbf{H}^T \mathbf{H})^{-1}$ 用 $[h_{i,j}]$ 来记, 其中 $h_{i,j}$ 表示该矩阵的第 i 行 j 列的元素, 于是

$$\text{var}\{\delta x_u\} = \sigma^2 h_{1,1} \quad (7.77)$$

$$\text{var}\{\delta y_u\} = \sigma^2 h_{2,2} \quad (7.78)$$

$$\text{var}\{\delta z_u\} = \sigma^2 h_{3,3} \quad (7.79)$$

$$\text{var}\{\delta b\} = \sigma^2 \bar{h}_{4,4} \quad (7.80)$$

从式(7.77)到(7.80)可以看出, $(\mathbf{H}^T \mathbf{H})^{-1}$ 矩阵对角线上的元素在一定程度上反映了定位结果的精确度。这里用“一定程度上”是因为上述公式的推导是基于各个卫星观测量噪声功率相同的假设, 而该假设在工程实际中很难成立。在美国 SA 政策实施的时候, 由于伪距观测量总是存在固定幅度的卫星钟差分量, 导致定位误差的大小总是和 $\bar{h}_{i,i}$ 的值成正比。但当 SA 政策废止以后, 伪距观测量的误差项中并不存在非常显著的误差源, 此时如果伪距误差值很小的话, 虽然 $\bar{h}_{i,i}$ 的值比较大, 但最终也可能得到比较精确的定位结果。即使如此, 从 GPS 接收机的设计和性能分析的早期阶段开始, 人们定义了以下精度因子:

$$\text{位置精度因子 (PDOP)} = \sqrt{\bar{h}_{1,1} + \bar{h}_{2,2} + \bar{h}_{3,3}}$$

$$\text{钟差精度因子 (TDOP)} = \sqrt{\bar{h}_{4,4}}$$

$$\text{几何精度因子 (GDOP)} = \sqrt{\bar{h}_{1,1} + \bar{h}_{2,2} + \bar{h}_{3,3} + \bar{h}_{4,4}}$$

精度因子可以看作从观测量中的测量误差到状态估计误差的线性映射。在观测量误差都相同的情况下, 较大的精度因子会引起较大的状态估计误差, 而较小的精度因子会使状态估计的误差更小。从精度因子的定义可以看出, 精度因子和实际的观测量噪声无关, 而仅仅与 $(\mathbf{H}\mathbf{H}^T)^{-1}$ 有关, $(\mathbf{H}\mathbf{H}^T)^{-1}$ 直接由 $\mathbf{H}$ 矩阵算出。仔细观察 $\mathbf{H}$ 矩阵的形式, 可以知道 $\mathbf{H}$ 矩阵每一个行向量是由某一颗卫星和用户的方向余弦矢量和 1 组成的, 所以 $(\mathbf{H}\mathbf{H}^T)^{-1}$ 必然和多颗卫星的几何分布有关。

根据上述精度因子的定义, 可知

$$\begin{aligned} \sigma_{\text{Pos}} &= \sqrt{\sigma_x^2 + \sigma_y^2 + \sigma_z^2} \\ &= \sqrt{\bar{h}_{1,1} + \bar{h}_{2,2} + \bar{h}_{3,3}} \cdot \sigma_{\text{URE}} \\ &= \text{PDOP} \cdot \sigma_{\text{URE}} \end{aligned} \quad (7.81)$$

式中, σ_{Pos} 是最小二乘法计算的接收机位置的标准差。式(7.81)表示了伪距观测量中的测距误差和最终定位误差的关系。图 7.4 所示的例子直观地解释为什么几何精度因子会和卫星的几何分布有关。这个例子虽然是在二维平面上, 但将其推广到我们生活的三维空间从原理上并没有太多的困难。

图 7.4 中有两个星座排列, 每个星座排列有两颗星, 因为在二维平面上两个星足够定位了。当然, 如果考虑本地时钟的不稳定性的话, 需要三颗卫星, 但此处为了突出重点, 假设本地时钟已经足够精确。每个卫星的伪距方程在平面绘出一个圆。考虑到伪距方程中的测量误差, 这个圆不是一条曲线, 而是一个同心圆带, 同心圆带的厚度就反映了伪距测量误差的大小。理论上两个圆会有两个交点, 其中一个在地球表面的交点就是用户的所在地。但现在由于测量误差的影响, 两个同心圆带的交界就不是一个点, 而是有一个交汇带, 即图中用阴影绘出的部分。交汇带的区域就是用最小二乘法得到的所有可能的定位结果。图 7.4 中右边的星座排列是两个星

和用户的连线几乎成直线时的情况，而左边的星座排列是两颗星和用户的连线几乎相互垂直的情况。两个星座排列中相同卫星的同心圆带的厚度不变，唯一改变的是两颗卫星相对用户的排列。可以很容易地看出，右边的交汇带的面积比较大，而左边的交汇带面积就比较小。相应地，就是右边星座导致的定位结果的误差就比较大，而左边星座导致的定位结果的误差就比较小。




图 7.4 不同的星座排列对定位结果的影响

图 7.4 的例子推广到三维情况，就是几何精度因子的概念。因为 GPS 定位至少需要 4 颗星，理论上可以证明，在 4 颗卫星参与运算的情况下，最佳的星座排列是一颗星在天顶，另外三颗星以较低的仰角分散排列。

由式(7.77)~式(7.80)得到的精度因子是在 ECEF 坐标系中得到的；而在实际应用中人们往往对 ECEF 坐标系不甚熟悉，而更倾向于使用站心坐标系，即 ENU（或 NED）坐标系。如果想要得到在 ENU 坐标系中的几何精度因子的表达式，需要做一个旋转操作。

首先，考虑线性化的伪距方程

$$\delta \rho = H_e \delta x_e + n_p \quad (7.82)$$

式(7.82)中 H 和 δx 都加了下标“e”表示是在 ECEF 坐标系中。在 ENU 坐标系中，状态误差被表示为 δx_i 。根据矢量在不同坐标系中的旋转关系，可知在 ENU 坐标系中的 δx_i 和 ECEF 坐标系中的 δx_e 有如下关系：

$$\delta x_i = R_L \delta x_e \quad (7.83)$$

其中，

$$R_L = \begin{bmatrix} R_{e2i} & \mathbf{0}_{3 \times 1} \\ \mathbf{0}_{1 \times 3} & 1 \end{bmatrix}$$

R_L 表达式中 R_{e2i} 是将 ECEF 坐标系中的三维矢量 $[\delta x_u, \delta y_u, \delta z_u]^T$ 从 ECEF 坐标系旋转到 ENU 坐标系中的 $[\delta E_u, \delta N_u, \delta U_u]^T$ 的旋转矩阵， R_{e2i} 的表达式在 7.1.5 节已经给

出, 其中因为钟差量和具体坐标系无关, 所以 $\mathbf{R}_L$ 中有关时间的项是 1。从 $\mathbf{R}_L$ 的表达式可以看出, $\mathbf{R}_L$ 作为一个正交矩阵, 具有如下性质:

$$\mathbf{R}_L^T = \mathbf{R}_L^{-1} \Rightarrow \mathbf{R}_L^T \mathbf{R}_L = \mathbf{I} \quad (7.84)$$

故式(7.82)可以重写为

$$\begin{aligned} \delta \boldsymbol{\rho} &= \mathbf{H}_e \mathbf{R}_L^T \mathbf{R}_L \delta \mathbf{x}_e + \mathbf{n}_\rho \\ &= \mathbf{H}_t \delta \mathbf{x}_t + \mathbf{n}_\rho \end{aligned} \quad (7.85)$$

这里 $\mathbf{H}_t = \mathbf{H}_e \mathbf{R}_L^T$, $\delta \mathbf{x}_t = [\delta E_u, \delta N_u, \delta U_u, \delta b]^T$ 。

由类似于 ECEF 坐标系中的分析方法, 可知在针对 ENU 坐标系的理论推导中, 式(7.76)中的 $(\mathbf{H}^T \mathbf{H})^{-1}$ 变为

$$\begin{aligned} (\mathbf{H}_t^T \mathbf{H}_t)^{-1} &= (\mathbf{R}_L \mathbf{H}^T \mathbf{H} \mathbf{R}_L^T)^{-1} \\ &= \mathbf{R}_L (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{R}_L^T \end{aligned} \quad (7.86)$$

得到了 $(\mathbf{H}_t^T \mathbf{H}_t)^{-1}$ 以后, 用 $[h'_{i,j}]$ 来标记第 i 行第 j 列元素。由于现在 $\delta \mathbf{x}_t = [\delta E_u, \delta N_u, \delta U_u, \delta b]^T$ 表示东向、北向和上方向的位置误差, 所以 $(\mathbf{H}_t^T \mathbf{H}_t)^{-1}$ 4 个对角线上的元素分别对应东向、北向、上方向的位置误差和一个钟差误差, 于是可以定义

$$\text{水平位置精度因子 (HDOP)} = \sqrt{h'_{1,1} + h'_{2,2}}$$

$$\text{垂直位置精度因子 (VDOP)} = \sqrt{h'_{3,3}}$$

$$\text{钟差精度因子 (TDOP)} = \sqrt{h'_{4,4}}$$

$$\text{几何精度因子 (GDOP)} = \sqrt{h'_{1,1} + h'_{2,2} + h'_{3,3} + h'_{4,4}}$$

由于 GPS 卫星时刻处于运动状态, 所以几何精度因子也相应地在动态地改变。GPS 接收机必须时刻监控几何精度因子的状况, 在几何精度因子变差的时候要采取相应的策略, 或者向使用者指出目前的几何精度因子的状况以加以预警。在早期 GPS 接收机中, 由于集成电路工艺和信号处理器处理能力的限制, 往往只能同时跟踪为数不多的几颗卫星, 这样导致几何精度因子不会很好。现代的 GPS 接收机一般都能同时跟踪 12 颗或更多的卫星, 并且能够把全部跟踪上的卫星的伪距观测量参与定位解算, 所以几何精度因子已经越来越不是一个严重的问题; 只是偶尔在有障碍物遮挡部分卫星或在室内定位的时候, 才会有比较差的几何精度因子, 这时在使用中必须加以注意。

对于北斗和 GPS 双模联合定位的情况, 如果采用系统设置法则, 最小二乘法的 $\mathbf{H}$ 矩阵依然是 $m \times 4$ 维的, 所以上述几何精度因子的定义和计算方法依然适用。如果采用在用户设备端将 T_{GB} 看作待估的系统状态量的方法, 则 $\mathbf{H}$ 矩阵变为 $m \times 5$ 维的, 除了三个位置、一个钟差外, 增加了一个系统时间偏差项。此时, 几何精度因子除了上面的集中以外, 还多了一项系统时间偏差精度因子:

$$\text{系统时间偏差精度因子 (STDOP)} = \sqrt{h'_{4,4}} \quad (7.87)$$

上式在下列情况下成立:

$$H = \begin{bmatrix} DC_{G1} & 0 & 1 \\ \vdots & \vdots & \vdots \\ DC_{Gm} & 0 & 1 \\ DC_{B1} & 1 & 1 \\ \vdots & \vdots & \vdots \\ DC_{Bn} & 1 & 1 \end{bmatrix} \quad (7.88)$$

即 H 矩阵的第 4 列对应系统时间偏差 T_{GB} , 其中 $DC_{G/Bi}$ 表示北斗 / GPS 卫星的方向余弦矢量。由式(7.88)可知此时的 $(H_i^T H_i)^{-1}$ 矩阵是 5×5 维的, 所以其余的 PDOP、TDOP、HDOP、VDOP 和 GDOP 等物理量的定义和单 GPS 的情况下类似, 只不过需要根据 $(H_i^T H_i)^{-1}$ 的对角线元素对对应的物理意义稍做调整即可。

图 7.5、图 7.6、图 7.7 和图 7.8 分别是 24 h 的 PDOP、HDOP、VDOP 和 TDOP 值, 均包括了单 GPS 解算、单北斗解算和 GPS+BDS 联合解算的情况。其中, 接收机位置为 $(39.9005^\circ\text{N}, 116.4135^\circ\text{E})$, 采样间隔为 30 s, 大部分时间跟踪到的 GPS 和北斗卫星的总数目在 20 颗左右, 计算几何精度因子时全部跟踪到的卫星信号不参与运算。从计算结果看, VDOP 值要略大于 HDOP 值, 这是因为所有卫星均位于天顶方向, 导致解算得到的定位结果在垂直方向的约束不如水平方向强。从图 7.5 可以看到, 双模解算时的 PDOP 有相当大的概率小于 1, 而根据式(7.81), 小于 1 的 PDOP 值将会导致更小的 σ_{Pos} , 这是双模联合定位带来的一个好处。




图 7.5 24 h 的 PDOP 值




图 7.6 24 h 的 HDOP 值




图 7.7 24 h 的 VDOP 值

从图 7.5、图 7.6、图 7.7 和图 7.8 还可以看到，北斗单模情况下的 DOP 变化较慢，而同时刻的 GPS 单模情况下的 DOP 变化较快，这是因为目前北斗卫星还主要由 GEO 和 IGSO 卫星组成，MEO 卫星较少，导致卫星的几何分布变化不如 GPS 快；随着北斗 MEO 卫星的增多，北斗单模情况下的 DOP 的变化趋势将和 GPS 类似。




图 7.8 24 h 的 TDOP 值

7.1.7 接收机自主完好性监测 (RAIM)

接收机自主完好性监测 (Receiver Autonomous Integrity Monitoring, RAIM) 的目的, 是通过不同观测量之间的冗余约束关系对最小二乘法的定位结果的有效性进行判决。根据 7.1.3 节中的结论可知, 最小二乘法中的未知量数目是 4 个 (在双模解算情况下也可能是 5 个, 但下面的分析过程将默认未知量数目是 4), 接收机往往能够跟踪多于未知数数目的卫星, 因此超出部分的伪距观测量将提供冗余信息, 根据冗余信息和最小二乘解是否吻合就能够判断当前的最小二乘解是否存在错误或明显偏差。

1. 伪距残差判决法

一个或多个错误的伪距观测量会导致错误的定位结果, 但在 7.1.3 节的迭代过程中却无法判知。为了证明这一点, 对于某个时元的一组伪距观测量, 例如, 下例中有 7 颗 GPS 卫星可用, 将其中一颗卫星的伪距观测量人为地加上 300 km, 模拟伪距观测量出现了明显偏差的情况。这种情况在接收机中产生了错误的比特同步的时候非常常见。将这组出现了错误的伪距观测量进行迭代运算, 其迭代更新量和伪距残差结果分别在表 7.2 和表 7.3 中显示。

表 7.2 对错误的伪距进行 6 次迭代后的更新量 (单位: 米)

迭代次数	Δx_u	Δy_u	Δz_u	Δb
1	-3 482 231.70	5 717 628.68	3 985 718.62	1 404 937.22
2	551 235.04	-855 330.66	-6 31 169.52	-1 255 831.43
3	15 528.43	-19759.21	-17 773.41	-36 677.45
4	-12.36	49.56	-0.48	5.82
5	0.07 564	-0.139 474	-0.134 227	-0.102 945
6	-0.239 181E-3	0.527 204E-3	0.103 028E-3	0.266 970E-3

表 7.3 对错误伪距进行迭代收敛时各卫星伪距残差 (单位: 米)

卫星索引	1	2	3	4	6	7
伪距残差	-1.1036E5	-0.4787E5	-0.3670E5	0.2917E5	1.1923E5	0.4653E5

可以看出, 虽然伪距观测量被人为地破坏, 在 6 次迭代以后更新量却依然可以趋近于 0。由于更新量小于预定门限, 所以在最小二乘法中依然可以认为迭代结束; 但显然由此得到的定位结果是错误的, 迭代停止更新只是说明在给定的伪距观测量的条件下由式(7.2)定义的代价函数取到了最小值。但是此时表 7.3 给出的伪距残差却非常大, 都在 20~100 km 的范围, 所以利用伪距残差的结果可以大致判断定位结果的正确与否。需要指出的是, 只有在有冗余方程的情况下, 即观测量的数目大于 4 的情况下, 才能用上述方法判断定位结果是否正确; 如果只有 4 个伪距观测量, 则即使某个观测量是错误的, 迭代结束后依然会给出很小的伪距残差 (接近于 0)。读者可以自行验证这一点。

上述过程中通过计算伪距残差的方法可以判断当前最小二乘解的有效性, 一般把这种 RAIM 方法称为伪距残差判决法。首先考虑基于前一个时元的定位结果将当前的伪距观测量进行线性化, 结果如下列方程所示:

$$\boldsymbol{\rho} = \mathbf{H}\mathbf{x} + \boldsymbol{\varepsilon} \quad (7.89)$$

这里

- $\boldsymbol{\rho}$ 是 n 颗卫星的伪距观测量进行线性化后的结果, $\boldsymbol{\rho} \in \mathbb{R}^n$;
- $\mathbf{H} \in \mathbb{R}^{n \times 4}$, $\mathbf{H}$ 中每一行的行向量为 $[e_x, e_y, e_z, 1]$, 其中 $[e_x, e_y, e_z]^T$ 是从卫星位置到接收机位置的方向余弦矢量;
- $\mathbf{x} \in \mathbb{R}^4$ 是待估系统状态矢量, 通常包括 3 个位置量和 1 个钟差量;
- $\boldsymbol{\varepsilon} \in \mathbb{R}^n$ 是观测噪声向量, 通常包括信号传输噪声、卫星星历误差、卫星钟差和接收机误差等, 通常可以认为噪声为零均值的高斯白噪声, 并且不同卫星之间的噪声相互独立, 即 $E[\boldsymbol{\varepsilon}] = \mathbf{0}$, $\text{cov}[\boldsymbol{\varepsilon}] = \sigma_\varepsilon^2 \mathbf{I}_n$ 。

从前面章节可知, 式(7.89)的最小二乘解为

$$\mathbf{x}_{ls} = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \boldsymbol{\rho} \quad (7.90)$$

由上式可以得到伪距残差矢量为

$$\mathbf{z} = [\mathbf{I} - \mathbf{H}(\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T] \boldsymbol{\rho} \quad (7.91)$$

如果定义矩阵 $\mathbf{S} \triangleq \mathbf{I} - \mathbf{H}(\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T$, 则式(7.91)可以写为

$$\mathbf{z} = \mathbf{S} \boldsymbol{\rho} \quad (7.92)$$

可以验证, $\mathbf{S}$ 矩阵为对称矩阵, 且为幂等矩阵 ($\mathbf{S}^2 = \mathbf{S}$)。可见, 只要知道了 $\mathbf{H}$ 矩阵, 就可以计算出 $\mathbf{S}$ 矩阵, 进而无须计算最小二乘解 $\mathbf{x}_{ls}$ 就能直接计算出 $\mathbf{z}$ 矢量。得到了 $\mathbf{z}$ 矢量以后, 可以计算伪距残差平方和 SSE:

$$\text{SSE} = \mathbf{z}^T \mathbf{z} \quad (7.93)$$

很显然, SSE 是一个数值而非矢量, 由 $\mathbf{z}$ 矢量各个元素的平方和得到。如果 n 颗卫星的伪距观测量中的观测噪声为零均值高斯噪声且相互独立, 则可以证明 SSE 为自由度为 $n-4$ 的开方分布, 于是可以根据 SSE 的概率分布而计算出给定虚警概率下的检测门限, 当 SSE 大于该门限时可以认定当前的伪距观测量中存在错误观测量, 相应地当前时元的最小二乘解存在问题而需要丢弃。有些学者建议采用归一化的伪距残差平方和 $\sqrt{\text{SSE}/(n-4)}$ 进行判决, 从这里可以看出, 采用伪距残差判决法要求伪距观测量的数目至少大于 4 个, 小于或等于 4 颗卫星的伪距观测量无法得到有效的伪距残差平方和。

伪距残差判决法的优点在于 SSE 的表达式形式简单, 计算复杂度也不高。由于是标量值, 所以判决门限为单一门限, SSE 的结果和卫星几何分布形式无关, 只和伪距观测量的噪声分布有关。在 SA 政策有效期间, 伪距观测量的噪声分布比较容易确定, 而且由于各个 GPS 卫星的伪距观测量噪声功率基本一致, 所以符合前面对 ϵ 的理论假设; 但在 SA 政策废止以后各个 GPS 卫星的伪距观测量噪声功率不再一致, 所以 SSE 的概率分布相对更复杂一些, 实际中往往用经验值的方法来确定判决门限。伪距残差判决法的一个缺陷, 在于它只能判决当前伪距观测量集合存在问题或错误, 但无法判决具体哪颗卫星的伪距观测量出现了问题; 这是因为全部伪距观测量都被用来计算最小二乘解, 即使只有 1 个伪距观测量出现错误, 也会导致错误的结果。

2. 伪距比较法

在伪距观测量数目大于 4 的情况下, 假设伪距观测量数目为 n , 可以将伪距观测量集合分为两部分, 其中第一部分包括 4 个伪距观测量, 第二部分包含剩下的 $n-4$ 个伪距观测量。第一步, 先根据第一部分的 4 个伪距观测量得到最小二乘解; 第二步, 将第二部分的伪距观测量作为判决依据, 具体步骤是先计算第二部分中每一个卫星的位置, 然后根据式(7.32)和第一步中得到的最小二乘解计算出预测的伪距量, 将第二部分中的伪距观测量和预测的伪距量相减: 如果所有的 $n-4$ 个伪距差的绝对值都很小, 说明这组伪距观测量应该没有问题, 第一步得到的最小二乘解也是可靠的; 否则, 说明这组伪距观测量应该存在错误或问题, 错误观测量可能出现在第一

部分的伪距观测量中,也可能出现在第二部分作为判决的伪距观测量中。这个过程可以看作一次二元假设检验,即 H_0 和 H_1 判决,出现错误的时候为 H_1 判决,没有出现错误的时候为 H_0 判决。当为 H_1 判决时,如果所有的 $n-4$ 个伪距差的绝对值都比较大,则说明通过第一部分的 4 个伪距观测量计算得到的最小二乘解出现错误的概率较大;如果 $n-4$ 个伪距差中只有一个绝对值较大而其他的都较小,则说明最小二乘解正确的概率较大,出现问题的伪距观测量恰恰是那个伪距差较大的伪距观测量。这种 RAIM 方法叫作伪距比较法。这种方法和伪距残差判决法的不同之处,在于它并不把全部伪距观测量都用来计算最小二乘解;所以如果只有 1 个伪距观测量出现错误,只要这个伪距观测量不在第一部分的 4 个伪距观测量出现,则最小二乘解依然是正确的。此时通过上述的逻辑判决可以找到错误的伪距观测量,必要时需要对两部分的伪距观测量集合进行重新分组,然后重新计算最小二乘解并比较伪距值。当然,这样会增大运算量和逻辑判决的复杂性。

3. 校验向量法

校验向量法是另外一种在实际工程中广泛应用的 RAIM 方法。这种方法通过一个校验矩阵 P 计算校验向量 p :

$$p = Pp \quad (7.94)$$

其中,校验矩阵 P 具有如下性质:

- ① $P \in \mathbb{R}^{(n-4) \times n}$, 即 P 的维度是 $(n-4) \times n$;
- ② $\text{rank}(P) = n-4$, 即 P 的秩为 $n-4$;
- ③ $PP^T = I_{n-4}$, 即 P 的行向量相互正交;
- ④ $PH = 0$ 。

根据 P 矩阵的性质,可以看出校验向量 p 是 $(n-4)$ 维,并且可以证明

$$p^T p = z^T z \quad (7.95)$$

式中, z 是伪距残差法中的伪距残差矢量,即式(7.92)的结果。这证实了校验向量法和伪距残差法的一致性,在计算 SSE 时可以采用两种方法中的任意一种。

由矩阵 P 的第 4 个性质可知, P 的列向量在 H^T 的零空间里。如果将式(7.89)代入式(7.94),并利用 P 的性质 4, 可得

$$p = P\varepsilon \quad (7.96)$$

从式(7.96)可知,系统状态矢量 x 在左乘 P 以后为 0 向量,只有观测误差向量才会被“转换”到校验向量 p 中,这是一个非常有用的性质。关于这一点,假如我们把式(7.90)和式(7.94)写在一起,如式(7.97)所示,就能够理解得更透彻一些。

$$\begin{array}{ccc} x_{ls} & (H^T H)^{-1} H^T & \\ \cdots & = & \cdots \quad [\rho] \\ P & P & \end{array} \quad (7.97)$$

其中, $[\rho]$ 对应观测矢量空间, $[\mathbf{x}_s]$ 对应系统状态矢量空间, $[\mathbf{p}]$ 对应校验矢量空间, 从观测量空间到系统状态空间的转换通过矩阵 $(\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T$ 完成, 从观测量空间到校验空间的转换通过 $\mathbf{P}$ 矩阵完成。从式(7.96)可知, 由于校验向量 $\mathbf{p}$ 和观测噪声矢量 $\boldsymbol{\varepsilon}$ 呈齐次线性关系, 那么对于错误观测量的检测和甄别就可以通过校验向量 $\mathbf{p}$ 来完成。以 $n=6$ 个伪距观测量为例, 此时 $\mathbf{H}$ 矩阵为 4×6 维, $\mathbf{P}$ 矩阵为 2×6 维, 假设 $\mathbf{P}$ 矩阵取如下的形式:

$$\mathbf{P} = \begin{bmatrix} p_{11} & p_{12} & p_{13} & p_{14} & p_{15} & p_{16} \\ p_{21} & p_{22} & p_{23} & p_{24} & p_{25} & p_{26} \end{bmatrix}$$

当 6 个伪距观测中第 j 个出现了错误时, 即 $\rho_j = \mathbf{H}_j \mathbf{x} + b$, 其中 b 为该伪距观测中的明显偏差, 如果其他几个观测量的噪声大小忽略不计的话, 则此时校验向量为

$$\mathbf{p} \approx \begin{bmatrix} p_{1j} \\ p_{2j} \end{bmatrix} b \quad (7.98)$$

从式(7.98)可以得到两个结论: 首先 $\mathbf{p}$ 的模可以用来判决是否出现了观测量错误; 其次 $\mathbf{p}$ 向量可以用来判决哪个观测量出现了错误, 判决原则就是用 $\mathbf{p}$ 向量的元素和原点 (0,0) 之间的连线的斜率和 p_{1i}/p_{2i} ($i=1, \dots, 6$) 比较, 两者最接近的 i 值就表明该位置对应的卫星的伪距观测量出错的概率最大。实际中, 可以把 $\mathbf{P}$ 矩阵的每一个列向量的元素看作一个偏差倾斜斜率, 每一个倾斜斜率对应一个伪距观测量, 上述例子中的 6 个伪距观测量可以得到 6 个偏差倾斜斜率, 如图 7.9 中左图所示。左图中有 6 条直线, 每条直线的斜率由 p_{1i}/p_{2i} 决定, 图中圆的半径表示判决门限, 只有当 $\mathbf{p}$ 的模大于该门限时才说明出现了观测量错误, 此时会判决 $\mathbf{p}$ 向量和那条直线平行, 从而甄别出错误的伪距观测量。




图 7.9 6 个伪距观测量和 7 个伪距观测量的偏差倾斜斜率示意图

当伪距观测量的数目大于 6 个时, 偏差倾斜斜率就需要在更高维度的空间中表示了。图 7.9 中右图就是伪距观测量数目为 7 时的偏差倾斜斜率, 此时的校验矢量空间为 3 维空间, 相应的判决门限决定的形状是一个球而非一个圆, $\mathbf{p}$ 向量是三维空间中的直线, 但判决的依据依然是检查 $\mathbf{p}$ 向量和哪个偏差倾斜斜率平行。

从 $\mathbf{P}$ 矩阵的性质可知, $\mathbf{P}$ 矩阵并不是唯一的, $\mathbf{P}$ 矩阵可以通过对 $\mathbf{H}$ 矩阵做 QR 分解得到, 即如果

$$\mathbf{H} = \mathbf{Q}\mathbf{R} \quad (7.99)$$

则 $\mathbf{Q}$ 的转置矩阵的底部 $n-4$ 个行向量就是 $\mathbf{P}$ 矩阵。

校验向量方法不仅实现了伪距观测量的错误判决, 而且还能够通过比较偏差倾斜斜率实现对错误观测量的甄别, 所以在实际产品中得到了比较广泛的使用。但校验向量法也有一定的不足, 例如: 如果两个卫星对应的偏差倾斜斜率很接近, 则容易出现误判现象; 当出现错误的观测量不止一个时, 校验向量 $\mathbf{p}$ 就由多个不同斜率的直线组合而成, 这样就很难甄别出那个观测量出现了错误。另外, 图 7.9 中的判决门限, 即图中的圆和球的半径, 很难被准确地确定, 当 $\mathbf{p}$ 的模很大时比较容易确定出错的观测量, 当 $\mathbf{p}$ 的模很小时无须确定出错的观测量, 当 $\mathbf{p}$ 的模 c 处于两者之间时恰恰是最棘手的情况; 因为此时的 b 虽然不大, 但这样的观测量却能对定位结果产生不可忽视的偏差, 而此时却很难将出错的观测量筛选出来。

4. 最大解分离法

最大解分离法的基本思想是将 N 个伪距观测量分成 N 组集合, 每一组不包括第 i 个伪距观测量, $i=1, \dots, N$ 。即每一组集合包含的观测量数目是 $N-1$, 如果 $N-1$ 足够大 ($N-1 \geq 4$), 则依然能够得到一个有效的最小二乘解。这样就能够得到 N 的定位结果, 判断这些 N 个定位结果之间的两两距离: 如果最大的距离小于预设的门限, 说明全部 N 个伪距观测量没有错误; 反之, 则说明其他有一个或多个伪距观测量存在错误。这种方法的依据是当只有一个伪距观测量出现错误时, 通过上述的分组方式必然有一组观测量集合不包含错误观测量, 而此时通过该观测量集合计算得到的定位结果必然在正确位置附近, 其他各组必然包含错误观测量, 所以其定位结果由于受错误观测量的影响而不会得到正确位置, 这样正确的定位结果和错误的定位结果之间必然存在较大的距离。这种方法存在若干个变种, 其中之一就是观测量分组计算方法, 这种方法将 N 个观测量分成 C_N^M 个组, 每一个组内包含 M 个观测量, 显然如果 $M \geq 4$, 每一组可以得到一个最小二乘解, 比较这 C_N^M 个解的距离, 可以判断全部观测量中是否存在错误, 进一步对 C_N^M 个解的详细分析可以甄别出错误观测量。这些方法的代价是分组导致运算量增大, 在对错误观测量进行甄别时需要复杂的逻辑处理, 并且存在一定的判决错误概率。

从上面对几种 RAIM 方法进行分析中可以看出, 这些方法均利用了伪距观测量的冗余信息, 如果没有冗余的伪距观测量, 则无法对最小二乘解的正确与否做出判

断。从这个角度出发,也可以利用更多的冗余信息,这里的冗余信息并不一定限于卫星信号,也可以是来自惯性传感器、气压计、磁力计、罗兰-C 导航结果、车辆里程计等信息。

7.2 卡尔曼滤波解算

自从 20 世纪 60 年代出现卡尔曼滤波以来,全世界的学者已经对其进行了详尽的研究和探讨。卡尔曼滤波在很多领域,尤其在目标跟踪、制导、控制和导航领域得到了非常广泛的应用。卡尔曼滤波的显著特点包括递归运算和运算的高效性,同时在最小均方误差的意义上是最优的。一般来说,卡尔曼滤波的每次更新需要两个步骤:第一个步骤是进行状态更新,第二个步骤是观测量更新。状态更新基于系统状态转移方程,对系统状态量进行时间预测;而观测量更新发生在系统观测量到来以后,将预测的状态量和观测量一起作为输入对系统状态量进行最小二乘法的估计,而得到的估计又作为下一个时刻的系统更新的起点。所以,卡尔曼滤波从某种意义上来说和递归最小二乘(Recursive Least Square, RLS)方法有一定的相似之处。本节将从 RLS 开始,详细讲解卡尔曼滤波的原理及其在北斗 / GPS 接收机内部的应用,同时结合具体工程问题对卡尔曼滤波在具体实现方法上进行一些有益的探讨。

7.2.1 递归最小二乘法

从 7.1.2 节中可知,对于用状态转移方程

$$Y = Ax + n$$

所描述的系统来说,对其系统状态量的加权最小二乘估计为

$$\hat{x} = (A^T W A)^{-1} A^T W \tilde{Y} \quad (7.100)$$

式中, n 、 W 、 $\tilde{Y}$ 和 7.1.2 节中的定义一样。假设 $\tilde{Y}$ 包含从时刻 0 开始的所有观测量,这样的处理是对所有观测量同时处理,一般被称作批处理(Batch Processing)方式。

由于现代数字系统工作于离散时间域,所以下面分析将基于数字采样时刻 t_k 展开,其中 $k=0,1,\dots,\infty$ 。假设在时刻 t_m ,有 m 个观测量,即 $\tilde{Y}_m = [\tilde{y}_1, \tilde{y}_2, \dots, \tilde{y}_m]^T$,则状态转移矩阵 A 是一个 $m \times k$ 的矩阵,这里 k 是系统状态矢量 x 的维数。那么由式(7.100)得到的 WLS 估计是基于 $\tilde{Y}_m$ 中的所有元素得到的。显而易见,整个批处理过程需要一次 $k \times m$ 和 $m \times k$ 的矩阵相乘,一次 $k \times k$ 的矩阵求逆,一个 $k \times m$ 和 $m \times 1$ 的矩阵相乘,一个 $k \times k$ 和 $k \times 1$ 的矩阵相乘。

在时刻 t_{m+1} ,有了一个新的观测量 $\tilde{y}_{m+1}$,因此观测量向量

$$\begin{aligned}\tilde{\mathbf{Y}}_{m+1} &= [\tilde{y}_1, \tilde{y}_2, \dots, \tilde{y}_m, \tilde{y}_{m+1}]^T \\ &= [\tilde{\mathbf{Y}}_m^T, \tilde{y}_{m+1}]^T\end{aligned}$$

如果继续沿用式(7.100)的批处理方式对系统状态进行 WLS 估计, 则新的估计基于 $\tilde{\mathbf{Y}}_{m+1}$ 中的所有元素。类似前面的分析可知, 所需的运算量为一次 $k \times (m+1)$ 和 $(m+1) \times k$ 的矩阵相乘, 一次 $k \times k$ 的矩阵求逆, 一个 $k \times (m+1)$ 和 $(m+1) \times 1$ 的矩阵相乘, 和一个 $k \times k$ 与 $k \times 1$ 的矩阵相乘。

这样做粗看起来似乎并没有什么不妥。可是仔细分析以后就会发现, $\tilde{\mathbf{Y}}_m$ 包含的全部信息已经在 t_m 时刻用过了, 在 t_{m+1} 时刻已经没有必要再重新从 $\tilde{y}_1$ 开始计算。因为 $\tilde{\mathbf{Y}}_{m+1}$ 和 $\tilde{\mathbf{Y}}_m$ 相比, 其中的新信息其实只包含在 $\tilde{y}_{m+1}$ 中, 所以只需在上一次估计的基础上考虑这个新的观测量即可。

简单地基于式(7.100)的方法还有一个致命的问题, 就是系统资源开销的问题, 尤其是存储器开销的问题。随着时间的流逝, 新的观测量源源不断地到来, 则系统需要不断开辟新的存储空间来存储新的观测量。长此以往, 一个实际的系统必然有内存耗尽而停止工作的时刻。所以我们必须另辟蹊径以避免发生这些问题, 假如把基于 $\tilde{\mathbf{Y}}_m = [\tilde{y}_1, \tilde{y}_2, \dots, \tilde{y}_m]^T$ 的最小二乘估计表示为 $E^*[x | \tilde{y}_1, \tilde{y}_2, \dots, \tilde{y}_m]$, 下面将从递推的角度来看 $E^*[x | \tilde{y}_1, \tilde{y}_2, \dots, \tilde{y}_m, \tilde{y}_{m+1}]$ 和 $E^*[x | \tilde{y}_1, \tilde{y}_2, \dots, \tilde{y}_m]$ 的关系。

假设在 t_m 时刻基于 $\tilde{\mathbf{Y}}_m$ 对系统状态 $\mathbf{x}$ 的 WLS 估计为 $\hat{\mathbf{x}}_m$, $\hat{\mathbf{x}}_m$ 和真实的 $\mathbf{x}$ 值之间的偏差用 $\delta\hat{\mathbf{x}}_m$ 表示, 即

$$\hat{\mathbf{x}}_m = \mathbf{x} + \delta\hat{\mathbf{x}}_m \quad (7.101)$$

同时, 误差的协方差矩阵 $\text{var}\{\delta\hat{\mathbf{x}}_m\} = \mathbf{P}_m$ 为已知, 即 7.1.2 节中的式(7.24)。

在 t_{m+1} 时刻, 新的观测量 $\tilde{y}_{m+1}$ 到来, 假设其观测噪声方差为 R_{m+1} 。我们可以将 t_m 时刻的 WLS 估计量 $\hat{\mathbf{x}}_m$ 和 $\tilde{y}_{m+1}$ 一起组成一个新的观测向量 $[\hat{\mathbf{x}}_m^T, \tilde{y}_{m+1}]^T$, 这个观测量和系统状态参量 $\mathbf{x}$ 之间的状态转移方程变为

$$\begin{bmatrix} \hat{\mathbf{x}}_m \\ \tilde{y}_{m+1} \end{bmatrix} = \begin{bmatrix} \mathbf{I} \\ \mathbf{A}_{m+1} \end{bmatrix} \mathbf{x} + \begin{bmatrix} \delta\hat{\mathbf{x}}_m \\ n_{m+1} \end{bmatrix} \quad (7.102)$$

式中, $\mathbf{A}_{m+1}$ 为 t_{m+1} 时刻的状态转移矩阵, 下标 “ $m+1$ ” 表示状态转移矩阵可以是时变的; n_{m+1} 为 t_{m+1} 时刻的观测噪声, 它和 $\delta\hat{\mathbf{x}}_m$ 组成新的观测噪声矢量。 n_{m+1} 和 $\delta\hat{\mathbf{x}}_m$ 相互独立, 则新的观测测量误差的协方差矩阵可以用 $\mathbf{R}_{m+1}$ 表示。根据上述分析, $\mathbf{R}_{m+1}$ 可以表示为

$$\mathbf{R}_{m+1} = \text{cov}\{\delta\hat{\mathbf{x}}_m^T, n_{m+1}\} = \begin{bmatrix} \mathbf{P}_m & \mathbf{0} \\ \mathbf{0} & R_{m+1} \end{bmatrix} \quad (7.103)$$

有了 $\mathbf{R}_{m+1}$ 的表达式, 对新的观测向量 $[\hat{\mathbf{x}}_m^T, \tilde{y}_{m+1}]^T$ 采用 WLS 方法, 新的状态转移矩阵和观测噪声由式(7.102)给出, 并取加权矩阵为 $\mathbf{W} = \mathbf{R}_{m+1}^{-1}$, 则新的状态参量估计 $\hat{\mathbf{x}}_{m+1}$ 为

$$\hat{\mathbf{x}}_{m+1} = \begin{bmatrix} \mathbf{P}_{m+1} & \mathbf{I} & \mathbf{A}_{m+1}^T \end{bmatrix} \begin{bmatrix} \mathbf{P}_m & \mathbf{0} \\ \mathbf{0} & R_{m+1} \end{bmatrix}^{-1} \begin{bmatrix} \hat{\mathbf{x}}_m \\ \tilde{\mathbf{y}}_{m+1} \end{bmatrix} \quad (7.104)$$

其中,

$$\begin{aligned} \mathbf{P}_{m+1} &= \text{var}\{\delta \hat{\mathbf{x}}_{m+1}\} \\ &= \begin{bmatrix} \mathbf{I} & \mathbf{A}_{m+1}^T \end{bmatrix} \begin{bmatrix} \mathbf{P}_m & \mathbf{0} \\ \mathbf{0} & R_{m+1} \end{bmatrix}^{-1} \begin{bmatrix} \mathbf{I} \\ \mathbf{A}_{m+1} \end{bmatrix}^{-1} \end{aligned} \quad (7.105)$$

将式(7.105)展开得到

$$\mathbf{P}_{m+1}^{-1} = \mathbf{P}_m^{-1} + \mathbf{A}_{m+1}^T R_{m+1}^{-1} \mathbf{A}_{m+1} \quad (7.106)$$

上式中由于 $\mathbf{A}_{m+1}^T R_{m+1}^{-1} \mathbf{A}_{m+1}$ 总是非负定的, 所以可以看出随着新的观测量到来, 信息矩阵总是递增的。根据 7.1.2 节中信息矩阵的定义及其性质, 可以看出, 当新的观测量到来时信息矩阵中的信息量增大, 下一步就是如何利用新的信息量来使本地状态的估计量更准确。

对式(7.106)两边同时左乘 $\mathbf{P}_{m+1}$ 并整理得到

$$\mathbf{P}_{m+1} \mathbf{P}_m^{-1} = \mathbf{I} - \mathbf{P}_{m+1} \mathbf{A}_{m+1}^T R_{m+1}^{-1} \mathbf{A}_{m+1} \quad (7.107)$$

式(7.107)将在下面的推导中被用到。

将式(7.104)展开并在下式中第二步利用式(7.107)的结果, 可以得到

$$\begin{aligned} \hat{\mathbf{x}}_{m+1} &= \mathbf{P}_{m+1} \mathbf{P}_m^{-1} \hat{\mathbf{x}}_m + \mathbf{P}_{m+1} \mathbf{A}_{m+1}^T R_{m+1}^{-1} \tilde{\mathbf{y}}_{m+1} \\ &= \hat{\mathbf{x}}_m + \mathbf{P}_{m+1} \mathbf{A}_{m+1}^T R_{m+1}^{-1} (\tilde{\mathbf{y}}_{m+1} - \mathbf{A}_{m+1} \hat{\mathbf{x}}_m) \end{aligned} \quad (7.108)$$

令 RLS 增益矩阵

$$\mathbf{k}_{m+1} = \mathbf{P}_{m+1} \mathbf{A}_{m+1}^T R_{m+1}^{-1} \quad (7.109)$$

则式(7.108)可以简化为

$$\hat{\mathbf{x}}_{m+1} = \hat{\mathbf{x}}_m + \mathbf{k}_{m+1} (\tilde{\mathbf{y}}_{m+1} - \mathbf{A}_{m+1} \hat{\mathbf{x}}_m) \quad (7.110)$$

式(7.110)中, $\hat{\mathbf{y}}_{m+1} = \mathbf{A}_{m+1} \hat{\mathbf{x}}_m$ 是基于 $\hat{\mathbf{x}}_m$ 对 t_{m+1} 时刻的观测量进行预测, 而 $(\tilde{\mathbf{y}}_{m+1} - \mathbf{A}_{m+1} \hat{\mathbf{x}}_m)$ 是实际观测量和预测观测量的残差。

对式(7.110)可以这样理解: 假设在 t_m 时刻, 我们已经得到了对系统状态的 WLS 估计 $\hat{\mathbf{x}}_m$, 同时也得到了估计误差方差矩阵 $\mathbf{P}_m$ 。在 t_{m+1} 时刻, 新的观测量 $\tilde{\mathbf{y}}_{m+1}$ 到来, 同时到来的还有新观测量的系统转移矩阵 $\mathbf{A}_{m+1}$ 和观测噪声方差 R_{m+1} 。首先根据式(7.105)计算出 $\mathbf{P}_{m+1}$, 然后利用 $\mathbf{P}_{m+1}$ 、 $\mathbf{A}_{m+1}$ 和 R_{m+1}^{-1} 根据式(7.109)计算出增益矩阵 $\mathbf{k}_{m+1}$, 然后将观测量残差 $(\tilde{\mathbf{y}}_{m+1} - \hat{\mathbf{y}}_{m+1})$ 和 $\mathbf{k}_{m+1}$ 相乘, 将结果反馈回去更新 $\hat{\mathbf{x}}_m$, 更新后的结果就是在 t_{m+1} 时刻对系统状态的 WLS 估计 $\hat{\mathbf{x}}_{m+1}$ 。而当前时刻的状态估计 $\hat{\mathbf{x}}_{m+1}$ 和估计误差方差矩阵 $\mathbf{P}_{m+1}$ 又作为下一时刻迭代的起点。

整个过程没有从最初的观测量开始, 而是巧妙地利用了上一次估计的结果和本次的观测量。理论上可以证明, 迭代处理的结果和从最初的观测量开始的批处理方式结果是一样的, 但运算量要小得多, 而且对存储空间的开销也要小了很多。

整个过程用示意图的方法用图 7.10 表示出来。图中 $\hat{\mathbf{x}}_m$ 和 $\mathbf{P}_m$ 被保存在本地存储器




图 7.10 递归最小二乘法（RLS）的迭代原理^[21]

中， $\tilde{y}_{m+1}$ 、 $\mathbf{A}_{m+1}$ 和 R_{m+1} 等信息则来自观测量。每次处理的结果要更新 $\hat{\mathbf{x}}_m$ 和 $\mathbf{P}_m$ 。RLS 算法的运算量分析和存储量分析如表 7.4 所示^[21]，其中计算运算量和存储器开销过程中的变量 n 为系统状态参量的个数，即 $\mathbf{x} \in \mathbb{R}^n$ ，观测量为标量，故 $\mathbf{H}_{m+1} \in \mathbb{R}^{1 \times n}$ ， $\tilde{y}_{m+1}$ 和 R_{m+1} 均为标量， $\mathbf{F}_{m+1}$ 实际是一个中间变量矩阵，其物理意义为信息矩阵。

表 7.4 RLS 运算量和存储器开销对比

计算项	FLOPS	暂时存储器	全局存储器
$\mathbf{A}_{m+1}$	0	0	n
$r = \tilde{y}_{m+1} - \mathbf{A}_{m+1} \hat{\mathbf{x}}_m$	n	1	0
$\mathbf{d} = \mathbf{A}_{m+1}^T \mathbf{R}_{m+1}^{-1}$	N	n	0
$\mathbf{F}_{m+1} = \mathbf{F}_m + \mathbf{d} \mathbf{A}_{m+1}$	$\frac{1}{2}(n+1)n$	0	$\frac{1}{2}(n+1)n$
$\mathbf{P}_{m+1} = \mathbf{F}_{m+1}^{-1}$	$n^3 + \frac{1}{2}(n+1)n$	$\frac{1}{2}(n+1)n$	0
$\mathbf{K} = \mathbf{P}_{m+1} \mathbf{d}$	n^2	n	0
$\hat{\mathbf{x}}_{m+1} = \hat{\mathbf{x}}_m + \mathbf{K} r$	n	0	n
总计运算量	$n^3 + 2n^2 + 4n$	$\frac{1}{2}n^2 + \frac{5}{2}n + 1$	$\frac{1}{2}n^2 + \frac{5}{2}n$

由表 7.4 可以看出，RLS 算法所需的运算量和存储器开销只和状态向量的维数 n 有关，所以其开销是一个固定的数目。相对应式(7.100)的批处理方式所需的运算量和存储器开销随着处理时刻的增加而增加，所以当 m 非常大时，系统将不堪重负而濒于崩溃。

最后以一个简单的例子来对 RLS 方法做一个总结，同时让读者更容易理解 RLS 算法的基本思想。

依然用 7.1.2 节最后的例子。在 7.1.2 节我们已经知道，当观测量的噪声功率都

相等时, 即 $\text{var}\{\tilde{y}\} = \sigma^2$, 对它的 WLS 估计就是对所有的观测值 $[\tilde{y}_1, \tilde{y}_2, \dots, \tilde{y}_m]$ 取平均, 即

$$\hat{x}_m = \frac{1}{m} \sum_{i=1}^m \tilde{y}_i, \quad \text{var}\{\delta x\} = \frac{\sigma^2}{m}$$

在 $m+1$ 时刻, 一个新的观测值 $\tilde{y}_{m+1}$ 来到, 则此时新的状态估计为

$$\begin{aligned} \hat{x}_{m+1} &= \frac{1}{m+1} \sum_{i=1}^{m+1} \tilde{y}_i \\ &= \hat{x}_m + \frac{1}{m+1} (\tilde{y}_{m+1} - \hat{x}_m) \end{aligned} \quad (7.111)$$

在上式推导过程中, 将新的状态估计 $\hat{x}_{m+1}$ 写成递推的方式。注意, 这里的递推方式只是批处理方式的一种数学变形, 而非本节所讲述的 RLS 方法。下面将完全从 RLS 算法的原理出发, 推导出相应的状态估计表达式, 并和式(7.111)相比较。

现在考虑从 RLS 的方法。从时刻 0 开始, 观测值为 $\tilde{y}_0$, 观测噪声方差为 $\text{var}\{\tilde{y}_0\} = \sigma^2$, 则此时对 x 的 WLS 估计为 $\hat{x}_0 = \tilde{y}_0$, $P_0 = \text{var}\{\delta \hat{x}_0\} = \sigma^2$ 。

在时刻 1, 观测值 $\tilde{y}_1$ 到来, 根据式(7.105)、式(7.109)和式(7.110)分别得到 P_1 、 K_1 和 $\hat{x}_1$ 如下:

$$\begin{aligned} P_1 &= (P_0^{-1} + A_1 R_1^{-1} A_1)^{-1} = \frac{\sigma^2}{2} \\ K_1 &= P_1 A_1 R_1^{-1} = \frac{1}{2} \\ \hat{x}_1 &= \hat{x}_0 + K_1 (\tilde{y}_1 - A_1 \hat{x}_0) = \hat{x}_0 + \frac{1}{2} (\tilde{y}_1 - \hat{x}_0) \end{aligned}$$

上面各式推导过程中用到了 $A_i = 1, R_i = \sigma^2, \forall i$ 。

继续利用式(7.105)、(7.109)和(7.110)和上一时刻的估计结果 P_m 、 K_m 和 $\hat{x}_m$, 可以得到在后续的 $m+1$ 时刻的 P_{m+1} 、 K_{m+1} 和 $\hat{x}_{m+1}$ 如下:

$$\begin{aligned} P_{m+1} &= (P_m^{-1} + A_{m+1} R_{m+1}^{-1} A_{m+1})^{-1} = \frac{\sigma^2}{m+1} \\ K_{m+1} &= P_{m+1} A_{m+1} R_{m+1}^{-1} = \frac{1}{m+1} \\ \hat{x}_{m+1} &= \hat{x}_m + K_{m+1} (\tilde{y}_{m+1} - A_{m+1} \hat{x}_m) = \hat{x}_m + \frac{1}{m+1} (\tilde{y}_{m+1} - \hat{x}_m) \end{aligned} \quad (7.112)$$

式(7.112)说明: RLS 的结果可以看作对观测值 $\tilde{y}_m$ 的时变低通滤波器, 滤波器系数 $1/(m+1)$ 随时间流逝逐渐变小, 表明系统对本地状态的更新将随着时间的推移而更倾向于保留上一个时刻的估计结果。将式(7.112)和式(7.111)相比较, 可以看出 RLS 的结果和利用批处理的方法得到的结果完全吻合。这印证了如果被正确初始化, RLS 方法和批处理方法有同样的结果, 但显然 RLS 方法比批处理方法的总运算量更小, 存储器开销也更少。

7.2.2 基本的卡尔曼滤波器

RLS 算法巧妙地利用了迭代，从而能基于时刻 t_m 的估计结果和时刻 t_{m+1} 的观测对当前的系统状态进行加权最小二乘估计。所以可以看出：RLS 算法要求系统状态在时刻 t_m 和时刻 t_{m+1} 保持不变，由此递推到未来的所有时刻；RLS 算法要求系统状态必须是常量，否则就不能再用 RLS 算法。而在实际的应用中，系统状态往往需要随着时间而变，此时 RLS 算法就无能为力了。

考虑一个状态时间线性系统，该系统由离散时间差分方程描述如下：

$$\mathbf{x}_m = \Phi_{m-1} \mathbf{x}_{m-1} + \mathbf{G}_{m-1} \mathbf{u}_{m-1} + \mathbf{w}_{m-1} \quad (7.113)$$

$$\mathbf{y}_m = \mathbf{H}_m \mathbf{x}_m + \mathbf{v}_m \quad (7.114)$$

其中， $\mathbf{x}_m$ 是系统状态矢量； Φ_m 是状态转移矩阵； $\mathbf{u}_m$ 是输入信号矢量； $\mathbf{H}_m$ 是系统观测方程； $\mathbf{w}_m$ 和 $\mathbf{v}_m$ 分别是系统处理噪声和观测噪声。式(7.113)被称作状态转移方程，而式(7.114)被称作系统观测方程。

观察者不能直接测量 $\mathbf{x}_m$ ，而只能观测到 $\mathbf{Y}_m$ ，将观测到的 $\mathbf{Y}_m$ 叫作观测量，用 $\tilde{\mathbf{Y}}_m$ 表示以示区分。由于 $\mathbf{w}_m$ 和 $\mathbf{v}_m$ 都是随机变量，所以无法得到其具体数值，而只能对其统计特性进行分析。这里假设 $\mathbf{w}_m$ 和 $\mathbf{v}_m$ 都是白噪声，均值为 0，而且相互独立，即

$$E\{\mathbf{w}\} = 0, \quad E\{\mathbf{w}_j \mathbf{w}_l^T\} = \mathbf{Q} \mathbf{D}_j \delta_{j,l} \quad (7.115)$$

$$E\{\mathbf{v}\} = 0, \quad E\{\mathbf{v}_j \mathbf{v}_l^T\} = \mathbf{R}_j \delta_{j,l} \quad (7.116)$$

$$E\{\mathbf{w}_j \mathbf{v}_l^T\} = 0 \quad (7.117)$$

其中，

$$\delta_{j,l} = \begin{cases} \mathbf{I}, & \text{当 } l = j \\ \mathbf{0}, & \text{当 } l \neq j \end{cases} \quad (7.118)$$

式(7.118)说明了白噪声的典型特点，就是在时间上不相关，由于随机信号的功率谱是其自相关函数的 FFT，则白噪声在频域的特点就是功率谱在整个频率区间上都是常量，这和白光在整个光谱频率区间内功率均匀分布的特点类似。

式(7.115)、式(7.116)和式(7.117)是对于系统噪声的假设，这种假设在理想条件下才成立，实际系统中和这种假设不符的情况主要有两种：① $\mathbf{w}_m$ 和 $\mathbf{v}_m$ 是有色噪声；② $\mathbf{w}_m$ 和 $\mathbf{v}_m$ 相关。这两种情况的处理对策在后面章节介绍，这里为了推导卡尔曼滤波的基本方程，假设式(7.115)、式(7.116)和式(7.117)成立。

假设在时刻 $m-1$ 我们已经有了对于系统状态 $\mathbf{x}_{m-1}$ 的估计 $\hat{\mathbf{x}}_{m-1}$ ，同时也知道了估计误差方差矩阵 $\mathbf{P}_{m-1} = \text{var}\{(\delta \hat{\mathbf{x}}_{m-1})(\delta \hat{\mathbf{x}}_{m-1})^T\}$ ，则在时刻 m ，在已知 $\mathbf{y}_m$ 、 $\mathbf{Q} \mathbf{D}_m$ 和 $\mathbf{R}_m$ 的基础上，如何利用迭代的方法得到对系统状态 $\mathbf{x}_m$ 的估计 $\hat{\mathbf{x}}_m$ ？

在时刻 m ，系统状态 $\mathbf{x}_m$ 发生了变化，但这个变化是由状态转移方程决定，所以首先可以根据式(7.113)来对 $\mathbf{x}_m$ 进行时间预测：

$$\hat{\mathbf{x}}_m^- = \Phi_{m-1} \hat{\mathbf{x}}_{m-1}^+ + \mathbf{G}_{m-1} \mathbf{u}_{m-1} \quad (7.119)$$

这里用上标“-”表示观测量更新之前，用上标“+”表示观测量更新之后，后续内容将沿用同样的表示。一般往往把 $\hat{\mathbf{x}}_m^-$ 叫作 $\hat{\mathbf{x}}_{m-1}^+$ 的时间更新。

由于 $\hat{\mathbf{x}}_{m-1}^+$ 是无偏的，而 $\mathbf{w}_{m-1}$ 均值为 0，所以可以证明 $\hat{\mathbf{x}}_m^-$ 也是无偏的，即

$$\delta \hat{\mathbf{x}}_m^- = \hat{\mathbf{x}}_m^- - \mathbf{x}_m, \text{ 且 } E\{\delta \hat{\mathbf{x}}_m^-\} = \mathbf{0} \quad (7.120)$$

用式(7.113)和式(7.119)相减，得到

$$\delta \hat{\mathbf{x}}_m^- = \Phi_{m-1} \delta \hat{\mathbf{x}}_{m-1}^+ + \mathbf{w}_{m-1} \quad (7.121)$$

将 $\hat{\mathbf{x}}_m^-$ 的估计误差的协方差矩阵记作 $\mathbf{P}_m^-$ ，则

$$\begin{aligned} \mathbf{P}_m^- &= E\{[\delta \hat{\mathbf{x}}_m^-][\delta \hat{\mathbf{x}}_m^-]^T\} \\ &= \Phi_{m-1} E\{[\delta \hat{\mathbf{x}}_{m-1}^+][\delta \hat{\mathbf{x}}_{m-1}^+]^T\} \Phi_{m-1}^T + E\{\mathbf{w}_{m-1} \mathbf{w}_{m-1}^T\} \\ &= \Phi_{m-1} \mathbf{P}_{m-1}^+ \Phi_{m-1}^T + \mathbf{QD}_{m-1} \end{aligned} \quad (7.122)$$

上式的推导用到了式(7.121)，推导过程中的第二步中没有交叉项是因为 $E\{(\delta \hat{\mathbf{x}}_{m-1}^+)(\mathbf{w}_{m-1}^T)\} = \mathbf{0}$ ，这是因为 $\mathbf{w}_{m-1}^T$ 只影响 $\hat{\mathbf{x}}_m^-$ 、 $\mathbf{w}_{m-1}^T$ 和 $\delta \hat{\mathbf{x}}_{m-1}^+$ 不相关，所以 $E\{(\delta \hat{\mathbf{x}}_{m-1}^+)(\mathbf{w}_{m-1}^T)\} = E\{\delta \hat{\mathbf{x}}_{m-1}^+\} E\{\mathbf{w}_{m-1}^T\}$ ，由于 $E\{\mathbf{w}_{m-1}^T\} = \mathbf{0}$ ，所以 $E\{(\delta \hat{\mathbf{x}}_{m-1}^+)(\mathbf{w}_{m-1}^T)\} = \mathbf{0}$ 。

现在我们已经有了对 $\mathbf{x}_m$ 的时间预测估计 $\hat{\mathbf{x}}_m^-$ ，其估计误差协方差矩阵 $\mathbf{P}_m^-$ 也已知，所以可以列出如下类似式(7.102)的方程：

$$\begin{bmatrix} \hat{\mathbf{x}}_m^- \\ \tilde{\mathbf{y}}_m \end{bmatrix} = \begin{bmatrix} \mathbf{I} \\ \mathbf{H}_m \end{bmatrix} \mathbf{x}_m + \begin{bmatrix} \delta \hat{\mathbf{x}}_m^- \\ \mathbf{v}_{m+1} \end{bmatrix} \quad (7.123)$$

分析至此，已经可以很清楚地看出，我们可以直接利用 7.2.1 节中对 RLS 分析的方法，类似于式(7.110)的推导，而得出对 $\mathbf{x}_m$ 的估计 $\hat{\mathbf{x}}_m^+$ ，如下所示：

$$\hat{\mathbf{x}}_m^+ = \hat{\mathbf{x}}_m^- + \mathbf{k}_m (\tilde{\mathbf{y}}_m - \mathbf{H}_m \hat{\mathbf{x}}_m^-) \quad (7.124)$$

式(7.124)中的 $\mathbf{k}_m = \mathbf{P}_m^+ \mathbf{H}_m^T \mathbf{R}_m^{-1}$ ，被称作卡尔曼增益矩阵，用来对观测量残差加权以后再更新 $\hat{\mathbf{x}}_m^-$ 。 $\hat{\mathbf{x}}_m^+$ 是系统状态经过观测量更新以后的值，其误差协方差矩阵为 $\mathbf{P}_m^+$ ，由式(7.106)可知

$$(\mathbf{P}_m^+)^{-1} = (\mathbf{P}_m^-)^{-1} + \mathbf{H}_m^T \mathbf{R}_m^{-1} \mathbf{H}_m \quad (7.125)$$

对 $\mathbf{k}_m$ 的表达式进行直观的分析可知：当观测量包含更大的噪声，即当 $\mathbf{R}_m^{-1}$ 变大时，相应的 $\mathbf{k}_m$ 就变小，表示当前系统更倾向于保持原来的估计结果；反之，当观测量的可信度更大时， $\mathbf{R}_m^{-1}$ 变小，则 $\mathbf{k}_m$ 就变大，系统就允许更多的来自于观测量的更新。由此可见卡尔曼滤波过程其实是一个智能的自适应的调整过程，其对状态参量的估计是基于自身当前状态参量可信度和外界观测量可信度的折中。

基于以上分析，卡尔曼滤波器可以分成两个步骤：第一个步骤是根据系统状态转移方程对系统状态进行时间更新，同时还需要更新状态协方差矩阵；第二步是观测量更新，在观测量到来以后，首先更新状态协方差矩阵，从而算出卡尔曼增益，最后更新系统状态。而当前时刻的系统状态和协方差矩阵又成为下一次迭代的初始条件。作为一个总结，整个过程用下面的公式表示：

$$\hat{\mathbf{x}}_m^- = \Phi_{m-1} \hat{\mathbf{x}}_{m-1}^+ + \mathbf{G}_{m-1} \mathbf{u}_{m-1} \quad (7.126)$$

$$\hat{\mathbf{y}}_m = \mathbf{H}_m \hat{\mathbf{x}}_m^- \quad (7.127)$$

$$\mathbf{P}_m^- = \Phi_{m-1} \mathbf{P}_{m-1}^+ \Phi_{m-1}^T + \mathbf{QD}_{m-1} \quad (7.128)$$

$$(\mathbf{P}_m^+)^{-1} = (\mathbf{P}_m^-)^{-1} + \mathbf{H}_m^T \mathbf{R}_m^{-1} \mathbf{H}_m \quad (7.129)$$

$$\mathbf{k}_m = \mathbf{P}_m^+ \mathbf{H}_m^T \mathbf{R}_m^{-1} \quad (7.130)$$

$$\hat{\mathbf{x}}_m^+ = \hat{\mathbf{x}}_m^- + \mathbf{k}_m (\tilde{\mathbf{y}}_m - \hat{\mathbf{y}}_m) \quad (7.131)$$

式(7.126)~式(7.128)就是时间更新的所有操作, 式(7.129)~式(7.131)就是观测更新的所有操作, 这就是卡尔曼滤波的基本方程。

在上述所有操作中, 式(7.129)是所有操作中对运算量要求最高的一步, 需要先去求矩阵 $\mathbf{P}_m^-$ 的逆, 然后再求 $(\mathbf{P}_m^-)^{-1} + \mathbf{H}_m^T \mathbf{R}_m^{-1} \mathbf{H}_m$ 的逆。矩阵求逆对处理器的运算能力的要求很高, 尤其当矩阵的维度很大时, 所以人们研究出了其他的计算方法。附录A中证明了 $\mathbf{k}_m$ 和 $\mathbf{P}_m^+$ 可以通过下面的方法算出:

$$\mathbf{k}_m = \mathbf{P}_m^- \mathbf{H}_m^T (\mathbf{H}_m \mathbf{P}_m^- \mathbf{H}_m^T + \mathbf{R}_m)^{-1} \quad (7.132)$$

$$\mathbf{P}_m^+ = (\mathbf{I} - \mathbf{k}_m \mathbf{H}_m) \mathbf{P}_m^- \quad (7.133)$$

这里也许会产生疑问: 从式(7.132)看出, 这种变通的方法同样需要求矩阵 $(\mathbf{H}_m \mathbf{P}_m^- \mathbf{H}_m^T + \mathbf{R}_m)$ 的逆, 那么新方法的优势何在呢? 如果我们仔细比较式(7.132)和式(7.129), 就知道原来的方法中需要求 $(\mathbf{P}_m^-)^{-1} + \mathbf{H}_m^T \mathbf{R}_m^{-1} \mathbf{H}_m$ 和 $\mathbf{P}_m^-$ 的逆, 这两个矩阵的维数都是由系统状态向量的维数决定的, 当系统状态参量一定的情况下, 这两个矩阵的维数是不变的; 而式(7.132)需要求 $(\mathbf{H}_m \mathbf{P}_m^- \mathbf{H}_m^T + \mathbf{R}_m)$ 的逆, 而该矩阵的维数由系统观测量的数目决定, 在不同时刻系统观测量的数目可能会不同, 同时由6.2.6节可以看到, 可以利用序贯处理的方式对每一个观测值顺序处理, 此时每次观测值更新只对一个观测值进行处理, 对矩阵求逆就变成了对数值求倒数, 从而减小运算量。

从式(7.126)~式(7.131)也可以推导出卡尔曼滤波的一步预测方程, 即利用 $\hat{\mathbf{x}}_m^-$ 、 $\mathbf{P}_m^-$ 直接计算 $\hat{\mathbf{x}}_{m+1}^-$ 、 $\mathbf{P}_{m+1}^-$ 的方程:

$$\hat{\mathbf{x}}_{m+1}^- = \Phi_m \hat{\mathbf{x}}_m^- + \Phi_m \mathbf{k}_m (\tilde{\mathbf{y}}_m - \mathbf{H}_m \hat{\mathbf{x}}_m^-) + \mathbf{G}_m \mathbf{u}_m \quad (7.134)$$

$$\mathbf{P}_{m+1}^- = \Phi_m (\mathbf{I} - \mathbf{k}_m \mathbf{H}_m) \mathbf{P}_m^- \Phi_m^T + \mathbf{QD}_m \quad (7.135)$$

从上述推导过程可以看出, 由于采用了递推算法, 卡尔曼滤波过程不必把全部观测值存储下来, 节省了存储器开销和运算量。虽然每一次观测值更新只利用了当前时刻的观测值信息, 但系统状态量估计 $\hat{\mathbf{x}}_m^+$ 包含了从初始化时刻开始的全部观测值信息, 随着更新时刻的增加, $\hat{\mathbf{x}}_m^+$ 中包含的信息浓度在不断增加。

卡尔曼滤波的另一个优异特点, 是每一次滤波过程基于前一时刻的系统状态矢量根据系统状态转移矩阵 Φ_m “预测”到当前时刻。这样就允许系统状态矢量在观测过程中非平稳, 整个推导过程中只需要知道系统噪声和观测噪声的统计特性, 而不需要知道被估计量的一阶、二阶矩。所以, 卡尔曼滤波和 RLS 相比, 一个明显优势

就是它可以对非平稳的被估计量进行估计。当然,前提是系统的状态方程是准确已知的,同时系统噪声和观测噪声是平稳白噪声过程,统计特性不随时间而变。

7.2.3 从连续时间系统到离散时间系统

在 7.2.2 节中,所有分析都是基于式(7.113)和式(7.114),而式(7.113)和式(7.114)描述的显然是一个离散时间系统,所有的观测量和状态估计都是基于一定的时间间隔来完成的。在一个实际的离散系统里,该时间间隔往往是一个固定的时钟周期 T_s 。但是在实际世界里,一个线性系统呈现给系统设计者最初的数学模型往往在时间上是连续的,而非离散的,人们将连续时间系统转换为离散时间系统是便于现代计算机处理。所以将连续时间系统转换为离散时间系统是系统设计者一个很重要也是很基础的工作。本节将讲述如何完成这一转换。

考虑一个连续时间线性系统,用下面的状态观测差分方程描述:

$$\dot{\mathbf{x}}(t) = \mathbf{F}(t)\mathbf{x}(t) + \mathbf{G}(t)\mathbf{w}(t) \quad (7.136)$$

$$\mathbf{y}(t) = \mathbf{H}(t)\mathbf{x}(t) + \mathbf{v}(t) \quad (7.137)$$

这里, $\mathbf{x}(t)$ 是 $(n \times 1)$ 维系统状态矢量; $\mathbf{F}(t)$ 是 $(n \times n)$ 的状态转移矩阵; $\mathbf{G}(t)$ 是 $(n \times l)$ 输入转换矩阵 (l 为输入变量的维数); $\mathbf{y}(t)$ 是 $(m \times 1)$ 的观测矢量 (m 为观测量的个数); $\mathbf{H}(t)$ 是 $(m \times n)$ 的观测矩阵。这个系统的系统处理噪声和观测噪声分布为随机过程 $\mathbf{w}(t)$ 和随机过程 $\mathbf{v}(t)$ 。以上所有变量均为连续时间范畴。

式(7.136)和式(7.137)分别对应式(7.113)和式(7.114),为了简化,这里省去了输入变量 $\mathbf{u}(t)$ 。

对随机变量 $\mathbf{w}(t)$ 和 $\mathbf{v}(t)$ 的合理假设可以认为它们都是白噪声,均值为 0,方差已知,并且相互独立,即

$$E\{\mathbf{w}(t)\} = 0, \quad \text{var}\{\mathbf{w}(t)\mathbf{w}(t+\tau)^T\} = \mathbf{Q}(t)\delta(\tau) \quad (7.138)$$

$$E\{\mathbf{w}(t)\} = 0, \quad \text{var}\{\mathbf{w}(t)\mathbf{w}(t+\tau)^T\} = \mathbf{Q}(t)\delta(\tau) \quad (7.139)$$

$$E\{\mathbf{w}(t)\mathbf{v}(t+\tau)^T\} = \mathbf{0} \quad (7.140)$$

上式中的 $\delta(\tau)$ 是狄拉克函数,即式(7.115)和式(7.116)中的 $\delta_{j,i}$ 在连续时间域的表达方式。

由线性系统的知识可知,如果有一个 $(n \times n)$ 的矩阵 $\Phi(t)$, 满足条件

$$\Phi(0) = \mathbf{I}, \quad \text{并且} \quad \dot{\Phi}(t) = \mathbf{F}(t)\Phi(t), \quad \forall t > 0$$

则

$$\mathbf{x}(t) = \Phi(t, t_0)\mathbf{x}(t_0) + \int_{t_0}^t \Phi(t, \lambda)\mathbf{G}(\lambda)\mathbf{w}(\lambda)d\lambda \quad (7.141)$$

其中, $\Phi(t, t_0) = \Phi(t)\Phi^{-1}(t_0)$, 叫作连续时间上的状态转移矩阵,该矩阵揭示了系统状态从时刻 t_0 到时刻 (t) 的转换关系。很容易验证, $\Phi(t, t_0)$ 有如下的性质:

$$\Phi(t, t) = \mathbf{0} \quad (7.142)$$

$$\Phi(t, t_0) = \Phi^{-1}(t_0, t) \quad (7.143)$$

$$\Phi(t, \alpha)\Phi(\alpha, t_0) = \Phi(t, t_0) \quad (7.144)$$

$$\frac{d\Phi(t, t_0)}{dt} = \mathbf{F}(t)\Phi(t, t_0) \quad (7.145)$$

$$\frac{d\Phi(t, t_0)}{dt_0} = -\Phi(t, t_0)\mathbf{F}(t) \quad (7.146)$$

为了验证式(7.141)的确满足式(7.136), 我们将式(7.141)对时间 t 求导, 得到

$$\begin{aligned} \dot{\mathbf{x}}(t) &= \frac{d}{dt}(\Phi(t, t_0)\mathbf{x}(t_0)) + \frac{d}{dt}\left(\int_{t_0}^t \Phi(t, \lambda)\mathbf{G}(\lambda)\mathbf{w}(\lambda)d\lambda\right) \\ &= \mathbf{F}(t)\Phi(t, t_0)\mathbf{x}(t_0) + \int_{t_0}^t \mathbf{F}(t)\Phi(t, \lambda)\mathbf{G}(\lambda)\mathbf{w}(\lambda)d\lambda + \Phi(t, t)\mathbf{G}(t)\mathbf{w}(t) \\ &= \mathbf{F}(t)(\Phi(t, t_0)\mathbf{x}(t_0) + \int_{t_0}^t \Phi(t, \lambda)\mathbf{G}(\lambda)\mathbf{w}(\lambda)d\lambda) + \mathbf{G}(t)\mathbf{w}(t) \\ &= \mathbf{F}(t)\mathbf{x}(t) + \mathbf{G}(t)\mathbf{w}(t) \end{aligned}$$

在 $\mathbf{F}(t)$ 是常量的情况下,

$$\begin{aligned} \Phi(t) &= e^{\mathbf{F}t} \Rightarrow \\ \Phi(t, t_0) &= e^{\mathbf{F}\Delta t}, \text{ 这里 } \Delta t = t - t_0 \end{aligned} \quad (7.147)$$

在工程实际中, $\mathbf{F}(t)$ 往往是个变量, 此时一个近似的方法就是把 $[t_0, t]$ 划分成若干个小的时间段, 比如 $[t_0, t_1, t_2, \dots, t_N]$, 这里 $t_N = t$ 。在每个小时间段 $t \in [t_i, t_{i+1})$ 内, 可以认为 $\mathbf{F}(t) = \mathbf{F}_i$ 是个常量, 则 $\Phi(t_i, t_{i+1}) = e^{\mathbf{F}_i \delta t_i}$, 此处 $\delta t_i = t_{i+1} - t_i$ 。于是在整个时间段 $[t_0, t]$,

$$\Phi(t, t_0) \approx \prod_{i=0}^N e^{\mathbf{F}_i \delta t_i}, i = 0, 1, \dots, N \quad (7.148)$$

式(7.148)的计算步骤可以用图 7.11 表示出来, 图中把 $[t_0, t]$ 划分成 N 个小时时间段, 每一个时间段内可以把 $\mathbf{F}(t)$ 近似认为是常量, 从而可以对每一个时间段按照式(7.147)计算 Φ_i , 则整个时间跨度内的总的 $\Phi(t, t_0) = \Phi_0 \Phi_1 \dots \Phi_{N-1}$ 。



图 7.11 计算 $\Phi(t, t_0)$ 的近似方法

现在考虑离散时间系统。离散时间系统的所有更新都发生在一定时间间隔 T_s 的时刻。如果 T_s 比较小, 可以假设 $\mathbf{F}(t)$ 是不变的, 这个假设在后面的分析中将会大大简化分析。于是在时刻 t_k 和 t_{k+1} 的状态矢量有如下关系:

$$\mathbf{x}(t_{k+1}) = e^{\mathbf{F}T_s} \mathbf{x}(t_k) + \int_{t_k}^{t_{k+1}} e^{\mathbf{F}(t_k - \lambda)} \mathbf{G}(\lambda)\mathbf{w}(\lambda)d\lambda \quad (7.149)$$

从式(7.149)可以看出, 经过从时刻 t_0 到 t 的状态转化, 输入的噪声变量也变为

$$\mathbf{w}_d = \int_{t_k}^{t_{k+1}} \mathbf{e}^{F T_s} \mathbf{G}(\lambda) \mathbf{w}(\lambda) d\lambda \quad (7.150)$$

基于 $\mathbf{w}(t)$ 是白噪声过程的假设, $\mathbf{w}_d$ 的协方差矩阵可以计算如下:

$$\begin{aligned} QD_w &= E\{\mathbf{w}_d \mathbf{w}_d^T\} \\ &= E\left\{\int_{t_k}^{t_{k+1}} \int_{t_k}^{t_{k+1}} \mathbf{e}^{F(\lambda-t_k)} \mathbf{G}(\lambda) \mathbf{w}(\lambda) \mathbf{w}^T(\beta) \mathbf{G}^T(\beta) (\mathbf{e}^{F(\beta-t_k)})^T d\lambda d\beta\right\} \\ &= \int_{t_k}^{t_{k+1}} \mathbf{e}^{F(\lambda-t_k)} \mathbf{G}(\lambda) \mathbf{Q}(\lambda) \mathbf{G}^T(\lambda) (\mathbf{e}^{F(\lambda-t_k)})^T d\lambda \end{aligned} \quad (7.151)$$

对式(7.151)的一个粗略的近似是

$$QD_w \approx \mathbf{G} \mathbf{Q} \mathbf{G}^T T_s \quad (7.152)$$

这里假设 T_s 足够小, 以至于 $\mathbf{e}^{F(\lambda-t_k)} \approx \mathbf{I}$, $\forall \lambda \in [t_k, t_{k+1})$ 。对式(7.151)的更精确的近似是先利用泰勒级数展开 $\mathbf{e}^{F(\lambda-t_k)}$, 即

$$\mathbf{e}^{FT} = \mathbf{I} + \mathbf{F}T + \frac{1}{2!} \mathbf{F}^2 T^2 + \frac{1}{3!} \mathbf{F}^3 T^3 + \dots$$

然后代入式(7.151)得到

$$\begin{aligned} QD_w &\approx \mathbf{Q}_G T + (\mathbf{F} \mathbf{Q}_G + \mathbf{Q}_G \mathbf{F}^T) \frac{T^2}{2!} + \\ &\quad (\mathbf{F}^2 \mathbf{Q}_G + 2\mathbf{F} \mathbf{Q}_G \mathbf{F}^T + \mathbf{Q}_G (\mathbf{F}^T)^2) \frac{T^3}{3!} + \dots \end{aligned} \quad (7.153)$$

其中, $\mathbf{Q}_G = \mathbf{G} \mathbf{Q} \mathbf{G}^T$ 。这里只展开到泰勒级数的第 3 项, 更高项读者可以自行展开。

至此, 我们已经明白了从连续时间系统到离散时间系统的转换, 包括系统状态的转换和输入噪声变量的协方差矩阵的转换。下面将用一个在北斗 / GPS 接收机中经常使用的例子来帮助读者深化对这一节的理解。

考虑一个两个状态的线性系统, 状态矢量 $\mathbf{x} = [x_1, x_2]^T$, 输入噪声矢量 $\mathbf{w} = [w_1, w_2]^T$, 其连续时间状态方程为

$$\begin{bmatrix} \dot{x}_1 \\ \dot{x}_2 \end{bmatrix} = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + \begin{bmatrix} w_1 \\ w_2 \end{bmatrix} \quad (7.154)$$

式(7.154)中的状态矢量可以适用于接收机中的位置和速度, 即 $[P, v]^T$, 或者钟差和钟漂 $[b, \dot{b}]^T$ 。注意, 这里 P 和 v 是一维的, 多维的可以类似处理。 $[w_1, w_2]^T$ 作为系统的输入, 被称作 $[x_1, x_2]^T$ 的系统处理噪声。

假设 $\text{var}\{w_1(t)\} = S_1$, $\text{var}\{w_2(t)\} = S_2$, 那么就有

$$\mathbf{Q}(t) = \begin{bmatrix} S_1 & 0 \\ 0 & S_2 \end{bmatrix} \quad (7.155)$$

同时由式(7.154)可知

$$\mathbf{F}(t) = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}, \quad \mathbf{G}(t) = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \quad (7.156)$$

可见 $\mathbf{F}(t)$ 和 $\mathbf{G}(t)$ 都是常量。稍作演算, 可以证明 $\mathbf{F}^n = \mathbf{0}$, $n \geq 2$, 这个性质将简化后面的推导。

根据式(7.147)可知,

$$\begin{aligned} \Phi(t, t_0) &= e^{\mathbf{F}(t-t_0)} \\ &= \mathbf{I} + \mathbf{F}(t-t_0) \\ &= \begin{bmatrix} 1 & (t-t_0) \\ 0 & 1 \end{bmatrix} \end{aligned} \quad (7.157)$$

上式第二行是用泰勒级数将 $e^{\mathbf{F}(t-t_0)}$ 展开, 并利用了 $\mathbf{F}^n = \mathbf{0}, n \geq 2$ 。

根据式(7.153)可以得到 $\mathbf{QD}_w$:

$$\begin{aligned} \mathbf{QD}_w &\approx \mathbf{Q}_G \Delta t + (\mathbf{FQ}_G + \mathbf{Q}_G \mathbf{F}^T) \frac{\Delta t^2}{2!} + 2\mathbf{FQ}_G \mathbf{F}^T \frac{\Delta t^3}{3!} \\ &= \begin{bmatrix} S_1 \Delta t + S_2 \frac{\Delta t^3}{3} & S_2 \frac{\Delta t^2}{2} \\ S_2 \frac{\Delta t^2}{2} & S_2 \Delta t \end{bmatrix} \end{aligned} \quad (7.158)$$

这里 $\Delta t = (t - t_0)$ 。

于是该系统的离散时间表示就为

$$\begin{bmatrix} x_1(k) \\ x_2(k) \end{bmatrix} = \begin{bmatrix} 1 & T_s \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x_1(k-1) \\ x_2(k-1) \end{bmatrix} + \begin{bmatrix} w_1(k-1) \\ w_2(k-1) \end{bmatrix} \quad (7.159)$$

这里 T_s 即为两次采样之间的时间间隔, 而

$$E \begin{bmatrix} w_1(k-1) \\ w_2(k-1) \end{bmatrix} [w_1(k-1), w_2(k-1)] = \mathbf{QD}_w \quad (7.160)$$

上式中 $\mathbf{QD}_w$ 由式(7.158)计算得到。

7.2.4 扩展卡尔曼滤波器

前面几节描述的卡尔曼滤波器都是基于线性系统的, 但在实际应用中往往不能保证系统状态方程或观测方程都是线性的, 在这种情况下, 常规的线性卡尔曼滤波器就不适用了。对这种非线性系统运用卡尔曼滤波之前, 往往要先对其进行线性化处理, 才能继续沿用常规线性卡尔曼滤波的方法。人们把这类卡尔曼滤波叫作扩展的卡尔曼滤波器 (Extended Kalman Filter, EKF)。

假设一个非线性系统用如下差分方程描述:

$$\dot{\mathbf{x}}(t) = \mathbf{f}(\mathbf{x}, \mathbf{u}, t) + \mathbf{g}(\mathbf{x}, t) \mathbf{w}(t) \quad (7.161)$$

$$\mathbf{y}(t) = \mathbf{h}(\mathbf{x}, t) + \mathbf{v}(t) \quad (7.162)$$

式(7.161)是系统状态转移方程, 式(7.162)是观测方程, $\mathbf{f}(\mathbf{x}, \mathbf{u}, t)$ 是关于系统状态 $\mathbf{x}$ 、输入量 $\mathbf{u}$ 和 t 的非线性方程, $\mathbf{h}(\mathbf{x}, t)$ 是关于 $\mathbf{x}$ 、 t 的非线性方程, $\mathbf{w}(t)$ 和 $\mathbf{v}(t)$ 分别是在连续时间域的处理噪声和观测噪声。

假设系统在时刻 t 的状态 $\mathbf{x}(t)$ 是未知的, 但我们知道其大致范围, 则可以选定一个值 $\mathbf{x}^*(t)$, 于是只要得到了对 $\delta\mathbf{x}(t) = \mathbf{x}(t) - \mathbf{x}^*(t)$ 的估计, 那么就可以修正 $\mathbf{x}^*(t)$, 从而得到对 $\mathbf{x}(t)$ 的更准确的估计。

在选取 $\mathbf{x}^*(t)$ 的时候, 需要保证以下关系式成立:

$$\dot{\mathbf{x}}^*(t) = \mathbf{f}(\mathbf{x}^*, \mathbf{u}, t) \quad (7.163)$$

$$\mathbf{y}^*(t) = \mathbf{h}(\mathbf{x}^*, t) \quad (7.164)$$

于是用式(7.161)和式(7.163)相减, 式(7.162)和式(7.164)相减, 并用泰勒级数展开, 略去高阶项, 得到

$$\delta\dot{\mathbf{x}}(t) = \mathbf{F}(t)\delta\mathbf{x}(t) + \mathbf{g}(\mathbf{x}, t)\mathbf{w}(t) \quad (7.165)$$

$$\delta\mathbf{y}(t) = \mathbf{H}(t)\delta\mathbf{x}(t) + \mathbf{v}(t) \quad (7.166)$$

其中,

$$\mathbf{F}(t) = \left. \frac{\partial \mathbf{f}(\mathbf{x}, \mathbf{u}, t)}{\partial \mathbf{x}} \right|_{\mathbf{x}=\mathbf{x}^*}, \quad \mathbf{H}(t) = \left. \frac{\partial \mathbf{h}(\mathbf{x}, t)}{\partial \mathbf{x}} \right|_{\mathbf{x}=\mathbf{x}^*}$$

式(7.165)和式(7.166)与线性卡尔曼滤波的状态方程和观测方程一致, 所以能遵循 7.2.2 节的步骤非常类似的方法来实现卡尔曼滤波, 不同之处只在于系统状态的时间更新和观测量的预测。同时需要注意的是, 式(7.165)和式(7.166)只在当 $\mathbf{x}^*(t)$ 和系统的真实状态接近时才适用, 当 $\mathbf{x}^*(t)$ 和真实的状态相差太大时, 根据一阶泰勒级数展开结果的线性化就有较大的误差了。所以在用卡尔曼滤波完成对 $\delta\mathbf{x}(t)$ 的估计以后, 对 $\mathbf{x}^*(t)$ 及时更新就显得非常重要。

结合以上分析和常规的线性卡尔曼滤波的原理, 扩展卡尔曼滤波器的基本步骤如下所述。

1. 对系统状态进行时间更新

假设在时刻 t_k 的系统状态的估计是 $\hat{\mathbf{x}}_{k|k}$, 根据式 $\dot{\mathbf{x}}^*(t) = \mathbf{f}(\mathbf{x}^*, \mathbf{u}, t)$, 将 $\hat{\mathbf{x}}_{k|k}$ 带入, 得到 $\dot{\mathbf{x}}^*(t)|_{\hat{\mathbf{x}}_{k|k}}$, 对其在时间 $[t_k, t_{k+1})$ 上积分, 得到 $\hat{\mathbf{x}}_{k+1|k}$, 即

$$\hat{\mathbf{x}}_{k+1|k} = \hat{\mathbf{x}}_{k|k} + \int_{t_k}^{t_{k+1}} \dot{\mathbf{x}}^*(t)|_{\hat{\mathbf{x}}_{k|k}} dt \quad (7.167)$$

2. 计算观测量残差

根据第 1 步得到的 $\hat{\mathbf{x}}_{k+1|k}$ 计算预测的观测量:

$$\hat{\mathbf{y}}_{k+1} = \mathbf{h}(\hat{\mathbf{x}}_{k+1|k}, t_{k+1}) \quad (7.168)$$

进而计算实际观测量和预测的观测量之间的观测量残差:

$$\mathbf{z}_{k+1} = \tilde{\mathbf{y}}_{k+1} - \hat{\mathbf{y}}_{k+1} \quad (7.169)$$

从这一步可以看出, 观测量的预测 $\hat{\mathbf{y}}_{k+1}$ 是通过非线性方程基于状态量的预测 $\hat{\mathbf{x}}_{k+1|k}$ 得到的。

3. 对误差协方差矩阵 $\mathbf{P}_{k|k}$ 和误差状态 $\delta\hat{\mathbf{x}}_{k|k}$ 进行时间更新

将第1步得到的 $\hat{\mathbf{x}}_{k+1|k}$ 带入 $\mathbf{F}(t) = \frac{\partial \mathbf{f}}{\partial \mathbf{x}}$, 得到在 t_{k+1} 时刻的 $\mathbf{F}(t)|_{\hat{\mathbf{x}}_{k+1|k}}$ 矩阵, 然后再利用 7.2.3 节中的方法计算 Φ_k 和 $\mathbf{QD}_w$, 对 $\mathbf{P}_{k|k}$ 和 $\delta\hat{\mathbf{x}}_{k|k}$ 进行时间更新得到

$$\delta\hat{\mathbf{x}}_{k+1|k} = \Phi_k \delta\hat{\mathbf{x}}_{k|k} = \Phi_k \mathbf{0} = \mathbf{0} \quad (7.170)$$

$$\mathbf{P}_{k+1|k} = \Phi_k \mathbf{P}_{k|k} \Phi_k^T + \mathbf{QD}_w \quad (7.171)$$

这里 $\delta\hat{\mathbf{x}}_{k|k} = \mathbf{0}$ 的原因在下面第6步中解释。

4. 对观测量在 t_{k+1} 时刻进行线性化并计算卡尔曼增益矩阵 $\mathbf{k}_{k+1}$

将观测量方程 $\mathbf{h}(\mathbf{x}^*, t)$ 在 $\hat{\mathbf{x}}_{k+1|k}$ 处线性化, 得到 $\mathbf{H}_{k+1} = \left. \frac{\partial \mathbf{h}}{\partial \mathbf{x}} \right|_{\hat{\mathbf{x}}_{k+1|k}}$, 于是卡尔曼增益

矩阵为

$$\mathbf{k}_{k+1} = \mathbf{P}_{k+1|k} \mathbf{H}_{k+1}^T [\mathbf{H}_{k+1} \mathbf{P}_{k+1|k} \mathbf{H}_{k+1}^T + \mathbf{R}_{k+1}]^{-1} \quad (7.172)$$

5. 对误差状态 $\delta\hat{\mathbf{x}}_{k+1|k}$ 进行观测量更新

$$\begin{aligned} \delta\hat{\mathbf{x}}_{k+1|k+1} &= \delta\hat{\mathbf{x}}_{k+1|k} + \mathbf{k}_{k+1} \mathbf{z}_{k+1} \\ &= \mathbf{k}_{k+1} \mathbf{z}_{k+1} \end{aligned} \quad (7.173)$$

这里 $\delta\hat{\mathbf{x}}_{k+1|k}$ 是第3步中对误差状态 $\delta\hat{\mathbf{x}}_{k|k}$ 的时间更新。

6. 更新系统状态 $\hat{\mathbf{x}}_{k+1|k+1}$ 和 $\mathbf{P}_{k+1|k+1}$

现在得到了观测量更新以后的误差状态 $\delta\hat{\mathbf{x}}_{k+1|k+1}$, 而在第1步已经得到了系统状态的时间更新 $\hat{\mathbf{x}}_{k+1|k}$, 所以可以对 $\hat{\mathbf{x}}_{k+1|k}$ 进行观测量更新:

$$\hat{\mathbf{x}}_{k+1|k+1} = \hat{\mathbf{x}}_{k+1|k} + \delta\hat{\mathbf{x}}_{k+1|k+1} \quad (7.174)$$

在这一步更新以后, $\hat{\mathbf{x}}_{k+1|k+1} = E\{\mathbf{x}(t_{k+1})\}$, 所以 $\delta\hat{\mathbf{x}}_{k+1|k+1}$ 中包含的新的信息已经使用了, 因此需要置 $\delta\hat{\mathbf{x}}_{k+1|k+1} = \mathbf{0}$, 这也解释了为什么在第3步中 $\delta\hat{\mathbf{x}}_{k|k} = \mathbf{0}$ 的原因。

与此同时, 需要更新误差协方差矩阵:

$$\mathbf{P}_{k+1|k+1} = (\mathbf{I} - \mathbf{k}_{k+1} \mathbf{H}_{k+1}) \mathbf{P}_{k+1|k} \quad (7.175)$$

上述第1~3步为时间更新, 第4~6步为观测量更新。每次处理的结果 $\mathbf{P}_{k+1|k+1}$ 和 $\hat{\mathbf{x}}_{k+1|k+1}$ 被保存下来, 作为下一次迭代的起始条件。

在式(7.174)中, 通过观测量残差和卡尔曼增益矩阵得到对系统状态误差的估计,

用这个估计对系统全状态的时间更新 $\hat{\mathbf{x}}_{k+1|k}$ 进行修正, 这是非常关键的一步。只有在这个更新以后, 才能将 $\delta\hat{\mathbf{x}}_{k+1|k+1}$ 置 0, 同时这一步也保证了系统状态 $\hat{\mathbf{x}}_{k+1|k+1}$ 一直处于系统真实状态的临近值域附近, 从而保证后续线性化的正确性。

在 GPS 接收机中, 伪距观测量是系统状态的非线性函数, 所以本节所讲述的扩展卡尔曼滤波器在现代 GPS 接收机中得到了广泛的应用, 在北斗 / GPS 双模接收机中, 双模观测量比单 GPS 伪距观测量稍微复杂一些, 但上述的扩展卡尔曼滤波原理是一样的。7.2.5 节将对接收机内常用的几种卡尔曼滤波器的模型进行分析, 并结合本节的步骤具体分析如何实现扩展卡尔曼滤波器。

7.2.5 接收机中常用的几种 KF 模型

1. 静止用户: P 模型

当接收机处于静态的时候, 因为速度恒定为 0, 所以只需要把位置坐标和时钟作为系统状态, 即 $\mathbf{x} = [\mathbf{x}_p^T, \mathbf{x}_c^T]^T$, 这里位置状态向量 $\mathbf{x}_p = [x, y, z]^T$, 时钟状态向量 $\mathbf{x}_c = [b, d]^T$, b 为本地钟差, d 为本地钟漂。因为一般来说, 时钟向量必须被包括在系统状态中, 为了突出 $\mathbf{x}_p$, 所以这种 KF 模型被称作 P 模型。

在 P 模型中, 位置状态被认为是随机游走过程。P 模型的系统状态方程为

$$\begin{aligned} \dot{\mathbf{x}} &= \begin{bmatrix} 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix} \mathbf{x} + \begin{bmatrix} w_x \\ w_y \\ w_z \\ w_b \\ w_d \end{bmatrix} \end{aligned} \quad (7.176)$$

其中, $\mathbf{w}_p = \begin{bmatrix} w_x \\ w_y \\ w_z \end{bmatrix}$, $\mathbf{w}_c = \begin{bmatrix} w_b \\ w_d \end{bmatrix}$ 分别是位置的处理噪声向量和时钟的处理噪声向量。

由第 5 章可知, 观测量包括伪距观测量和多普勒观测量。在 P 模型中, 由于系统状态不包括速度向量, 一般选用伪距观测量就足够了。如果需要使用多普勒观测量, 需要将其速度分量置 0。单模伪距观测量的观测方程为

$$\rho_i = \sqrt{(x - x_{si})^2 + (y - y_{si})^2 + (z - z_{si})^2} + cb + n_i, \quad i=1, \dots, m \quad (7.177)$$

上式中 c 为光速, $[x_{si}, y_{si}, z_{si}]^T$ 为卫星的位置, n_i 为伪距噪声。如果是北斗和 GPS 双模接收机, 并且采用把 T_{GB} 看作待估的系统状态量的方法, 则 GPS 和北斗伪距观测量的观测方程为

$$\tilde{\rho}_{Gi} = \sqrt{(x_u - x_{Gsi})^2 + (y_u - y_{Gsi})^2 + (z_u - z_{Gsi})^2} + cb + n_{\rho_{Gi}} \quad (7.178)$$

$$\tilde{\rho}_{Bi} = \sqrt{(x_u - x_{Bs_i})^2 + (y_u - y_{Bs_i})^2 + (z_u - z_{Bs_i})^2} + cb + cT_{GB} + n_{\rho_{Bi}} \quad (7.179)$$

同时需要将系统状态方程调整为

$$\begin{aligned} \dot{\mathbf{x}} &= \begin{bmatrix} 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \\ T_{GB} \\ b \\ d \end{bmatrix} + \begin{bmatrix} w_x \\ w_y \\ w_z \\ w_T \\ w_b \\ w_d \end{bmatrix} \end{aligned} \quad (7.180)$$

式(7.180)和式(7.176)的区别在于系统状态量中多了 T_{GB} ，同时处理噪声向量中多了 w_T ，即 T_{GB} 也被建模成随机游走过程，由于 T_{GB} 随时间变化很小，所以可以把 Q 矩阵中对应 w_T 的方差项设置为很小的值。

多普勒观测量的观测方程为

$$f'_{d_i} = cd + v_i, \quad i=1, \dots, m \quad (7.181)$$

这里 $f'_{d_i}, i=1, \dots, m$ ，是式(7.68)中的线性化的多普勒观测量，即从伪码跟踪环的 NCO 得到的多普勒频移再减去卫星速度在方向余弦上的投影分量， c 为光速。由于接收机速度为 0，所以式(7.68)中的 $H\mathbf{x}_v$ 只剩下钟漂项。

2. 低动态用户：PV 模型

当用户处于一种低动态运动的环境中时，就应该采用 PV 模型。这种模型应用的场合包括平稳驾驶的车船、步行者等。在这种模型中，速度分量被认为是随机游走过程，而位置分量是速度分量的积分，时钟模型保持不变。系统状态向量 $\mathbf{x} = [\mathbf{x}_p^T, \mathbf{x}_v^T, \mathbf{x}_c^T]^T$ ，其中 $\mathbf{x}_v = [v_x, v_y, v_z]^T$ 是速度状态向量， $\mathbf{x}_p$ 和 $\mathbf{x}_c$ 的含义保持不变。

PV 模型的系统状态方程为

$$\begin{aligned} \dot{\mathbf{x}} &= \begin{bmatrix} 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \\ v_x \\ v_y \\ v_z \\ b \\ d \end{bmatrix} + \begin{bmatrix} w_x \\ w_y \\ w_x \\ w_{v_x} \\ w_{v_y} \\ w_{v_z} \\ w_b \\ w_d \end{bmatrix} \end{aligned} \quad (7.182)$$

这里 $\mathbf{w}_v = [w_{v_x}, w_{v_y}, w_{v_z}]^T$ ，是速度状态的处理噪声向量。位置状态和时钟状态的处理噪声向量 $\mathbf{w}_p$ 和 $\mathbf{w}_c$ 与 P 模型中的定义一样。在 PV 模型中，可以认为位置状态的处理噪声向量 $\mathbf{w}_p = \mathbf{0}$ ，即认为位置状态没有处理噪声，此时位置状态可以由速度

状态的积分完美地决定。

单模的伪距观测量和 P 模型相比没有变化, 北斗和 GPS 双模伪距观测量和式(7.178)、式(7.179)一样, 而系统状态方程变为式(7.184), 可以看出双模系统状态多出了 T_{GB} 一项, T_{GB} 也被建模成随机游走过程, 由于 T_{GB} 随时间变化很小, 所以可以把 Q 矩阵中对应 w_T 的方差项设置为很小的值。需要注意的是, 如果采用通过系统设置来读取 T_{GB} 的方案, 则系统状态方程中不包含 T_{GB} , 系统状态方程采取式(7.182)的形式, 此时双模伪距观测量的数学模型均采取式(7.177)的形式。

PV 模型下的多普勒观测量和式(7.181)不同, 由于此时速度状态向量不为 $\mathbf{0}$, 则多普勒观测量采取式(7.183)的形式:

$$f'_{d-i} = h_{x-i}v_x + h_{y-i}v_y + h_{z-i}v_z + cd + v_i, \quad i=1, \dots, m \quad (7.183)$$

$$\begin{array}{cccccccccccc} \dot{x} & 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & x & w_x \\ \dot{y} & 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & y & w_y \\ \dot{z} & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 & z & w_x \\ \dot{v}_x & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & v_x & w_{v_x} \\ \dot{v}_y & = & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & v_y & + & w_{v_y} \\ \dot{v}_z & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & v_z & w_{v_z} \\ \dot{T}_{GB} & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & T_{GB} & w_T \\ \dot{b} & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & b & w_b \\ \dot{d} \downarrow & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & d \downarrow & w_d \downarrow \end{array} \quad (7.184)$$

式(7.183)中方向余弦矢量 $\mathbf{H} = [h_{x-i}, h_{y-i}, h_{z-i}]^T$ 和 7.1.3 节中的定义一样。因为此时速度向量不再是 $\mathbf{0}$, 所以多普勒观测方程中相对应的矩阵元素也不再是 0。

3. 高动态用户: PVA 模型

在某些应用场合, 用户的运动加速度变化范围很大, 比如高速飞行器, 此时就需要将三个加速度分量加进系统状态向量内, 这种模型就叫作 PVA 模型。和 PV 模型相比, PVA 模型多了三个加速度分量, 同时多了一项时钟高阶项。因为 PVA 模型的状态分量比较多, 为了表述的简洁, 下面的公式中将采用分块矩阵的表现形式。

PVA 模型中的系统状态向量 $\mathbf{x} = [\mathbf{x}_p^T, \mathbf{x}_v^T, \mathbf{x}_a^T, \mathbf{x}_c^T]^T$ 。其中, $\mathbf{x}_p$ 、 $\mathbf{x}_v$ 、 $\mathbf{x}_c$ 分别是位置状态向量、速度状态向量和时钟状态向量; $\mathbf{x}_p$ 和 $\mathbf{x}_v$ 的定义与 PV 模型中的定义一样, $\mathbf{x}_a = [a_x, a_y, a_z]^T$ 是新加进去的加速度状态向量。此时 $\mathbf{x}_c$ 包含三个量, 分别是钟偏、钟漂和钟漂加速度, 即 $\mathbf{x}_c = [b, d, j]^T$, 其中 j 是钟漂的加速度, 可以把 j 建模为随机游走过程, 则 $\mathbf{x}_c$ 满足以下方程:

$$\dot{\mathbf{x}}_c = \mathbf{F}_c \mathbf{x}_c + \mathbf{w}_c \quad (7.185)$$

$$\begin{array}{ccc} 0 & 1 & 0 \\ \text{其中, } F_c = & 0 & 0 & 1 \\ 0 & 0 & 0 \end{array} \quad \begin{array}{c} w_b \\ w_d \\ w_j \end{array}$$

在 PVA 模型中, 位置状态是速度状态的积分, 速度状态是加速度状态的积分, 加速度状态可以用一阶马尔可夫过程来近似, 即

$$\begin{aligned} \dot{\mathbf{x}}_p &= \mathbf{x}_v \\ \dot{\mathbf{x}}_v &= \mathbf{x}_a \\ \dot{\mathbf{x}}_a &= \mathbf{D}\mathbf{x}_a \end{aligned} \quad (7.186)$$

这里 $\mathbf{D} = \text{diag} \left[-\frac{1}{\tau_x}, -\frac{1}{\tau_y}, -\frac{1}{\tau_z} \right]$, 为一个对角线矩阵。 τ_x 、 τ_y 、 τ_z 分别是三个加

速度各自的时间相关常数。

综合以上分析, PVA 模型的系统状态方程可以写为

$$\begin{array}{cccccc} \dot{\mathbf{x}}_p & \mathbf{0} & \mathbf{I} & \mathbf{0} & \mathbf{0} & \mathbf{x}_p & \mathbf{w}_p \\ \dot{\mathbf{x}}_v & \mathbf{0} & \mathbf{0} & \mathbf{I} & \mathbf{0} & \mathbf{x}_v & \mathbf{w}_v \\ \dot{\mathbf{x}}_a & \mathbf{0} & \mathbf{0} & \mathbf{D} & \mathbf{0} & \mathbf{x}_a & \mathbf{w}_a \\ \dot{\mathbf{x}}_c \end{array} = \begin{array}{cccccc} & & & & & & \\ & & & & & & \\ & & & & & & \\ & \mathbf{0} & \mathbf{0} & \mathbf{0} & F_c \end{array} \begin{array}{c} \mathbf{x}_c \\ \mathbf{w}_c \end{array} + \begin{array}{c} \mathbf{w}_p \\ \mathbf{w}_v \\ \mathbf{w}_a \\ \mathbf{w}_c \end{array} \quad (7.187)$$

式中 $\mathbf{I}$ 为 3×3 的单位矩阵。

对于北斗和 GPS 双模观测量的情况, 和 P 模型及 PV 模型类似, 只需在系统状态矢量中增加 T_{GB} 项, 系统状态方程如下式所示:

$$\begin{array}{cccccc} \dot{\mathbf{x}}_p & \mathbf{0} & \mathbf{I} & \mathbf{0} & \mathbf{0} & \mathbf{0} & \mathbf{x}_p & \mathbf{w}_p \\ \dot{\mathbf{x}}_v & \mathbf{0} & \mathbf{0} & \mathbf{I} & \mathbf{0} & \mathbf{0} & \mathbf{x}_v & \mathbf{w}_v \\ \dot{\mathbf{x}}_a & \mathbf{0} & \mathbf{0} & \mathbf{D} & \mathbf{0} & \mathbf{0} & \mathbf{x}_a & \mathbf{w}_a \\ \dot{T}_{GB} & \mathbf{0} & \mathbf{0} & \mathbf{0} & \mathbf{0} & \mathbf{0} & T_{GB} & \mathbf{w}_T \\ \dot{\mathbf{x}}_c \end{array} = \begin{array}{cccccc} & & & & & & & \\ & & & & & & & \\ & & & & & & & \\ & \mathbf{0} & \mathbf{0} & \mathbf{0} & \mathbf{0} & F_c \end{array} \begin{array}{c} \mathbf{x}_c \\ \mathbf{w}_c \end{array} + \begin{array}{c} \mathbf{w}_p \\ \mathbf{w}_v \\ \mathbf{w}_a \\ \mathbf{w}_T \\ \mathbf{w}_c \end{array} \quad (7.188)$$

上式中 T_{GB} 依然被建模成随机游走过程。双模伪距观测量和多普勒观测量与 PV 模型相比没有变化。采用式(7.185)的卡尔曼滤波包含 12 个状态量, 采用式(7.188)的卡尔曼滤波包含 13 个状态量, 在采用单模或双模伪距观测量和多普勒观测量的时候需要将观测矩阵相应的元素加以调整即可, 在此不再赘述。

4. 经纬高模型

上面所讲述的三种系统模型均是在 ECEF 坐标系中, 经纬高模型在测地坐标系中表示位置坐标, 此时位置状态向量 $\mathbf{x}_p = [\phi, \lambda, h]^T$, 其中, ϕ 、 λ 和 h 分别是接收机的经度、纬度和高度, 相应的速度状态向量 $\mathbf{x}_v = [v_n, v_e, v_d]^T$, $\mathbf{x}_v$ 包含了北东地方向的速度分量。时钟状态向量 $\mathbf{x}_c = [b, d]^T$, 其中 b 为本地钟差, d 为本地钟漂。所以这种系统模型下的状态矢量为 $\mathbf{x} = [\mathbf{x}_p^T, \mathbf{x}_v^T, \mathbf{x}_c^T]^T$, 总共包含 8 个状态变量。

根据第 1 章的式(1.39)和(1.40)可得经纬高模型的系统状态方程

$$\begin{array}{ccccccc}
 \dot{\phi} & 0 & 0 & 0 & \frac{1}{R_M + h} & 0 & 0 & 0 & \phi & w_{\phi} \\
 \dot{\lambda} & & & & & & & & \lambda & w_{\lambda} \\
 \dot{h} & 0 & 0 & 0 & 0 & \frac{1}{(R_N + h)\cos\phi} & 0 & 0 & 0 & h & w_h \\
 \dot{v}_n & 0 & 0 & 0 & 0 & 0 & -1 & 0 & 0 & v_n & w_{v_n} \\
 \dot{v}_e & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & v_e & w_{v_e} \\
 \dot{v}_d & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & v_d & w_{v_d} \\
 \dot{b} & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & b & w_b \\
 \dot{d} \rfloor & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & d \rfloor & w_d \rfloor \\
 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \rfloor & &
 \end{array} = \quad (7.189)$$

式(7.189)中的 R_N 和 R_M 定义如下 (见第 1 章):

$$R_N = \frac{a}{1 - e^2 \sin^2 \phi}^{1/2}, \quad R_M = \frac{a(1 - e^2)}{1 - e^2 \sin^2(\phi)}^{3/2}$$

在采用经纬高度作为位置状态向量的情况下, 伪距观测量却很难直接用经纬高度来表示, 伪距数学表达式依然为式(7.177)。由于式(7.177)中的卫星位置和接收机位置都是在 ECEF 坐标系中表达的, 所以无法直接得到伪距观测量和 $[\phi, \lambda, h]^T$ 的关系。在采用 EKF 更新步骤过程中, 计算式(7.169)中的伪距观测量残差

$$\begin{aligned}
 \partial \rho_i &\approx H_{xi} \partial x + H_{yi} \partial y + H_{zi} \partial z + c \partial b \\
 &= \begin{bmatrix} h_{x_i} & h_{y_i} & h_{z_i} \end{bmatrix} \begin{bmatrix} \partial x \\ \partial y \\ \partial z \end{bmatrix} + c \partial b
 \end{aligned} \quad (7.190)$$

其中, $\mathbf{H}_{E_i} = [h_{x_i}, h_{y_i}, h_{z_i}]^T$ 为在 ECEF 坐标系里表示的第 i 个伪距观测量对应的卫星方向余弦矢量。由第 1.2.4 节可知,

$$\begin{bmatrix} \partial x \\ \partial y \\ \partial z \end{bmatrix} = R_{t2e} \begin{bmatrix} \partial n \\ \partial e \\ \partial d \end{bmatrix} \quad (7.191)$$

将式(7.191)代入式(7.190)可以得到

$$\begin{aligned}
 \partial \rho_i &\approx \begin{bmatrix} h_{n_i} & h_{e_i} & h_{d_i} \end{bmatrix} \begin{bmatrix} \partial n \\ \partial e \\ \partial d \end{bmatrix} + c \partial b \\
 &= \mathbf{H}_{T_i} \begin{bmatrix} \partial n \\ \partial e \\ \partial d \end{bmatrix} + c \partial b
 \end{aligned} \quad (7.192)$$

式(7.192)中的 $\mathbf{H}_{T_i} = [h_{n_i}, h_{e_i}, h_{d_i}]^T$ 依然是第 i 个卫星的方向余弦矢量, 却是在

NED 坐标系中表示的, $\mathbf{H}_{T_i}$ 和 $\mathbf{H}_{E_i}$ 的关系为

$$\mathbf{H}_{T_i} = \mathbf{H}_{E_i} \mathbf{R}_{l2e} \quad (7.193)$$

其中, $\mathbf{R}_{l2e}$ 由式(1.32)决定。

同时由式(1.39)可知

$$\begin{aligned} \frac{\partial n}{\partial e} &= \begin{bmatrix} (R_M + h) & 0 & 0 \\ 0 & (R_N + h)\cos(\phi) & 0 \\ 0 & 0 & -1 \end{bmatrix} \begin{bmatrix} \partial\phi \\ \partial\lambda \\ \partial h \end{bmatrix} \end{aligned} \quad (7.194)$$

将式(7.194)代入式(7.192)可得

$$\partial\rho_i \approx \begin{bmatrix} (R_M + h)h_{n_i} & (R_N + h)\cos(\phi)h_{e_i} & -h_{d_i} \end{bmatrix} \begin{bmatrix} \partial\phi \\ \partial\lambda \\ \partial h \end{bmatrix} + c\partial b \quad (7.195)$$

式(7.195)即伪距残差和 $[\partial\phi, \partial\lambda, \partial h]^T$ 的线性关系, 在进行伪距观测量更新时需要用到。

多普勒观测量的情况比伪距观测量简单一些, 可以很容易推导出

$$\begin{aligned} f'_{d_i} &= h_{n_i}v_n + h_{e_i}v_e + h_{d_i}v_d + cd + v_i, \\ &= \mathbf{H}_{T_i} \begin{bmatrix} v_n \\ v_e \\ v_d \end{bmatrix} + cd + v_i, \quad i=1, \dots, m \end{aligned} \quad (7.196)$$

其中, $\mathbf{H}_{T_i}$ 由式(7.193)计算出来。

经纬高模型最大的好处在于直接把接收机的高程量作为系统状态量之一, 这样在有气压计或高度计的情况下很容易实现高度辅助, 只需要把传感器输出的高度值作为一个观测量加入卡尔曼滤波观测量集合即可。

以上分析基于单模伪距观测量的情况, 在北斗和 GPS 双模观测量的情况下只需要将系统状态向量 $\mathbf{x}$ 扩充为 $[\mathbf{x}_p^T, \mathbf{x}_v^T, T_{GB}, \mathbf{x}_e^T]^T$ 即可, 与 P 模型、PV 模型及 PVA 模型中的处理类似, T_{GB} 也被建模成随机游走过程, 读者可以根据前面的讲解自行完成。

5. 实例分析: PV 模型

由于 PV 模型在实际的 GPS 接收机中应用最广泛, 所以这里选择 PV 模型作为一个实现的实例来对本章所讲述的卡尔曼滤波的原理加以概括说明, 同时也在实际中具有一定的实用意义。希望读者根据该实例的方法能举一反三, 真正理解卡尔曼滤波器的原理, 并推广到更多的实际应用中。

PV 模型的状态矢量包括接收机的位置、速度和时钟参量, 所以适用的场景包括平稳运动的车、船、行人和低速飞行器等, 由于涵盖了人们日常生活中的大部分运动场景, 所以 PV 模型在民用接收机中使用得非常广泛, 这也是本书将该模型作为实例分析的原因。

由式(7.182)可以看出, PV 模型的系统状态方程是线性的, 而且 $\mathbf{F}(t)$ 是个常矩阵

$$\begin{aligned}
F(t) = & \begin{bmatrix} 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix}
\end{aligned} \quad (7.197)$$

但由于伪距观测量是非线性的，所以对状态向量 $\mathbf{x}$ 估计需要使用前面讲述的扩展卡尔曼滤波。

首先，需要对伪距方程线性化，根据 7.2.4 节的方法，取误差状态

$$\delta \mathbf{x} = \mathbf{x} - \mathbf{x}^*$$

上式中 $\mathbf{x}$ 是未知的系统真实状态， $\mathbf{x}^*$ 是 $\mathbf{x}$ 临近值域的一个估计值。下面的卡尔曼滤波过程的任务就是尽可能找出 $\mathbf{x}^*$ 和 $\mathbf{x}$ 之差的最优估值，然后对 $\mathbf{x}^*$ 进行修正。

由于系统状态方程本身就是线性的，所以无须对状态方程线性化；伪距方程是非线性的，所以需要线性化。用一阶泰勒级数对伪距观测量方程展开得到

$$\delta \dot{\mathbf{x}}(t) = \mathbf{F} \delta \mathbf{x}(t) + \mathbf{w}(t) \quad (7.198)$$

$$\delta \rho = \mathbf{H} \delta \mathbf{x}(t) + \mathbf{v} \quad (7.199)$$

在实际中， $\mathbf{x}^*$ 的初始化往往是通过最小二乘法得到 PVT 解算的结果，然后利用解算结果来置 $\hat{\mathbf{x}}$ 的初始值，即 $\hat{\mathbf{x}}_0$ 。在卡尔曼进入稳态以后，随着每一个时元观测量不断到来，系统状态被不断更新，则系统状态必然在真实状态 $\mathbf{x}$ 的临近值附近，由此保证了线性化的正确性。

式(7.199)中 $\mathbf{H}$ 的每一个行向量对应一颗卫星的观测方程：

$$\mathbf{H} = \begin{bmatrix} h_{x_1} & h_{y_1} & h_{z_1} & 0 & 0 & 0 & 1 & 0 \\ h_{x_2} & h_{y_2} & h_{z_2} & 0 & 0 & 0 & 1 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ h_{x_m} & h_{y_m} & h_{z_m} & 0 & 0 & 0 & 1 & 0 \end{bmatrix} \quad (7.200)$$

其中， $h_{x_i}, h_{y_i}, h_{z_i} = \left[\frac{\partial \rho_i}{\partial x} \right]_{\mathbf{x}^*}, \left[\frac{\partial \rho_i}{\partial y} \right]_{\mathbf{x}^*}, \left[\frac{\partial \rho_i}{\partial z} \right]_{\mathbf{x}^*}$ ，为第 i 颗卫星和 $\mathbf{x}^*$ 之间的方向余

弦矢量。需要注意的是，随着接收机位置的改变， $\mathbf{H}$ 也随之改变，所以每一次用户位置更新后都需要重新计算 $\mathbf{H}$ 矩阵。

状态处理噪声 $\mathbf{w}(t)$ 的协方差矩阵表示为如式(7.201)所示的 $\mathbf{Q}$ 矩阵，其中只包含了对角线元素，非对角线元素为 0，说明此处认为各个系统状态中的处理噪声各不相关。实际中的 $\mathbf{Q}$ 矩阵并不一定是对角线矩阵，但这并不影响卡尔曼滤波的更新步骤。

$$\mathbf{Q} = \text{var}\{\mathbf{w}(t)\} = \begin{bmatrix} \sigma_p & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & \sigma_p & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & \sigma_p & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & \sigma_v & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & \sigma_v & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & \sigma_v & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & \sigma_b & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & \sigma_d \end{bmatrix} \quad (7.201)$$

这里假设每个状态量的处理噪声相互独立，且为白噪声，各自的噪声功率谱密度分别为 $\text{diag}\{\sigma_p, \sigma_p, \sigma_p, \sigma_v, \sigma_v, \sigma_v, \sigma_b, \sigma_d\}$ 。 $\mathbf{Q}$ 矩阵将在后面计算 $\mathbf{QD}_w$ 的时候用到。

以上 $\mathbf{F}$ 、 $\mathbf{Q}$ 和 $\mathbf{H}$ 都在连续时间域，现在要在计算机上实现卡尔曼滤波，必须推导出离散时间域上相对应的 Φ 和 $\mathbf{QD}_w$ 。根据 7.2.3 节的分析可知：

$$\Phi = e^{\mathbf{F}T} = \begin{bmatrix} 1 & 0 & 0 & T & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & T & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & T & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 & T \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix} \quad (7.202)$$

$$\begin{aligned} \mathbf{QD}_w &\approx \mathbf{Q}T + (\mathbf{FQ} + \mathbf{QF}^T) \frac{T^2}{2!} + 2\mathbf{FQF}^T \frac{T^3}{3!} \\ &= \begin{bmatrix} Q_p & 0 & 0 & \frac{\sigma_v T^2}{2} & 0 & 0 & 0 & 0 \\ 0 & Q_p & 0 & 0 & \frac{\sigma_v T^2}{2} & 0 & 0 & 0 \\ 0 & 0 & Q_p & 0 & 0 & \frac{\sigma_v T^2}{2} & 0 & 0 \\ \frac{\sigma_v T^2}{2} & 0 & 0 & \sigma_v T & 0 & 0 & 0 & 0 \\ 0 & \frac{\sigma_v T^2}{2} & 0 & 0 & \sigma_v T & 0 & 0 & 0 \\ 0 & 0 & \frac{\sigma_v T^2}{2} & 0 & 0 & \sigma_v T & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & Q_b & \frac{\sigma_d T^2}{2} \\ 0 & 0 & 0 & 0 & 0 & 0 & \frac{\sigma_d T^2}{2} & \sigma_d T \end{bmatrix} \end{aligned} \quad (7.203)$$

上式中

$$Q_p = \sigma_p T + \frac{\sigma_v T^3}{3}, \quad Q_b = \sigma_b T + \frac{\sigma_d T^3}{3} \quad (7.204)$$

T 为每一次更新之间的间隔, 现代的 GPS 接收机中一般来说 $T=1$ 秒。对于一些特殊要求的接收机, 比如一些在大动态场合应用的接收机, 要求输出的定位信息的频率更高, 则 T 会取更小的值, 但此时对处理器的处理能力有更高的要求。

式(7.202)和式(7.203)的推导过程中应用了 F 的性质: $F^n = \mathbf{0}, n \geq 2$ 。做完了以上的准备工作后, 就可以实现卡尔曼滤波的两步更新了, 即时间更新和观测量更新。

假设在时刻 t_k 的系统状态为 $\hat{\mathbf{x}}_{k|k}$, 状态的协方差矩阵为 $\mathbf{P}_{k|k}$ 。首先进行系统状态和状态协方差矩阵的时间更新:

$$\hat{\mathbf{x}}_{k+1|k} = \Phi_k \hat{\mathbf{x}}_{k|k} \quad (7.205)$$

$$\mathbf{P}_{k+1|k} = \Phi_k \mathbf{P}_{k|k} \Phi_k^T + \mathbf{QD}_w \quad (7.206)$$

这里由于状态方程是线性的, 所以 $\hat{\mathbf{x}}_{k|k}$ 的时间更新也是线性的。更进一步来说, 对 PV 模型来说, 对 $\hat{\mathbf{x}}_{k|k}$ 的时间更新其实就是

$$x_{k+1|k} = x_{k|k} + v_{x,k|k} T$$

$$y_{k+1|k} = y_{k|k} + v_{y,k|k} T$$

$$z_{k+1|k} = z_{k|k} + v_{z,k|k} T$$

$$b_{k+1|k} = b_{k|k} + d_{k|k} T$$

这里 T 是此次更新和上次更新的时间间隔, 即 $T = t_{k+1} - t_k$ 。利用上式可以避开烦琐的矩阵相乘。

然后根据时间更新以后的系统状态 $\hat{\mathbf{x}}_{k+1|k}$ 对观测量进行预测, 即

$$\hat{\rho}_i = \sqrt{(x_{k+1|k} - x_{si})^2 + (y_{k+1|k} - y_{si})^2 + (z_{k+1|k} - z_{si})^2} + b_{k+1|k}, \quad (i = 1, \dots, m) \quad (7.207)$$

由于观测方程是非线性的, 所以这里对观测量进行预测也是状态参量的非线性函数。随着观测量 $\tilde{\rho}_{k+1} = [\tilde{\rho}_1, \dots, \tilde{\rho}_m]^T$ 的到来, 可以计算伪距残差

$$\delta \rho_{k+1} = \tilde{\rho}_{k+1} - \hat{\rho} \quad (7.208)$$

卡尔曼增益 $\mathbf{k}_{k+1}$ 的计算方法如下:

$$\mathbf{k}_{k+1} = \mathbf{P}_{k+1|k} \mathbf{H}_{k+1}^T [\mathbf{H}_{k+1} \mathbf{P}_{k+1|k} \mathbf{H}_{k+1}^T + \mathbf{R}_{k+1}]^{-1} \quad (7.209)$$

其中 $\mathbf{R}_{k+1}$ 是观测量方差矩阵, $\mathbf{H}_{k+1}$ 通过式(7.200)计算得到。

对系统状态的时间更新 $\hat{\mathbf{x}}_{k+1|k}$ 进行观测量更新:

$$\hat{\mathbf{x}}_{k+1|k+1} = \hat{\mathbf{x}}_{k+1|k} + \mathbf{k}_{k+1} \delta \rho_{k+1} \quad (7.210)$$

然后更新状态协方差矩阵 $\mathbf{P}_{k+1|k}$:

$$\mathbf{P}_{k+1|k+1} = (\mathbf{I} - \mathbf{k}_{k+1} \mathbf{H}_{k+1}) \mathbf{P}_{k+1|k} \quad (7.211)$$

更新以后的 $\hat{\mathbf{x}}_{k+1|k+1}$ 和 $\mathbf{P}_{k+1|k+1}$ 被保存下来为下一个时元的更新做准备。

以上就是在 GPS 接收机内部利用 PV 模型对用户的位置、速度和钟差进行卡尔曼滤波的基本过程，在北斗 / GPS 双模观测量情况下可以按照式(7.184)展开，具体步骤和上述过程类似。限于篇幅，我们只对伪距观测量的使用进行了描述，对于多普勒观测量的处理步骤，读者可以根据本节和前面几节的原理描述自行推导。在实际的接收机内部，可靠而稳定的导航算法是非常复杂繁重的任务，需要完成的工作远远不止以上的描述。本节的内容只是对接收机内部的扩展卡尔曼滤波的原理做了尽量详细的原理性说明，希望能对读者在实际工作中有所帮助。

7.2.6 卡尔曼滤波具体实现中的技术处理

上面章节中讲述的是卡尔曼滤波的基本方程，对于理解卡尔曼滤波的原理已经足够了，但是在卡尔曼滤波的工程实现过程中，往往有一些需要特殊考虑的问题，相应地就有一些特殊的技巧和处理方法。这些技巧和方法从原理上并不改变卡尔曼滤波的基本性质，但在实际工作中却是非常重要的部分，有些技巧的应用能在很大程度上减少运算量，有些能帮助使系统工作得更稳定，有些则使得卡尔曼滤波的噪声模型更贴近实际情况。本节将这些技巧和问题汇总如下。

1. 输入为有色噪声的情况

从式(7.115)和式(7.116)可知，卡尔曼滤波需要处理的噪声和观测噪声都是白噪声，在输入不是白噪声的情况下，卡尔曼滤波的后续处理尤其是系统状态协方差矩阵的更新就会出现問題。

考虑系统的状态方程和观测方程如式(7.212)和式(7.213)所示，即

$$\mathbf{x}_m = \Phi_{m-1} \mathbf{x}_{m-1} + \mathbf{G}_{m-1} \mathbf{u}_{m-1} + \mathbf{\Gamma}_{m-1} \mathbf{w}_{m-1} \quad (7.212)$$

$$\mathbf{y}_m = \mathbf{H}_m \mathbf{x}_m + \mathbf{v}_m \quad (7.213)$$

当处理噪声 $\mathbf{w}_m$ 为有色噪声的情况下，可以假设 $\mathbf{w}_m$ 满足方程

$$\mathbf{w}_m = \mathbf{B}_m \mathbf{w}_{m-1} + \boldsymbol{\zeta}_{m-1} \quad (7.214)$$

式(7.214)中的 $\boldsymbol{\zeta}_{m-1}$ 为零均值白噪声。

此时可以将 $\mathbf{w}_m$ 增扩为系统状态，即新的系统状态矢量为 $\mathbf{X}_m = \begin{bmatrix} \mathbf{x}_m \\ \mathbf{w}_m \end{bmatrix}$ ，则新的系统状态方程和观测方程为

$$\begin{bmatrix} \mathbf{x}_m \\ \mathbf{w}_m \end{bmatrix} = \begin{bmatrix} \Phi_{m-1} & \mathbf{\Gamma}_{m-1} \\ \mathbf{0} & \mathbf{B}_{m-1} \end{bmatrix} \begin{bmatrix} \mathbf{x}_{m-1} \\ \mathbf{w}_{m-1} \end{bmatrix} + \begin{bmatrix} \mathbf{G}_{m-1} \\ \mathbf{0} \end{bmatrix} \mathbf{u}_{m-1} + \begin{bmatrix} \mathbf{0} \\ \mathbf{I} \end{bmatrix} \boldsymbol{\zeta}_{m-1} \quad (7.215)$$

$$\mathbf{y}_m = \begin{bmatrix} \mathbf{H}_m & \mathbf{0} \end{bmatrix} \begin{bmatrix} \mathbf{x}_m \\ \mathbf{w}_m \end{bmatrix} + \mathbf{v}_m \quad (7.216)$$

这样式(7.215)和式(7.216)中的噪声都为白噪声，符合卡尔曼滤波的基本方程对于噪声的要求。

在观测噪声 $\mathbf{v}_m$ 为有色噪声的情况下, 处理略有不同, 此时无法采用将 $\mathbf{v}_m$ 增扩为系统状态的方法, 因为这样做会导致观测方程中没有观测噪声, 在计算卡尔曼增益时会导致矩阵求逆发散。

假设观测噪声 $\mathbf{v}_m$ 符合以下方程

$$\mathbf{v}_m = \mathbf{T}_m \mathbf{v}_{m-1} + \boldsymbol{\zeta}_{m-1} \quad (7.217)$$

由式(7.213)可知

$$\begin{aligned} \mathbf{y}_{m+1} &= \mathbf{H}_{m+1} \mathbf{x}_{m+1} + \mathbf{v}_{m+1} \\ &= \mathbf{H}_{m+1} (\boldsymbol{\Phi}_m \mathbf{x}_m + \mathbf{G}_m \mathbf{u}_m + \boldsymbol{\Gamma}_m \mathbf{w}_m) + (\mathbf{T}_{m+1} \mathbf{v}_m + \boldsymbol{\zeta}_m) \\ &= \mathbf{H}_{m+1} (\boldsymbol{\Phi}_m \mathbf{x}_m + \mathbf{G}_m \mathbf{u}_m + \boldsymbol{\Gamma}_m \mathbf{w}_m) + [\mathbf{T}_{m+1} (\mathbf{y}_m - \mathbf{H}_m \mathbf{x}_m) + \boldsymbol{\zeta}_m] \\ &= (\mathbf{H}_{m+1} \boldsymbol{\Phi}_m - \mathbf{T}_{m+1} \mathbf{H}_m) \mathbf{x}_m + \mathbf{H}_{m+1} \mathbf{G}_m \mathbf{u}_m + \mathbf{T}_{m+1} \mathbf{y}_m + (\mathbf{H}_{m+1} \boldsymbol{\Gamma}_m \mathbf{w}_m + \boldsymbol{\zeta}_m) \end{aligned} \quad (7.218)$$

由式(7.218)稍作变换得到

$$\mathbf{y}_{m+1} - \mathbf{T}_{m+1} \mathbf{y}_m = (\mathbf{H}_{m+1} \boldsymbol{\Phi}_m - \mathbf{T}_{m+1} \mathbf{H}_m) \mathbf{x}_m + \mathbf{H}_{m+1} \mathbf{G}_m \mathbf{u}_m + (\mathbf{H}_{m+1} \boldsymbol{\Gamma}_m \mathbf{w}_m + \boldsymbol{\zeta}_m) \quad (7.219)$$

定义

$$\begin{aligned} \mathbf{Y}_k &\triangleq \mathbf{y}_k - \mathbf{T}_k \mathbf{y}_{k-1}, \\ \mathbf{H}_k^* &\triangleq \mathbf{H}_k \boldsymbol{\Phi}_{k-1} - \mathbf{T}_k \mathbf{H}_{k-1}, \\ \mathbf{V}_k &\triangleq \mathbf{H}_k \boldsymbol{\Gamma}_{k-1} \mathbf{w}_{k-1} + \boldsymbol{\zeta}_{k-1} \end{aligned}$$

则式(7.219)可以重写为

$$\mathbf{Y}_{m+1} = \mathbf{H}_{m+1}^* \mathbf{x}_m + \mathbf{H}_{m+1} \mathbf{G}_m \mathbf{u}_m + \mathbf{V}_{m+1} \quad (7.220)$$

式(7.220)是新的量测方程, 可以证明新的观测噪声 $\mathbf{V}_k$ 为零均值白噪声, 符合卡尔曼滤波对观测噪声的要求, 但唯一的问题是 $\mathbf{V}_k$ 和 $\mathbf{w}_m$ 相关, 即量测噪声和处理噪声不再是不相关的, 式(7.117)不再成立。有关量测噪声和处理噪声相关条件下的卡尔曼滤波, 限于篇幅本书不展开详述了, 感兴趣的读者可以参看参考文献[22]的第2章。

2. 观测量的序贯(串行)更新

假设在 t_k 时刻有 m 个观测量同时来到, 根据 7.2.2 节一般的处理将这 m 个观测量组成一个 $m \times 1$ 的向量, 以一种并行处理的方式得到卡尔曼增益和状态修正量。

$$\begin{aligned} \mathbf{k}_k &= \mathbf{P}_k^- \mathbf{H}_k^T (\mathbf{H}_k \mathbf{P}_k^- \mathbf{H}_k^T + \mathbf{R}_k)^{-1} \\ \delta \hat{\mathbf{x}}_k &= \mathbf{k}_k (\tilde{\mathbf{y}}_k - \hat{\mathbf{y}}_k) \end{aligned}$$

可见, 在这种常规的并行处理方式中, 矩阵的逆运算是必不可少的。尤其是当观测量数目比较多时, $(\mathbf{H}_k \mathbf{P}_k^- \mathbf{H}_k^T + \mathbf{R}_k)$ 的维数可以很大, 所以在很多场合尤其是嵌入式应用的场合这种方法会带来非常繁重的运算量负担。

在实际中, 当观测量协方差矩阵 $\mathbf{R}$ 是对角矩阵的时候, 即

$$\mathbf{R} = \begin{bmatrix} R_1 & \cdots & 0 \\ \vdots & & \vdots \\ 0 & \cdots & R_m \end{bmatrix}$$

可以将这 m 个观测量看作“依次顺序”到来的，从而能以一种串行的方式来处理，即对每一个观测量 $\tilde{y}_i$ ，假设其噪声方差为 R_i ， $i=1, \dots, m$ ，可以计算这一个观测量导致的卡尔曼增益 $\mathbf{k}_i$ 、 $\mathbf{P}_i$ 和 $\mathbf{x}_k$ 的更新值。

首先可以引进两个辅助向量

$$\hat{\mathbf{x}}_0 = \mathbf{x}_k^-, \quad \mathbf{P}_0 = \mathbf{P}_m^-$$

此处 $\mathbf{x}_k^-$ 和 $\mathbf{P}_m^-$ 分别是经过时间更新以后的系统状态和状态误差方差矩阵，然后顺序对第 i 个观测量， $i=1, \dots, m$ ，做如下计算

$$\mathbf{k}_i = \frac{\mathbf{P}_{i-1} \mathbf{h}_i^T}{\mathbf{h}_i \mathbf{P}_{i-1} \mathbf{h}_i^T + R_i} \quad (7.221)$$

$$\hat{\mathbf{x}}_i = \hat{\mathbf{x}}_{i-1} + \mathbf{k}_i (\tilde{y}_i - \mathbf{h}_i \hat{\mathbf{x}}_{i-1}) \quad (7.222)$$

$$\mathbf{P}_i = [\mathbf{I} - \mathbf{k}_i \mathbf{h}_i] \mathbf{P}_{i-1} \quad (7.223)$$

上式中 $\mathbf{h}_i$ 是 $\mathbf{H}_k$ 矩阵中和观测量 $\tilde{y}_i$ 对应的行向量。重复式(7.221)到(7.223)的处理，直到处理完所有的 m 个观测量。在处理完所有的 m 个观测量以后，应该重置总的系统状态和状态方差矩阵：

$$\mathbf{x}_k^+ = \hat{\mathbf{x}}_m, \quad \mathbf{P}_m^+ = \mathbf{P}_m$$

很容易看到，根据每一个观测量进行观测量更新的时候，由于只有一个观测量，所以 $(\mathbf{h}_i \mathbf{P}_{i-1} \mathbf{h}_i^T + R_i)$ 是一个 1×1 的“矩阵”，即是一个数字，所以通过这种串行方式，将一个维数很大的矩阵求逆运算变换为若干个数字求倒数的运算。同时 $\mathbf{k}_i$ 也不再是一个矩阵，而是一个向量。

这种处理可以等效地看作对系统进行了若干次观测量更新，由于这些观测量都是同时到来的，即 $\Delta t = 0$ ，所以不需要做时间更新。序贯处理的累计的状态量更新 $\delta \hat{\mathbf{x}}_k$ 和并行处理是一样的，但最终的卡尔曼增益 $\mathbf{k}_m$ 却和并行处理却不一样，这是因为并行处理的 $\mathbf{k}_m$ 是基于所有观测量得到的，而这里却是每一次根据一个观测量得到的。

当观测量协方差矩阵 $\mathbf{R}$ 不是对角矩阵时，由于 $\mathbf{R}$ 是正定矩阵，所以可以将 $\mathbf{R}$ 分解为下三角矩阵相乘的形式，

$$\mathbf{R} = \mathbf{E} \mathbf{E}^T \quad (7.224)$$

然后对观测方程两边同时乘以可得

$$\mathbf{E}^{-1} \mathbf{y}_m = \mathbf{E}^{-1} \mathbf{H}_m \mathbf{x}_m + \mathbf{E}^{-1} \mathbf{v}_m \quad (7.225)$$

定义

$$\bar{\mathbf{y}}_m \triangleq \mathbf{E}^{-1} \mathbf{y}_m,$$

$$\bar{\mathbf{H}}_m \triangleq \mathbf{E}^{-1} \mathbf{H}_m,$$

$$\bar{\mathbf{v}}_m \triangleq \mathbf{E}^{-1} \mathbf{v}_m$$

则新的观测方程变为

$$\bar{\mathbf{y}}_m = \bar{\mathbf{H}}_m \mathbf{x}_m + \bar{\mathbf{v}}_m \quad (7.226)$$

并且可以验证新的观测量协方差矩阵

$$\bar{\mathbf{R}} = E\{\bar{\mathbf{v}}_m \bar{\mathbf{v}}_m^T\} = \mathbf{I}$$

所以可以继续利用观测量协方差矩阵是对角矩阵的处理方法。

3. 观测量有效性检测

在实际应用中, 由于某种原因往往使有错误或无效的观测量进入卡尔曼滤波器, 如果基于这些错误的观测量对系统状态进行更新会导致错误的系统状态。幸运的是, 卡尔曼滤波器从其原理上提供了对这些错误观测量筛选的机制。

考虑在某一时刻的观测量 $\tilde{\mathbf{y}}$, 假设其观测量方差为 $\mathbf{R}$, 系统状态协方差矩阵为 $\mathbf{P}$, 则根据系统状态 $\mathbf{x}$ 对观测量进行预测值为 $\hat{\mathbf{y}}$, 那么其观测量残差 $\delta\mathbf{y} = \tilde{\mathbf{y}} - \hat{\mathbf{y}}$ 为一个随机变量, 并且

$$E\{\delta\mathbf{y}\} = 0, \quad \text{var}\{\delta\mathbf{y}\} = \mathbf{H}\mathbf{P}\mathbf{H}^T + \mathbf{R} \quad (7.227)$$

于是可以定一个阈值 α , 使

$$\text{概率}\{(\delta\mathbf{y})^2 > \alpha(\mathbf{H}\mathbf{P}\mathbf{H}^T + \mathbf{R})\} \approx 0 \quad (7.228)$$

于是满足上式条件的观测量就可以认为是一个错误或无效的观测量, 从而被剔除出去不进行卡尔曼滤波的更新。 α 的值可以根据实际工程的情况而定, 基本原则是能剔除错误的观测量, 同时又不能过多干涉正确的观测量更新。

这里描述的方法往往被称作更新检测 (Innovation Check)。需要注意的是, 当由于某种原因系统状态偏离真实状态很远时, 即使正确的观测量也无法通过更新检测, 所以实用的策略必然需要考虑如何应对这种情况, 一个简单而有效的策略是如果信号质量足够好却被更新检测逻辑剔除出去的话, 就需要仔细检查当前系统状态的有效性。可以很容易看出, 更新检测可以很自然地在观测量的串行处理过程中应用, 每更新一个观测量时进行一次更新检测。需要注意的是, 此时一个有趣的技巧是观测量串行处理的顺序。一般需要对观测量的可信度进行排序, 先处理可信度高的观测量, 后处理可信度低的观测量, 这样不至于由于坏的观测量对系统状态的错误更新而使正常的观测量不能通过更新检测。

4. 丢失或无效的观测量

有时由于系统故障或通信问题, 观测量发生丢失或者无法被卡尔曼滤波模块得到, 在这种情况下时间更新依然可以进行, 观测量更新就没法进行了。

从另一个角度考虑, 当观测量丢失时, 可以认为观测量的不确定性是无穷大, 即 $\mathbf{R} = \infty$, 根据卡尔曼增益的公式

$$\mathbf{k} = \mathbf{P}^- \mathbf{H}(\mathbf{H}\mathbf{P}^- \mathbf{H}^T + \mathbf{R})^{-1}$$

可以看出, 因为 $\mathbf{R} = \infty$, 所以 $\mathbf{k} = \mathbf{0}$, 于是对系统状态的更新量必然为 $\mathbf{0}$, 导致此时对系统状态没有观测量更新, 但时间更新在继续, 同时 $\mathbf{P}_{k+1|k} = \Phi_k \mathbf{P}_{k|k} \Phi_k^T + \mathbf{Q}\mathbf{D}_w$, 所以系统状态协方差矩阵会递增, 表示系统状态的不确定性在增加。

5. 保持 $\mathbf{P}$ 矩阵的对称和正定

系统状态的协方差矩阵 $\mathbf{P}$ 从其自身定义来说是对称阵,而且还应该是正定矩阵。从时间更新得到的 $\mathbf{P}^-$ 到观测量更新后 $\mathbf{P}^+$ 的公式

$$\mathbf{P}^+ = (\mathbf{I} - \mathbf{kH})\mathbf{P}^-$$

似乎从形式上看不出 $\mathbf{P}^+$ 的对称性,但如果将 $\mathbf{k}$ 的计算公式

$$\mathbf{k} = \mathbf{P}^- \mathbf{H}^T (\mathbf{H} \mathbf{P}^- \mathbf{H}^T + \mathbf{R})^{-1}$$

代入就得到

$$\mathbf{P}^+ = \mathbf{P}^- - \mathbf{P}^- \mathbf{H}^T (\mathbf{H} \mathbf{P}^- \mathbf{H}^T + \mathbf{R})^{-1} \mathbf{H} \mathbf{P}^- \quad (7.229)$$

由式(7.229)可以看出,在 $\mathbf{P}^-$ 和 $\mathbf{R}$ 是对称阵的情况下,理论上 $\mathbf{P}^+$ 也一定是对称阵。因为在下一个时刻,当对 $\mathbf{P}^+$ 进行时间更新时,其操作也是对称的。所以在任何时刻, $\mathbf{P}^-$ 和 $\mathbf{P}^+$ 必定是对称阵。

在具体的实现过程中,由于计算机的字长效应和舍入效应不可避免,必然会导致 $\mathbf{P}$ 逐渐变得不对称,同时还会失去其正定性。当 $\mathbf{P}$ 变得非正定时,卡尔曼增益 $\mathbf{k}$ 无法实现观测量和本地状态之间真实的权重值,从而会使系统状态的更新出现严重错误。有一些方法可以保证 $\mathbf{P}$ 的对称性,其中之一是在每一次观测量更新以后,用 $\mathbf{P}$ 和 $\mathbf{P}^T$ 的平均重置 $\mathbf{P}$, 即

$$\mathbf{P} = \frac{1}{2}(\mathbf{P} + \mathbf{P}^T) \quad (7.230)$$

这个方法在实际中因为简单有效所以得到了很广泛的应用。

另一种非常简单的方法是在计算 $\mathbf{P}^+$ 的过程中,只计算对角线的元素和上半部分的元素,即 $\{P_{i,j}, i \leq j, i=1, \dots, n\}$, 这里 n 是 $\mathbf{P}$ 矩阵的维数,然后根据 $\mathbf{P}$ 矩阵的对称性,用其上半部分的元素来置其下半部分的元素,即

$$P_{j,i} = P_{i,j} \quad i < j,$$

但上面这两种方法只能保证 $\mathbf{P}$ 矩阵的对称性,却无法保证 $\mathbf{P}$ 矩阵的正定性。更进一步的方法还可以采用平方根滤波和 UDU 分解滤波方法。平方根滤波的基本思想是利用矩阵理论中的一个结论,即非负定的对称矩阵 $\mathbf{P}$ 总能被分解为两个三角矩阵相乘的形式,即

$$\mathbf{P} = \Delta \Delta^T \quad (7.231)$$

其中 Δ 为上三角或下三角矩阵,被称作 $\mathbf{P}$ 的平方根矩阵, Δ 矩阵可以通过对 $\mathbf{P}$ 进行 Cholesky 分解得到。后续的卡尔曼状态协方差矩阵的更新都基于 Δ 矩阵进行,由于式(7.231)保证了 $\mathbf{P}$ 的正定性和对称性,所以平方根滤波的优势在于能够严格保证 $\mathbf{P}$ 矩阵正定的同时,还能只用 $\mathbf{P}$ 矩阵一半的字长就能保证滤波结果的数值精度。UDU 分解滤波则是利用 $\mathbf{P}$ 矩阵的 UD 分解,即

$$\mathbf{P} = \mathbf{U} \mathbf{D} \mathbf{U}^T \quad (7.232)$$

其中, $\mathbf{U}$ 为上三角矩阵; $\mathbf{D}$ 为对角线矩阵; UDU 分解滤波在滤波过程中不再传

递容易因字长效应而失去正定性的 $\mathbf{P}$ 矩阵, 而是传递 $\mathbf{U}$ 、 $\mathbf{D}$ 矩阵。

这些方法通过对 $\mathbf{P}$ 矩阵进行平方根分解和 $\mathbf{UDU}$ 分解, 从而把对 $\mathbf{P}$ 矩阵的更新过程变为对平方根矩阵 Δ 或 $\mathbf{U}$ 、 $\mathbf{D}$ 矩阵的更新, 能够严格保证 $\mathbf{P}$ 矩阵的正定性, 但代价是增大运算量。由于篇幅所限, 这里就不详细讲解平方根滤波和 $\mathbf{UDU}$ 滤波的具体细节了, 感兴趣的读者可以阅读有关卡尔曼滤波原理的相关文献和书籍。



7.3 最小二乘法和卡尔曼滤波总结

北斗和 GPS 接收机通过伪距观测量和多普勒观测量计算用户的位置、速度和时间信息, 简称 PVT 解算, 在具体实现 PVT 解算的过程中, 可以采用最小二乘法或卡尔曼滤波法。

最小二乘法所得到的定位结果是基于某个时元的一组观测量, 和其他时元的观测量无关。接收机在提取观测量时, 不同时元的观测量是相互独立提取的, 所以来自于不同时元的观测量可以认为是相互独立的。由此基于不同时元的最小二乘定位结果的误差特性可以认为类似于白噪声, 所以最小二乘定位的结果在时间上有着类似白噪声的跳跃现象。

卡尔曼滤波器是一种线性、递归的估值方法, 被广泛应用在现代控制、参数估计及自适应滤波等系统中。卡尔曼滤波器理论基于系统处理噪声是高斯白噪声的前提。接收机中的卡尔曼滤波器基于多个时元的观测量, 可以认为共享了不同时元的观测量的所有信息。尽管在不同的时元的观测量噪声可以认为是白高斯分布, 但由于卡尔曼滤波对于不同时元的信息共享, 卡尔曼滤波的定位结果的误差特性表现为有色噪声分布, 体现在时间上其定位误差是连续缓变的。图 7.12 给出了在静态天线的情况下, 最小二乘定位结果和卡尔曼滤波定位结果的二维误差图示。为了保证比较的公正性, 最小二乘法和卡尔曼滤波方法处理的是相同的中频数据, 左半图是最小二乘定位的定位结果, 右半图是卡尔曼滤波的定位结果。横坐标和纵坐标分别是用户 ENU 坐标系中的正东和正北方向的误差, 单位均为米。图中相邻时刻的定位误差结果被细实线连接起来。可以很清楚地看出, 最小二乘定位的误差呈杂乱无章的分布, 而卡尔曼滤波的误差呈现一定规律的缓慢变化, 而且整体来说, 卡尔曼滤波的定位结果要比最小二乘定位结果的误差小一些, 这也体现了卡尔曼处理的低通滤波特性。卡尔曼滤波结果中的起始点在图中标出, 可以清楚地看到在迭代开始时刻卡尔曼滤波的更新量较大, 体现在图中就是相邻点之间的间距较大, 随着迭代次数增加, 卡尔曼滤波的 $\mathbf{P}$ 矩阵收敛, 则卡尔曼滤波的增益矩阵更依赖于本地状态, 导致卡尔曼滤波的更新量变小, 体现在图中就是相邻点之间的间距变小。




图 7.12 最小二乘法和卡尔曼滤波的定位结果比较

下面的一个例子更清楚的说明了卡尔曼滤波定位误差的有色噪声特性。

在本例中，接收机天线静止，接收机的输出包含了历时 500 秒的两种方法的定位结果，如图 7.13 所示。在 200 秒的时刻，将某一刻卫星的伪距观测量人为地引入




图 7.13 在 200 秒时刻引入的某颗伪距观测量误差导致的卡尔曼滤波和最小二乘法定位结果的不同表现

50 km 的跳变, 则卡尔曼滤波和最小二乘法都会出现较大定位误差。图中左边的三幅图分别是卡尔曼滤波输出的 ECEF 坐标系的 (x, y, z) 坐标, 而右边的三幅图分别是最小二乘法的 ECEF 坐标系的 (x, y, z) 坐标。可以看出, 最小二乘法只是在 200 秒时刻的定位结果出现偏差, 然后迅速回到正确的定位结果, 也就是说, 后续时刻的定位结果不受前一时刻的错误结果影响; 而卡尔曼滤波不仅在 200 秒时刻出现错误的定位结果, 而且在随后的较长一段时间内定位误差依然在延续, 一段时间以后才逐渐回到正确的定位结果。由此可以看出, 卡尔曼滤波的定位结果在时间上是相互关联的。

从问题的本质上看, 卡尔曼滤波结果的有色噪声特性来自于系统状态方程的约束, 例如, 在 PV 模型中, 位置和速度之间存在严格的积分关系, 所以当前时刻的定位结果和下一时刻的定位结果存在物理上的约束关系, 而这个约束来自于接收机自身的速度矢量, 卡尔曼滤波过程中的时间更新就是这种物理关系的体现, 而后续的观测量更新只不过是基于时间更新和观测量之间的残差进行修正的, 这样就决定了卡尔曼滤波的定位结果在时间上必定是相互关联的, 而充分利用时间上的相关关联特性是卡尔曼滤波和最小二乘的最大区别, 也是卡尔曼滤波的定位结果比最小二乘法的结果更为平滑的原因所在。

从最优估计的意义来看, 最小二乘法和卡尔曼滤波都基于 Least Square 的原则对用户位置进行估计, 但最小二乘法针对当前时元的一组观测量进行 Least Square 估计; 而卡尔曼滤波是巧妙地利用递推方式对从接收机上电时刻的观测量直到当前时元的观测量的基础上进行 Least Square 估计。最小二乘法不需要知道系统状态的统计特性, 甚至也无须知道观测量的统计特性, 其最优指标仅仅是量测估计的数值精度达到最优, 关于这一点从代价函数式(7.2)和式(7.15)可以看出, 所以最小二乘法的估计精度不高, 而且当观测量出现较大偏差时也会引起估计结果的较大偏差, 但由于算法简单、适用条件宽泛, 所以实际中仍然大量使用。虽然在已知观测向量的协方差矩阵的情况下, 可以根据式(7.10)和式(7.20)计算估计误差的协方差矩阵, 但这一点并不是必须的, 也就是说最小二乘法的估值结果并不需要以式(7.10)和式(7.20)的计算结果作为前提, 而与此相反, 卡尔曼滤波在得到系统状态估值的过程中必须计算 P 矩阵, 也就是估计误差的协方差矩阵。

卡尔曼滤波方法必须首先定义一个系统状态向量 x , 然后基于 x 求解一个时间-状态方程, 对观测量来说也必须是 x 的线性或非线性方程。如果无法导出系统状态向量的时间-状态方程, 则无法利用卡尔曼滤波的方法。时间-状态方程还必须能反映实际的系统运行情况, 否则卡尔曼滤波也无法达到预期的效果。比如对于高速运动的物体采用 P 模型, 就无法准确估计物体的速度矢量。

最小二乘法利用至少 4 颗卫星的观测量, 由每一颗卫星的观测量提供了一个方程, 通过非线性迭代的方式解出 4 个未知量, 即用户的三个位置坐标和一个时钟偏差。不同于最小二乘法, 卡尔曼滤波根据系统状态转换方程得到对当前系统状态的时间更新, 时间更新对卫星数目没有要求。在时间更新以后, 随着观测量的到来,

根据观测量的方程在时间更新的基础上进行观测量更新。在观测量更新的过程中对卫星数目依然没有要求,所以甚至在只有1~2颗卫星的观测量的情况下,卡尔曼滤波依然能给出定位结果,当然这种定位结果会随着时间的增长会逐渐偏离正确的位置。

从卡尔曼增益 k_m 的表达式

$$k_m = P_m^- H_m^T (H_m P_m^- H_m^T + R_m)^{-1}$$

可以看出,当 R 的对角线上某元素很大时,对应的 k_m 中的元素会很小,说明由对应的观测量导致的 δx 很小;如果 P 的某元素很小时,对应的 k_m 中的元素很小,说明此时的 δx 也很小。通过上述分析,我们可以看出卡尔曼滤波每次对系统状态的更新是基于当前系统状态的不确定度和观测量的不确定度之间的折中。如果当前的系统状态估计的不确定度为零,即当前的系统状态估计非常可靠,则由观测量导致的更新将非常小;反之,如果观测量的不确定度非常低,即观测量非常可信,则系统状态的更新将主要由观测量决定。所以卡尔曼滤波是一种自适应的过程,卡尔曼滤波中的 P 矩阵提供了对系统状态误差的方差估计,即

$$P = \text{cov}\{\delta x \delta^T x\}$$

在实际中, P 矩阵往往被用来对 x 的状态估计误差作出评估,如果 P 矩阵中的元素比较大,则说明对应的系统状态量可信度较低;反之,则说明对应的系统状态量可信度较高。

同时, P 矩阵也能被用来对观测量的可信度作出评估,在7.2.6节我们已经看到如何利用 P 进行观测量有效性检测。而在最小二乘法中,并没有一种直观的方法来对观测量的有效性作出评估。

卡尔曼滤波方法提供了一种数据融合的手段,所以在有些应用场合卡尔曼滤波是系统设计师唯一的选择。在组合导航的系统设计中,除了北斗和GPS接收机本身的卫星伪距和多普勒观测量之外,其他传感器还提供了更多的观测量,比如加速度计和陀螺仪提供了运动物体在三个方向的加速度和角速度量,高度计可以提供当前的水平高度,而数字罗盘可以提供当前的航向角信息,如何充分并有效地利用来自于这些传感器的观测量,就需要借助于卡尔曼滤波的方法,将这些所有的信息揉合在一起,根据系统状态方程和观测量方程作出对系统状态的最优估计,更多的有关这方面的知识读者可以参阅参考文献[21][25][26]。

对于北斗和GPS接收机设计人员来说,最小二乘法作为常规的定位解算方法是必须掌握的知识。随着技术的进步,传感器价格不断下降,越来越多的廉价接收机也开始使用传感器来辅助导航,所以深刻理解并掌握卡尔曼滤波的原理和方法,对实际的系统分析并设计出符合物理实际的卡尔曼滤波模型也显得越来越重要,同时对于学习其他非线性滤波方法,如Unscented卡尔曼滤波(UKF)^{[23][29][33][35]}和粒子滤波等新的滤波原理也是非常重要的理论基础,希望本章的内容可以让读者对这部分内容有初步的了解,并为以后进一步的学习打下基础。

参考文献

- [1] R.Grover Brown, Receiver Autonomous Integrity Monitoring, Chap.5 of Global Positioning System: Theory and Applications, Vol.II, B.Parkinson, J.Spiker, P.Axelrad, and P.Enge., 1996.
- [2] E.D.Kaplan, Understanding GPS Principles and Applications, 2rd Edition,Artech House Publishers, 2006.
- [3] 中国卫星导航系统管理办公室. 北斗卫星导航系统空间信号接口控制文件(公开服务信号) 2.0 版. 2013 年 12 月.
- [4] Pratap Misra, Per Enge. 全球定位系统——信号、测量和性能(第二版). 北京: 电子工业出版社, 2008.
- [5] GuoChang Xu, GPS:Theory, Algorithms and Applications, 2nd Edition, Springer 2010.
- [6] 张守信. GPS 卫星测量定位理论与应用. 北京: 国防科技大学出版社, 1996.
- [7] Sturza, M. A. and Brown, A. K., “Comparison of Fixed and Variable Threshold RAIM Algorithms”, Proceedings of the Third International Technical Meeting of the Satellite Division of The Institute of Navigation (ION GPS-90), Colorado Springs, CO, September 19-21, 1990, pp. 437-43.
- [8] Lee, Y. C., “Analysis of Range and Position Comparison Methods as a Means to Provide GPS Integrity in the User Receiver”, Proceedings of the Annual Meeting of The Institute of Navigation, Seattle, WA, June 24-26, 1986, pp. 1-4.
- [9] Parkinson, B. W. and Axelrad, P., “A Basis for the Development of Operational Algorithms for Simplified GPS Integrity Checking”, Proceedings of the Satellite Division First Technical Meeting, The Institute of Navigation, Colorado Springs, CO, 1987, pp. 269-76.
- [10] Sturza, M. A., “Navigation System Integrity Monitoring Using Redundant Measurements”, NAVIGATION, Journal of The Institute of Navigation, Vol. 35, No. 4, Winter 1988-89, pp. 483-501.
- [11] R.G.Brown and G.Y.Chin, “GPS RAIM: Calculation of Threshold and Protection Radius Using Chi-Square Methods A Geometric Approach”, Global Positioning System, Navigation, Volume V, Journal of The Institute of Navigation, 1997, pp.155-178.
- [12] Brown, R.G., “A Baseline GPS RAIM Scheme and a Note on the Equivalence of Three RAIM Methods”, NAVIGATION, Journal of The Institute of Navigation, Vol.39, No.3, Fall 1992.
- [13] Pakinson, B.W. and Axelrad, P.A., “Autonomous GPS Integrity Monitoring Using the Pseudorange Residual”, NAVIGATION, Journal of The Institute of Navigation, Vol.35, No.2, Summer 1988.
- [14] Chin,G.Y. and Kraemer, J.H., “GPS RAIM Screen Out Bad Geometries Under Worst-Case Bias Conditions”, NAVIGATION, Journal of The Institute of Navigation, Vol.39, No.4, Winter 1992-1993.
- [15] Brown, R.G. and Hwang, P.Y.C., “Introduction to Random Signals and Applied Kalman Filtering”,

- 2nd ed., New York: Wiley, 1992.
- [16] Pervan, B.S., et.al, "Parity Space Methods For Autonomous Fault Detection and Exclusion Algorithms Using Carrier Phase", Proceedings of PLANS 96 Symposium, Atlanta, GA, Apr. 1996.
 - [17] Kelly, R.J., "The Linear Model, RNP, and the Near-Optimum Fault Detection and Exclusion Algorithm", Invited Paper of GPS RedBook, Volume V, 1998.
 - [18] Brenner, M., "Implementation of a RAIM Monitor in a GPS Receiver and an Integrated GPS/IRS", Proceedings of ION GPS-90, Colorado Springs, CO, Sep.1990.
 - [19] Pullen, S. and Enge,P., "Satellite Integrity Monitoring Concepts for GPS/Galileo Augmentation Systems", Proceedings of ION GNSS 17th ITM of the Satellite Division, Long Beach, CA, September 2004.
 - [20] R.G. Brown, P.W. McBurney, "Self-Contained GPS Integrity Check Using Maximum Solution Separation as the Test Statistic", Proceedings of the Satellite Division First Technical Meeting, ION, Colorado Springs, CO, 1987.
 - [21] Jay A. Farrell, Aided Navigation, GPS with High Rate Sensors, McGraw Hill, 2008.
 - [22] 秦永元. 卡尔曼滤波与组合导航原理 (第二版). 西安, 西北工业大学出版社, 2012.
 - [23] Julier Simon J., Uhlmann Jeffrey K., "A New Extension fo the Kalman Filter to Nonlinear Systems", Proceedings of AeroSense, the 11th International Symposium on Aerospace/Defense Sensing, Simulation and Controls, 1997.
 - [24] Grewal M., Andrews A., Kalman Filtering: Theory and Practice Using Matlab, 2nd Edition, John Wiley & Sons Inc, 2001.
 - [25] Jay A. Farrell, M. Barth, "The Global Positioning System and Inertial Navigation", McGraw-Hill, 1999.
 - [26] Grewal M. , Weill L., Andrews A., "Global Positioning Systems, Inertial Navigation, and Integration", John Wiley & Sons Inc, 2001.
 - [27] S. Haykin. "Adaptive Filter Theory", 3rd edition, Prentice-Hall, Inc. ,1996.
 - [28] Kalman R.E., "A New Approach to Linear Filtering and Prediction Problems", Transactions of ASME, Journal of Basic Engineering, Vol.82, 1960.
 - [29] Wan Eric A. , Rudolph V. D. Merwe, "The Unscented Kalman Filter for Nonlinear Estimation".
 - [30] Thornton C.L., "Triangular Covariance Factorizations for Kalman Filtering", NASA PhD Thesis, 1976.
 - [31] Yaakov Bar-Shalom, Li X.Rong, Thiagalingarm Kirubarajan, "Estimation with Applications to Tracking and Navigation", John Wiley & Sons Inc., July 2001.
 - [32] Bierman Gerald J., "Factorization Methods for Discrete Sequential Estimation",Mathematics in Science and Engineering , Vol. 128, Academic Press, NY, 1977 .
 - [33] <http://www.cs.unc.edu/~welch/kalman/>.

- [34] Eric A. Wan, Rudolph V.D. Merwe, The Unscented Kalman Filter, Chap.7 of Kalman Filtering and Neural Networks, John Wiley & Sons, Inc. 2001.
- [35] Arthur Gelb, Applied Optimal Estimation, The MIT Press ,May 15, 1974.
- [36] Tine L. and Herman B. , Comment on “New Method for the Nonlinear Trans-formation of Means and Covariances in Filters and Estimators”, IEEE Transactions of Automatic Control, 2002.
- [37] A. Papoulis, Probability, Random Variables and Stochastic Processes, McGraw Hill, 1991.
- [38] Oppenheim, A. V., A. S. Willsky and S. H. Nawab, Signals and Systems, 2nd edition. Prentice-Hall, Inc. 1997.